



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática



TFG del Grado en Ingeniería
Informática

Creación de RAG para pliegos
de la Diputación



Presentado por Lydia Blanco Ruiz
en Universidad de Burgos
10 de junio de 2026

Tutores: Dr. Álgvar Arnaiz González
y Dr. César Ignacio García Osorio



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática



Los doctores Dr. César Ignacio García Osorio y Dr. Álgvar Arnaiz González, profesores del departamento de Ingeniería Informática, área de Lenguajes y Sistemas Informáticos.

Exponen:

Que la alumna D^a. Lydia Blanco Ruizha realizado el Trabajo final de Grado en Ingeniería Informática titulado Creación de RAG para pliegos de la Diputación.

Y que dicho trabajo ha sido realizado por la alumna bajo la dirección de los que suscriben, en virtud de lo cual se autoriza su presentación y defensa.

En Burgos, 10 de junio de 2026

Vº. Bº. del Tutor:

Vº. Bº. del co-tutor:

Dr. Dr. Álgvar Arnaiz González

Dr. Dr. César Ignacio García
Osorio

Resumen

La contratación pública genera una gran cantidad de documentación técnica y administrativa cuya consulta manual resulta compleja debido a su volumen, heterogeneidad y especialización. En este Trabajo Fin de Grado se presenta PythIA, un sistema basado en la técnica *Retrieval-Augmented Generation* (RAG) diseñado para facilitar la consulta inteligente de las licitaciones públicas mediante el uso de modelos de lenguaje de gran tamaño (LLM).

El proyecto integra un *pipeline* completo de recuperación semántica capaz de automatizar la obtención de documentos mediante técnicas de *Web Scraping*, convertir los documentos PDF extraídos a formato Markdown, fragmentar el contenido en *chunks*, generar *embeddings* y almacenarlos en una base de datos vectorial Qdrant. A partir de las consultas realizadas por el usuario, el sistema recupera los fragmentos documentales más relevantes y los incorpora al contexto del modelo generativo para mejorar la precisión, actualidad y fiabilidad de las respuestas. Esto permite analizar la relevancia, fidelidad y precisión de las respuestas generadas mediante la combinación de los *frameworks* RAGAS y ARES con métricas de *embeddings*.

Además del diseño e implementación del sistema RAG, el proyecto desarrolla una aplicación *web* utilizando Flask, incorporando autenticación de usuarios, historial de consultas, gestión documental, internacionalización, visualización de estadísticas y soporte *responsive*. Esta aplicación *web* ha sido desplegada utilizando Docker, Gunicorn y Nginx.

El proyecto demuestra la viabilidad de aplicar arquitecturas RAG en entornos reales de documentación pública, reduciendo las limitaciones tradicionales de los LLM y facilitando el acceso contextualizado a grandes colecciones documentales.

Descriptores

Modelos de Lenguaje a Gran Escala, Generación Aumentada por recuperación, evaluación RAG, chunks, embeddings, búsqueda semántica, aplicación web, Flask, Web Scraping, licitaciones públicas, bases de datos vectoriales, Docker.

Abstract

Public procurement generates a large amount of technical and administrative documentation whose manual consultation is complex due to its volume, heterogeneity, and specialization. This Bachelor's Thesis presents PythIA, a system based on the Retrieval-Augmented Generation (RAG) technique designed to facilitate the intelligent consultation of public tenders through the use of Large Language Models (LLMs).

The project integrates a complete semantic retrieval pipeline capable of automating document acquisition through Web Scraping techniques, converting extracted PDF documents into Markdown format, splitting the content into chunks, generating embeddings, and storing them in a Qdrant vector database. Based on user queries, the system retrieves the most relevant document fragments and incorporates them into the context of the generative model to improve the precision, relevance, and reliability of the generated responses. In addition, the system enables the analysis of the relevance, faithfulness, and accuracy of the generated answers by combining the RAGAS and ARES frameworks with embedding-based metrics.

Besides the design and implementation of the RAG system, the project also develops a web application using Flask. The application incorporates user authentication, query history, document management, internationalization, statistics visualization, and responsive support. The entire system is deployed using Docker, Gunicorn, and Nginx.

The project demonstrates the feasibility of applying RAG architectures in real-world public documentation environments, reducing the traditional limitations of LLMs and facilitating contextualized access to large document collections.

Keywords

Large Language Models, Retrieval Augmented Generation, RAG evaluation, chunks, embeddings, semantic search, web application, Flask, Web Scraping, public tenders, vector databases, Docker.

Índice general

Índice general	iii
Índice de figuras	v
Índice de tablas	vi
1. Introducción	1
2. Objetivos del proyecto	5
2.1. Objetivos específicos	5
2.2. Objetivos personales	7
3. Conceptos teóricos	9
3.1. <i>Web Scraping</i>	9
3.2. LLM	10
3.3. RAG	11
3.4. Conexión del LLM con el RAG	13
3.5. Diseño del RAG	13
3.6. Evaluación de la calidad del RAG	18
4. Técnicas y herramientas	21
4.1. Metodologías	21
4.2. Repositorio	22
4.3. Gestión de tareas	23
4.4. L ^A T _E X	24
4.5. Entorno de desarrollo	24
4.6. Patrones de diseño	25

4.7. <i>Web Scraping</i>	26
4.8. Gestión de dependencias y entornos Python	26
4.9. Bases de datos	28
4.10. Desarrollo <i>web</i>	30
4.11. Evaluación de la calidad del código	31
4.12. Despliegue de la aplicación	32
4.13. Inteligencia Artificial	36
5. Aspectos relevantes del desarrollo del proyecto	39
5.1. Inicio del proyecto	39
5.2. Web Scraping	40
5.3. <i>Retrieval Augmented Generation</i> (RAG)	41
5.4. Conversión a Markdown	51
5.5. Evaluación RAG	55
5.6. Tareas asíncronas	57
5.7. Desarrollo <i>web</i>	58
5.8. Evaluación de la calidad del código	62
5.9. Despliegue	64
5.10. Integración CI/CD	65
6. Trabajos relacionados	67
6.1. TFG relacionados	67
6.2. Proyectos relacionados	68
6.3. Análisis de las características de los proyectos	69
7. Conclusiones y Líneas de trabajo futuras	73
7.1. Líneas de trabajo futuras	75
Bibliografía	77

Índice de figuras

3.1. Diagrama del funcionamiento del RAG.	12
3.2. Funcionamiento de un modelo LLM con RAG y otro sin él [1]. .	13
3.3. Tríada de evaluación TruEra.	19
4.1. Metodología <i>Scrum</i>	22
4.2. Relación entre las herramientas utilizadas para desplegar la aplicación <i>web</i>	33
5.1. Datos obtenidos de la conversión a Markdown del sistema. . . .	56
5.2. Evolución de la interfaz desde los prototipos iniciales hasta el diseño final.	59
5.3. Distintas pantallas de la aplicación vistas desde un teléfono móvil.	60

Índice de tablas

4.1. Comparativa de Selenium y Playwright.	27
4.2. Comparativa de Qdrant y PyVector.	29
4.3. Comparativa de PostgreSQL y SQLite.	33
5.1. Resumen de resultados obtenidos mediante el proceso de <i>Web Scraping</i>	43
5.2. Pruebas realizadas para la selección de la estrategia de <i>chunking</i>	43
5.3. Comparación de los modelos de <i>embeddings</i> evaluados durante el desarrollo.	45
5.4. Fuentes de consumo computacional durante la conversión de PDF a Markdown mediante OCR multimodal.	52
6.1. Comparativa de las características de los proyectos.	71

1. Introducción

La contratación pública [7] constituye uno de los pilares fundamentales del sector público. A través de este proceso, las administraciones adquieren bienes, servicios y obras necesarias para el desarrollo de sus competencias, garantizando los principios de transparencia, libre concurrencia, igualdad de trato y eficiencia en el uso de los recursos públicos. En España, este procedimiento se materializa en la publicación de licitaciones que incluyen pliegos administrativos y técnicos, resoluciones, anexos y diversa documentación normativa que regula cada contrato.

Sin embargo, aunque la información es pública y accesible, su **volumen, complejidad técnica y extensión documental** dificultan enormemente su localización, consulta y análisis. Los pliegos de contratación pueden superar fácilmente decenas o incluso cientos de páginas, contienen lenguaje jurídico-administrativo especializado y presentan estructuras heterogéneas. Para empresas licitadoras, profesionales del sector o incluso para ciudadanos interesados, **localizar información** concreta puede convertirse en una **tarea lenta y costosa**.

En este contexto surge la necesidad de **herramientas inteligentes que permitan consultar grandes volúmenes de documentación** pública de forma eficiente, precisa y contextualizada. Los modelos de lenguaje de gran tamaño (LLM) han demostrado un gran potencial para la generación de texto y la comprensión del lenguaje natural. Sin embargo, presentan **limitaciones** importantes, ya que su conocimiento es estático (fecha de corte), pueden generar respuestas incorrectas con aparente seguridad (alucinaciones) y no tienen acceso directo a información específica o actualizada, como documentos concretos de licitación.

Para solventar estas limitaciones, en este Trabajo Fin de Grado se ha desarrollado PythIA, un proyecto que propone el diseño e implementación de un sistema basado en la técnica ***Retrieval-Augmented Generation*** (**RAG**), cuyo objetivo es combinar la capacidad generativa de un LLM con un sistema de recuperación semántica de información sobre una colección documental formada por licitaciones públicas. El sistema permite indexar automáticamente los documentos, fragmentarlos en unidades manejables (*chunks*), representarlos mediante vectores (*embeddings*) y almacenarlos en una base de datos vectorial especializada (Qdrant). Ante una consulta del usuario, el sistema recupera los fragmentos más relevantes y los incorpora al *prompt* del modelo generativo, mejorando la precisión, actualidad y fiabilidad de la respuesta.

El proyecto no se limita al diseño conceptual del sistema RAG, sino que aborda su implementación completa en un entorno realista y desplegable. Para ello, se ha desarrollado una aplicación *web* con Flask que permite la interacción del usuario con el sistema de forma transparente, se integra una base de datos relacional para la gestión de usuarios y consultas, y se utiliza una base de datos vectorial (Qdrant) para la recuperación semántica. Además, se emplea Docker para garantizar la reproducibilidad del entorno y facilitar el despliegue de la aplicación en producción.

Este documento es la memoria principal del proyecto. En él se describe el contexto en el que surge el proyecto, y los objetivos perseguidos. Se incluye una explicación de los fundamentos teóricos necesarios para comprender el proyecto, y de las herramientas empleadas para su desarrollo indicando el valor que aportan al proyecto frente a otras alternativas del mercado. También, se exponen los aspectos más relevantes que tuvieron lugar durante el desarrollo explicando sus dificultades y cómo se solventaron. Para poner en valor real el proyecto es importante conocer el estado del arte en el campo de los modelos de lenguaje alimentados con RAG, explicando y comparando el proyecto con otros similares ya existentes. Finalmente, se detallan las conclusiones obtenidas tras finalizar el proyecto y se proponen vías de mejoras para futuros desarrollos.

Junto con la memoria se entregan los siguientes materiales adjuntos:

- **Documentación técnica** (detallada en los anexos): describe los aspectos relevantes del proyecto. El documento comienza con la planificación temporal seguida durante el desarrollo, detallando cada uno de los *sprint* realizados. También, se analiza la viabilidad del proyecto mostrando su rentabilidad económica y su legalidad. Un apartado especialmente relevante es el dedicado a la fase de análisis y planifi-

cación, donde se identifican y describen los requisitos funcionales y no funcionales del sistema, así como los distintos casos de uso que definen su comportamiento. En la documentación también se incluye el diseño completo de la aplicación, abarcando la arquitectura del sistema, el modelo de datos, los procedimientos implementados y el diseño de interfaces. Para facilitar el mantenimiento y la utilización de la aplicación se incluyen los manuales del programador y del usuario. Finalmente, se realiza un estudio de sostenibilidad que evalúa el impacto del proyecto y su viabilidad a largo plazo.

- **PythIA**: página *web* del proyecto, accesible a través de la dirección de dominio: <https://pythia.es/>
- **Repositorio GitHub¹ del proyecto**: contiene el código, la documentación y el desarrollo del proyecto. La planificación puede revisarse a través de los *milestones*, asociados a los distintos *sprints*.
- **Progreso del proyecto**: ha sido gestionado utilizando **ZenHub²** mediante la utilización de un tablero *Kanban*, los *story points* y los *Milestone Burndown*. Este proyecto está asociado al de GitHub. El progreso del proyecto también puede verse en un **GitHub Project³** asociado al repositorio de GitHub, en el cual puede observarse una tabla con las *issues* de cada *sprint* y un tablero *Kanban*. Además en el apartado *insights⁴* se han generado los *Burndown chart* de cada *sprint*.
- **Informe de calidad**: para analizar la calidad del código de la aplicación se ha utilizado **SonarCloud⁵**.

¹https://github.com/lbr1014/TFG_RAG.git

²[https://app.zenhub.com/workspaces/tfgrag-68d94a186434450034791a44/
board](https://app.zenhub.com/workspaces/tfgrag-68d94a186434450034791a44/board)

³<https://github.com/users/lbr1014/projects/1>

⁴<https://github.com/users/lbr1014/projects/1/insights>

⁵https://sonarcloud.io/project/overview?id=lbr1014_TFG_RAG

2. Objetivos del proyecto

El objetivo principal del proyecto es diseñar e implementar un sistema de *Retrieval-Augmented Generation* (RAG) que permita enriquecer las respuestas de un modelo de lenguaje mediante la recuperación y utilización de información contextual proveniente de una colección documental.

2.1. Objetivos específicos

Los objetivos identificados en el presente trabajo fin de grado son los siguientes:

- Recopilar la colección documental.
 - Automatizar la obtención de los documentos (licitaciones del estado) a través de *Web Scraping*.
- Preprocesar la colección documental.
 - Convertir la colección documental (recopilada inicialmente en PDF) a Markdown.
 - Normalizar y limpiar el texto eliminando ruido, caracteres no deseados y formatos inconsistentes.
 - Segmentar los documentos en fragmentos (*chunks*).
 - Generar *embeddings* para representar semánticamente los fragmentos.
 - Incorporar metadatos asociados a cada *chunk*.
- Implementar y gestionar un índice vectorial.
 - Almacenar los *embeddings* en una base de datos vectorial.

- Optimizar consultas de similitud para recuperar contexto relevante.
- Implementar mecanismos de búsqueda semántica mediante similitud coseno.
- Gestionar la persistencia y actualización de los *embeddings* conforme se incorporen nuevos documentos.
- Incluir mecanismos de evaluación automática del sistema RAG.
- Desarrollar la capa de interacción con el usuario
 - Transformar la consulta del usuario en su representación vectorial.
 - Recuperar los fragmentos más relevantes de la base de datos vectorial.
 - Utilizar los fragmentos recuperados para enriquecer el *prompt* del usuario y así construir el *prompt* aumentado que finalmente se pasa al *Large Language Model* (LLM).
 - Integrar distintos modelos LLM y evaluar su comportamiento dentro del sistema RAG.
 - Mostrar la trazabilidad de la respuesta al usuario.
 - Implementar un historial de consultas.
- Desarrollar interfaz que facilite al usuario la interacción con el modelo para que el proceso de aumentado del *prompt* le sea transparente.
 - Desarrollar una aplicación *web* con Flask para que el usuario pueda interactuar con el modelo.
 - Implementar soporte *responsive* para distintos tamaños de pantalla.
 - Incorporar modo claro y oscuro como apariencias visuales del sistema.
 - Implementar internacionalización y soporte multilenguaje.
 - Incorporar autenticación, gestión de usuarios, recuperación de contraseña y control de acceso basado en roles.
 - Implementar paneles de administración para la gestión de documentos y usuarios.
 - Incorporar gráficos interactivos y estadísticas mediante D3.js.
 - Implementar tutoriales interactivos para mejorar la experiencia de usuario.
- Desplegar y mantener la aplicación
 - Levantar la aplicación Flask con Docker para la reproducibilidad y el correcto funcionamiento en distintos entornos.
 - Desplegar la aplicación en un entorno preparado para producción utilizando Gunicorn y Nginx.

- Garantizar la seguridad de las comunicaciones mediante certificados SSL/TLS.
- Asignar un dominio DNS a la aplicación para facilitar el acceso.
- Implementar análisis estático y evaluación de calidad del código mediante SonarCloud y Ruff.

2.2. Objetivos personales

- Adquirir conocimientos sobre los sistemas RAG, comprendiendo sus fundamentos, componentes y aplicaciones en el ámbito de la inteligencia artificial.
- Profundizar en el estudio de los modelos de lenguaje de gran tamaño (LLM).
- Desarrollar habilidades prácticas en la implementación de sistemas basados en RAG y LLM.
- Aprender a aplicar los sistemas RAG y los LLM en la resolución de problemas reales.
- Aplicar los conocimientos adquiridos durante la carrera.

3. Conceptos teóricos

En este apartado se van a definir los conceptos más relevantes a tener en cuenta sobre el proyecto, por lo cual se considera importante definir qué es el *Web Scraping*, qué es un RAG y cuáles son sus aportaciones más significativas a los LLM que ya existen. Además, se considera importante contextualizar su origen, y para ello se va a comenzar explicando qué son los LLM y sus principales limitaciones.

3.1. *Web Scraping*

Web Scraping es el **proceso automático de extraer información** expuesta en páginas *web* y transformarla en datos estructurados. Se realiza mediante programas que descargan y analizan el código HTML o emulan la navegación de un usuario con un navegador controlado por código. Se apoya en técnicas de rastreo (*crawling*), *parseo* y normalización para preparar el dato para su análisis o integración en sistemas [4].

Existe una convención estándar, llamada *Robots Exclusion Protocol* (`robots.txt`), mediante la cual un servidor *web* indica qué URL se deben evitar rastrear. En este archivo se especifica qué partes del sistema están permitidas o prohibidas para cada tipo de *bot*. Aunque, el incumplimiento de este protocolo no siempre implica por sí mismo una infracción legal, respetarlo constituye una buena práctica ética y técnica en procesos de *web scraping* [17].

3.2. LLM

Los *Large Language Model* (LLM), que se traduce como los grandes modelos del lenguaje, son modelos de aprendizaje automático que han sido entrenados con grandes conjuntos de datos generados por humanos. Estos datos se usan para **encontrar patrones estadísticos y replicar nuestras habilidades lingüísticas**. Por lo cual, se puede decir que en esencia son modelos de predicción del siguiente *token* o lo que es lo mismo de la siguiente palabra [16].

Algunos ejemplos de LLM son [GPT⁶](https://chat.openai.com), [Claude⁷](https://claude.ai), [Gemini⁸](https://gemini.google.com/app?hl=es), [LLaMA⁹](https://ai.meta.com/llama/), [Mistral¹⁰](https://mistral.ai/) o [Qwen¹¹](https://qwen.ai/home). Herramientas como [Ollama¹²](https://ollama.com/) permiten ejecutar algunos de estos modelos (o sus versiones de parámetros reducidos) en local.

Las principales características de los LLM son las siguientes:

- **Naturaleza de predicción del próximo *token*:** como se ha mencionado anteriormente, los LLM seleccionan la palabra más probable de una distribución. La elección de esta palabra se basa en los patrones estadísticos que ha aprendido con los datos del entrenamiento.
- **Memoria paramétrica:** es el conocimiento interno del LLM. Consiste en la información con la que ha sido entrenado y se basa únicamente en sus parámetros. Por lo cual es una memoria limitada y estática.

Las principales limitaciones de los LLM son las siguientes:

- **Desactualizado:** los LLM solo pueden acceder a la información presente en sus datos de entrenamiento, que tienen una fecha límite específica conocida como «fecha de corte del conocimiento». Cualquier evento, descubrimiento o información posterior a esta fecha no estará disponible para el modelo, lo que puede generar respuestas desactualizadas. Además, el entrenamiento de un LLM es muy costoso y requiere mucho tiempo, por lo que estos modelos no se reentrenan con frecuencia, perpetuando esta limitación temporal.
- **Alucinaciones:** a veces los LLM dan respuestas incorrectas con gran confianza de manera que parece que la información que está propor-

⁶<https://chat.openai.com>

⁷<https://claude.ai>

⁸<https://gemini.google.com/app?hl=es>

⁹<https://ai.meta.com/llama/>

¹⁰<https://mistral.ai/>

¹¹<https://qwen.ai/home>

¹²<https://ollama.com/>

cionando es verdadera. Esto se debe a su naturaleza de predicción del próximo *token*.

- Limitación de conocimiento: los LLM se entrenan con datos públicos, lo que limita su conocimiento, ya que no tienen acceso a información que no sea pública, como, por ejemplo, documentos internos de una empresa, información de los clientes o de los productos.

La solución para solventar estas limitaciones es darle al LLM el contexto¹³ que le falta. Para proporcionar dicho contexto se puede expandir la memoria del LLM mediante generación aumentada, es decir, incorporando un RAG.

3.3. RAG

Retrieval Augmented Generation (RAG), o en español, generación aumentada por recuperación, es una técnica que consiste en **recuperar la información más relevante de una fuente externa**. Con dicha información se aumenta la entrada al LLM, lo que permite que genere una respuesta mucho más precisa, contextual y confiable (ver pasos en la imagen 3.1). Para ello, el RAG usa tres pasos: recuperar, aumentar y generar.

El RAG combina dos tipos de memoria:

- **La memoria paramétrica:** es la que típicamente tienen los LLM, que como se ha visto es limitada al conocimiento disponible en el momento del entrenamiento y estática.
- **La memoria no paramétrica:** es información externa al LLM que se le puede proporcionar. Es un conocimiento externo y dinámico que se puede extender tanto como se desee y que puede contener documentos propietarios.

Por lo cual conociendo esto, se puede decir que la generación aumentada por recuperación (RAG) es una metodología que busca **ampliar la memoria paramétrica de un LLM** incorporando una memoria no paramétrica explícita. A través de un recuperador, se obtiene información relevante de esta memoria externa, la cual se añade al *prompt* y luego se envía al LLM. De esta forma, el modelo puede producir respuestas más contextuales, confiables y precisas [16].

¹³El contexto del LLM es la información no paramétrica que se le proporciona en la consulta o *prompt* para que el modelo genere una respuesta más precisa, actual y fundamentada.




Figura 3.1: Diagrama del funcionamiento del RAG.

Los objetivos de un sistema RAG son:

- Hacer que los LLM respondan con información actualizada.
- Hacer que los LLM respondan con información precisa, contextual y confiable.
- Hacer que los LLM tengan acceso a información propietaria.

Las principales ventajas de un sistema RAG son:

- **Conocimiento del contexto profundo:** esto se debe a que la información adicional ayuda al LLM a generar respuestas contextualmente apropiadas, ya que, las respuestas se basan en datos específicos. Esto aumenta la confianza del usuario.
- **Trazabilidad:** como la información se extrae de fuentes conocidas el sistema las puede citar en su respuesta. Esto incrementa la fiabilidad percibida y permite a los usuarios comprobar la información obtenida.
- **Reduce las alucinaciones:** el sistema está anclado a los hechos, por lo que se reducen las respuestas inexactas o falsas.




Figura 3.2: Funcionamiento de un modelo LLM con RAG y otro sin él [1].

3.4. Conexión del LLM con el RAG

El primer paso es el de recopilar los documentos externos, convertirlos a vectores numéricos (*embeddings*) y almacenarlos. Cuando llega una consulta (*prompt*), en lugar de buscar coincidencias por palabras, se busca en ese espacio vectorial los fragmentos que son semánticamente más parecidos. Este proceso se conoce como búsqueda por significado. Los fragmentos recuperados se incorporan como contexto al LLM, de modo que el RAG combina la capacidad de razonamiento del modelo con una recuperación de información altamente precisa. En la imagen 3.2 se puede ver la diferencia de funcionamiento entre un modelo que emplea un sistema RAG para generar la respuesta y uno que no lo hace [1].

3.5. Diseño del RAG

Un sistema RAG se construye en dos *pipelines* complementarios, el de indexación (*offline*/asíncrono), y el de generación (*online*/ tiempo real). El primero crea y mantiene la memoria no paramétrica o base de conocimiento. El segundo gestiona la interacción con el usuario, realizando la recuperación, el aumento del *prompt* y la generación de la respuesta. Esta separación

es estructural en el diseño de RAG y permite optimizar la precisión y la latencia del sistema [16].

3.5.1. *Pipeline* de indexación (*offline*)

Su objetivo es **consolidar y preparar el conocimiento** para que el *pipeline* de generación pueda consultarlo eficientemente. Consta de cinco pasos:

1. Conectarse a las fuentes externas.
2. Extraer y *parsear* los documentos.
3. Dividir textos largos en fragmentos más pequeños denominados *chunks*.
4. Convertir los *chunks* a un formato adecuado.
5. Almacenar en una base de datos vectorial los *embeddings*.

Además de crearlo, este *pipeline* mantiene y actualiza el conocimiento base, por lo que debe ejecutarse de forma periódica [16].

Los componentes clave del *pipeline* de indexación son:

- **Carga de datos** (*data loading*): consiste en conectarse a las fuentes, por ejemplo, sistemas de ficheros, *data lakes*, CMS o API, para la extracción del texto en bruto y el *parsing* de este en formatos heterogéneos, como pueden ser PDF, DOCX, JSON o HTML. Luego se le añaden metadatos y finalmente se hace limpieza quitando código, etiquetas raras y enmascarando datos confidenciales.
- **División de texto** (*chunking*): segmentación en unidades manejables, los *chunks*, para mejorar la recuperación y el alineamiento con las capacidades de contexto LLM. Ayuda a respetar la ventana de contexto, mitiga el problema de pérdida en el medio¹⁴ y facilita la búsqueda eficiente. Para dividir el texto puede usar diversos métodos:
 - Tamaño fijo: divide el texto en longitudes uniformes, como un número de caracteres o *tokens*.
 - Especializados: divide el texto basándose en su estructura como encabezados o párrafos.
 - Semántico: divide el texto basándose en su similitud de significado usando *embeddings*, aunque este método aun es experimental.

La estrategia elegida dependerá del tipo de contenido, la longitud y complejidad de la consulta, el caso de uso y el modelo de *embeddings*.

¹⁴El problema de la pérdida en el medio ocurre cuando los LLM pierden precisión al procesar mucha información, priorizando el inicio y el final [33].

- **Conversión a vectores** (*embeddings*): transforma el texto a representaciones numéricas de n dimensiones. Para conocer si los *chunks* se parecen a la consulta, el sistema mide la distancia entre sus vectores, ya que la proximidad refleja similitud semántica. Hay diversas técnicas para medir la distancia entre los vectores, una de las más utilizadas es la similitud coseno que consiste en que si el ángulo entre dos vectores es muy pequeño su similitud es casi uno, pero hay otras como la distancia euclidiana. Hay modelos preentrenados abiertos y propietarios, la elección dependerá de su uso, rendimiento, recuperación y coste.
- **Almacenamiento**: los *embeddings* se almacenan en bases de datos vectoriales diseñadas para vectores de altas dimensiones. Estas bases de datos vectoriales permiten la búsqueda eficiente sobre *embeddings* y metadatos. Hay diversas opciones:
 - Índices vectoriales: son bibliotecas mínimas centradas en indexación y búsqueda de alta dimensión, no gestionan datos ni ofrecen consultas ricas o interfaces de bases de datos. Ejemplos: [FAISS¹⁵](#), [NMSLIB¹⁶](#), [ANNOY¹⁷](#), [ScaNN¹⁸](#). Son útiles cuando se desea máximo control y rendimiento sin sobrecarga de base de datos.
 - Bases de datos vectoriales especializadas: añaden a lo anterior gestión de datos, seguridad, escalado, extensibilidad y metadatos, manteniendo búsqueda/similitud vectorial eficiente. Ejemplos: [Pinecone¹⁹](#), [ChromaDB²⁰](#), [Milvus²¹](#), [Qdrant²²](#).
 - Plataformas de búsqueda: son motores de texto tradicional ([Solr²³](#), [Elasticsearch²⁴](#), [OpenSearch²⁵](#), [Lucene²⁶](#)) que han incorporado similitud vectorial a sus capacidades.
 - Motores SQL/NoSQL con capacidad vectorial: son bases de datos ya existentes que añaden tipos y operadores vectoriales. Ejemplos:

¹⁵<https://faiss.ai/index.html>

¹⁶<https://nmslib.github.io/nmslib/>

¹⁷<https://github.com/spotify/annoy>

¹⁸<https://milvus.io/docs/es/scann.md>

¹⁹<https://www.pinecone.io/>

²⁰<https://www.trychroma.com/>

²¹<https://milvus.io/es>

²²<https://qdrant.tech/>

²³<https://solr.apache.org/>

²⁴<https://www.elastic.co/es/enterprise-search/vector-search>

²⁵<https://opensearch.org/platform/vector-search/>

²⁶<https://lucene.apache.org/core/>

[Azure SQL](#)²⁷, [PostgreSQL/pgvector](#)²⁸ o en NoSQL [MongoDB](#)²⁹. Son útiles para consolidar datos, aunque suelen estar menos especializados que una base de datos vectorial dedicada.

- Bases de datos gráficas con funciones vectoriales: grafos como [Neo4j](#)³⁰ que añaden búsqueda vectorial. Permiten combinar relaciones explícitas (grafos) con similitud semántica (vectores). Ejemplos: *path finding* sujeto a similitud.

Cuando la recuperación se externaliza, es decir, cuando la búsqueda y obtención de información no la realiza el sistema sobre su propia base vectorial, sino que se delega en un tercero (como por ejemplo una API) o en el documento que aporta el usuario, no es imprescindible construir un *pipeline* de indexación ni mantener una base vectorial. En cambio, en un RAG clásico, donde el sistema recupera conocimiento de su repositorio interno, sí se recomienda diseñar el *pipeline* de indexación y mantener una base vectorial propia [16].

3.5.2. *Pipeline* de generación (*online*)

Gestiona la consulta del usuario de extremo a extremo. Este *pipeline* recibe la pregunta del usuario, recupera el contexto relevante de la base de datos vectorial, los *chunks*, aumenta el *prompt* con ese contexto y genera la respuesta con el LLM. Se compone de tres fases: *retrieval*, *augmentation* y *generation* [16].

Los componentes clave del *pipeline* de generación son:

- ***Retriever***: es el motor de búsqueda sobre la base de datos vectorial, es decir, la base de conocimiento. Devuelve los documentos más relevantes. Es crítico para la precisión del sistema y contribuye a la latencia, su calidad condiciona el rendimiento del sistema RAG. El método más frecuente son los *embeddings* gracias a su capacidad semántica.
- Gestión del *prompt* – ***Augmentation***: combina la consulta y el contexto recuperado. Además, aplica estrategias de ingeniería de *prompt* para maximizar la calidad de la respuesta. Las estrategias recomendadas son:

²⁷<https://azure.microsoft.com/es-es/products/azure-sql/database>

²⁸<https://www.postgresql.org/about/news/pgvector-070-released-2852/>

²⁹<https://www.mongodb.com/>

³⁰<https://neo4j.com/>

- *Contextual prompting*: consiste en instruir al modelo para que solo responda con el contexto proporcionado.
 - *Controlled generation prompting*: consiste en indicarle al modelo que no conteste si el contexto no permite responder a la pregunta.
 - *Few-shot prompting*: consiste en incluir ejemplos para forzar el formato de la respuesta.
 - *Chain-of-thought*: consiste en pedir pasos intermedios cuando los razonamientos son complejos.
- Configuración LLM – **Generation**: es la selección del modelo que va a generar la respuesta final. Pueden ser modelos:
 - Originales o *fine-tuned*: los originales facilitan un arranque rápido, mientras que los *fine-tuned* mejoran la adaptación de dominio, la integración del contexto y formato de salida.
 - Abiertos o propietarios: los abiertos ofrecen control y despliegue flexible, mientras que los propietarios simplifican el uso y el mantenimiento.
 - Tamaño del modelo: los grandes tienen un razonamiento mejor y un contexto más amplio. Los pequeños tienen un coste y latencia menor.

3.5.3. Capas de soporte

Además de los dos *pipelines*, un sistema en producción requiere orquestación, evaluación y monitorización continua, caché semántico para reducir coste y latencia, controles de seguridad para cumplimiento normativo y seguridad frente a inyecciones en el *prompt*, envenenamiento de dato³¹ o fugas de información. Todo ello se sostiene sobre una **infraestructura de servicio y un *RAGOps stack*** formado por capas críticas, esenciales y de mejora que aseguran operación, calidad y seguridad extremo a extremo [16].

1. **Capas críticas**: son las capas imprescindibles del *RAGOps stack*.
 - Capa de datos: es la encargada de crear la base de conocimiento, para ello recolecta datos desde sistemas origen, los transforma y los almacena.
 - Capa de modelos: se incluyen los modelos de *embeddings*, de los LLM y de las tareas. Incluye el entrenamiento y la optimización de inferencia.

³¹El envenenamiento de datos es un ciberataque que corrompe los conjuntos de datos de entrenamiento utilizados para el proceso de entrenamiento del modelo de Inteligencia Artificial [18].

- Despliegue de modelos: pueden ser servicios gestionados, auto-hospedados o locales.
 - Orquestación de la aplicación: se encarga de coordinar la consulta, la recuperación de datos y la generación. Incluye soporte multiagente y automatización de flujos de trabajo.
2. **Capas esenciales:** son las capas que necesita el sistema, se encargan del rendimiento, la fiabilidad y de la seguridad.
- Capa de *prompt*: diseño, versión y evaluación de *prompts* para guiar al LLM y reducir las alucinaciones.
 - Capa de evaluación: se encarga de medir, de forma periódica, la relevancia del contexto, fidelidad y relevancia de la respuesta.
 - Capa de monitorización: observa el proceso del RAG para encontrar fallos. Para ello monitoriza la latencia y el error.
 - Seguridad y privacidad del LLM: es la encargada de emplear métodos para evitar el *prompt injection*. Algunos de los métodos que se emplean son validar las entradas, realizar encriptados y emplear control de accesos.
 - Capa de caché: emplea caché para reducir los costes y la latencia en consultas frecuentes.
3. **Capas de mejora:** son capas opcionales que pueden aportar beneficios dependiendo del caso de uso. Se centran en la eficiencia, usabilidad y escalabilidad del sistema.

3.6. Evaluación de la calidad del RAG

Se suele hacer mediante la **tríada de evaluación** propuesta por TruEra [21] (ver imagen 3.3). Estructura la calidad en tres comprobaciones entre consulta (*prompt*), contexto recuperado y respuesta. Complementariamente, se emplean métricas como relevancia, precisión y *recall*, y conjuntos *ground truth* para validación objetiva y monitorización continua en producción [16].

Las tres dimensiones de la tríada son:

- **Relevancia del contexto:** la información que se haya recuperado tiene que ver con la pregunta.
- **Groundedness** o fidelidad: la respuesta que da el LLM se basa de verdad en el contexto que le hemos dado, sin alucinaciones ni omisiones clave.



Figura 3.3: Triada de evaluación TruEra.

- **Relevancia de la respuesta:** la respuesta es útil y adecuada respecto a la intención y el contexto de la consulta original.

Aparte de las dimensiones de la triada, otros aspectos relevantes que el sistema debe incorporar son:

- Robustez al ruido: el sistema debe distinguir aquellos documentos relacionados pero que sean poco útiles.
- Rechazo en negativo: el sistema no debe responder cuando no hay evidencias relevantes.
- Integración de información: el sistema debe ser capaz de sintetizar múltiples documentos que posean información relevante.
- Robustez contrafactual: el sistema tiene que detectar y evitar la información inexacta en el propio *knowledge base*.

En este proyecto se han considerado especialmente dos herramientas de evaluación:

- **Retrieval-Augmented Generation Assessment** (RAGAS³²) [5]: es un *framework* que genera datos sintéticos y calcula métricas de la triada. Es útil para ciclos rápidos [28].

³²<https://github.com/vibrantlabsai/ragas>

- ***Automated RAG Evaluation System*** (**ARES³³**) [30]: es un *framework* con un funcionamiento similar al RAGAS, pero con mayor complejidad y cantidad de datos generados. Es más robusto.

³³<https://github.com/stanford-futuredata/ARES>

4. Técnicas y herramientas


En este apartado se va a realizar una breve explicación de la metodología empleada, así como de las herramientas utilizadas para el desarrollo del proyecto. En dicha explicación se va a incluir una comparación con otras herramientas similares en la cual se muestre el motivo de la selección de dicha herramienta.

4.1. Metodologías

Para llevar a cabo el proyecto se han seguido diversas metodologías de **desarrollo ágil**. Estas metodologías definen la forma en la que se planifica, organiza y gestiona el desarrollo de un proyecto, permitiendo estructurar las tareas, coordinar el progreso y mejorar la calidad del resultado.

4.1.1. *Scrum*

Scrum es un marco de trabajo ágil orientado a la **gestión y desarrollo de proyectos** de manera iterativa e incremental. Se organiza en ciclos cortos denominados *sprints*, al final de los cuales se entrega un incremento funcional del producto (ver imagen 4.1 para ver el proceso *Scrum* completo). Estos *sprints* favorecen la mejora continua y la adaptación al cambio, además, aseguran una entrega temprana de valor. A diferencia de metodologías tradicionales, *Scrum* aporta mayor flexibilidad y retroalimentación constante [32].

Figura 4.1: Metodología *Scrum*.

4.1.2. *Kanban*

Para la **gestión del flujo de trabajo y organización de tareas** se ha adoptado la metodología *Kanban* [22]. La cual consiste en un enfoque ágil orientado a la visualización del trabajo, la optimización del flujo y la mejora continua. Se basa en la idea de que el trabajo debe gestionarse como un flujo continuo en lugar de dividirse en iteraciones cerradas. Se centra en representar el estado de las tareas de forma visual, lo que facilita la planificación, el seguimiento y la detección de cuellos de botella. Este enfoque es útil en proyectos de desarrollo *software* en los que los requisitos puedan evolucionar, haciendo necesario tener una planificación flexible.

4.2. Repositorio

Para **alojar** el repositorio se han valorado distintas alternativas como *Bitbucket*³⁴, *GitHub*³⁵ o *GitLab*³⁶. Además se consideró *Trello*³⁷ como herramienta de gestión de tareas. Finalmente se ha elegido *GitHub* que es

³⁴<https://bitbucket.org/>

³⁵<https://github.com/>

³⁶<https://gitlab.com/>

³⁷<https://trello.com/>

una plataforma basada en la nube que permite alojar repositorios de código. GitHub ofrece funciones muy útiles como ramas (*branches*), *pull requests*, seguimiento de cambios (*commits*), historial del proyecto, gestión de incidencias (*issues*). Además, permite la **colaboración entre usuarios**, lo que es muy útil para la revisión del proyecto.

Otra ventaja es que GitHub es compatible con **herramientas de integración y despliegue continuo** (CI/CD) (Github Actions), lo que facilita la automatización de pruebas y la entrega de *software*. Asimismo, permite incluir documentación directamente en el repositorio, ya sea mediante archivos **README** o a través de *wikis*, lo que mejora la claridad y la reproducibilidad del trabajo. Al tratarse de la plataforma más utilizada a nivel mundial, cuenta con abundante documentación, lo que la convierte en una alternativa sólida y con amplio soporte [11].

4.3. Gestión de tareas

Para la gestión de las tareas del proyecto se han valorado diversas herramientas, como **ZenHub**³⁸, **GitHub Projects**³⁹ o **Asana**⁴⁰. Principalmente se ha optado por usar ZenHub que es una herramienta de gestión de proyectos fácilmente integrable con GitHub. Debido a que tiene mayor funcionalidad que GitHub Projects. Ambos permiten hacer tableros *Kanban* para **organizar las tareas** (*to-do, in progress, doing*). Pero, ZenHub, además, permite asignar *story points* a las tareas y generar los **gráficos *burndown*** de los *sprints* de manera sencilla. Sin embargo, también se ha utilizado GitHub Projects, en el cual se ha definido una tabla que organiza las tareas por *sprints* y se han guardado los *burndown* de cada *sprint*, así como, otras gráficas de interés.

³⁸<https://www.zenhub.com/>

³⁹<https://github.com/>

⁴⁰<https://asana.com/es>

4.4. L^AT_EX

Para la **edición de los documentos** en L^AT_EX se ha considerado usar T_EXMaker⁴¹, T_EXStudio⁴², Visual Studio Code⁴³ y Overleaf⁴⁴. Finalmente se ha optado por usar T_EXMaker, ya que es un editor multiplataforma, gratuito y de código abierto. Tiene un visor PDF integrado, así como herramientas para gestionar la bibliografía mediante BibT_EX. Además, tiene una interfaz simple que facilita el aprendizaje, incorpora funciones como el autocompletado, el plegado de código y la detección de errores de compilación, sin necesidad de instalar complementos adicionales.

Como distribución L^AT_EX para **procesar los documentos .tex** se ha valorado el uso de MikT_EX⁴⁵ y T_EXLive⁴⁶, al final se ha elegido usar MikT_EX ya que permite realizar una instalación mínima e ir añadiendo automáticamente los paquetes necesarios durante la compilación. Además, presenta un buen soporte para Windows, lo que se adapta bien a mi entorno de trabajo [35].

4.5. Entorno de desarrollo

Para el desarrollo del proyecto se ha utilizado Visual Studio Code⁴⁷ [29] como entorno de desarrollo integrado (IDE) [31]. Un IDE es una aplicación que integra en un único entorno herramientas esenciales para el desarrollo de software, como **editor de código, compilador, depurador y utilidades de automatización**.

Visual Studio Code es un editor de código fuente multiplataforma, gratuito y muy utilizado en el ámbito profesional. Se ha seleccionado frente a otras alternativas como PyCharm⁴⁸ o entornos más pesados debido a su flexibilidad, su facilidad para incorporar extensiones y su buena integración con herramientas modernas de desarrollo como son Git, Docker y Poetry. Per-

⁴¹<http://www.xmlmath.net/texmaker/>

⁴²<https://www.texstudio.org/>

⁴³<https://code.visualstudio.com/>

⁴⁴<https://es.overleaf.com/>

⁴⁵<https://miktex.org/>

⁴⁶<https://www.tug.org/texlive/>

⁴⁷<https://code.visualstudio.com/>

⁴⁸<https://www.jetbrains.com/es-es/pycharm/>

mitiendo mantener un entorno de desarrollo coherente, modular y fácilmente reproducible.

4.6. Patrones de diseño

Durante el desarrollo del sistema se han aplicado distintos patrones de diseño *software* con el objetivo de **mejorar la modularidad, reutilización, mantenibilidad y eficiencia** de la aplicación.

4.6.1. Patrón *Singleton*

El patrón *Singleton* es un patrón de diseño creacional cuyo objetivo es garantizar que **una clase tenga una única instancia** durante toda la ejecución de la aplicación, proporcionando además un punto global de acceso a dicha instancia. Este patrón resulta especialmente útil cuando se trabaja con recursos costosos de inicializar o que deben compartirse entre múltiples componentes del sistema.

En el proyecto se ha elegido utilizar un patrón de diseño *Singleton* para gestionar los componentes del RAG cuya creación tiene un elevado coste computacional o de memoria, como el modelo de generación de *embeddings* mediante **SentenceTransformers**, la conexión con la base de datos vectorial Qdrant y la gestión del cliente de comunicación con Ollama.

Como alternativa se valoró utilizar una inicialización desacoplada basada en inyección de dependencias (*Dependency Injection*). Este enfoque aporta una mayor flexibilidad y facilita las pruebas unitarias, ya que permite sustituir fácilmente las dependencias por objetos simulados (*mocks*).

Otra alternativa considerada fue utilizar variables globales simples para almacenar los recursos compartidos. Aunque esta solución es más sencilla, presenta inconvenientes importantes relacionados con el acoplamiento, la mantenibilidad y el control del ciclo de vida de los objetos.

Sin embargo, para este proyecto se optó por una aproximación basada en *Singleton* debido a que su utilización evita realizar inicializaciones repetidas de modelos de inteligencia artificial, conexiones de red o clientes pesados cada vez que se procesa una consulta. Esto reduce considerablemente el consumo de memoria, disminuye la latencia y mejora el rendimiento general del sistema. Además, permite centralizar la configuración de dichos recursos, facilitando el mantenimiento y la coherencia interna de la aplicación.

4.7. *Web Scraping*

Para el *Web Scraping*, es decir, para la **obtención de documentos de manera automática** se ha valorado usar **Selenium**⁴⁹ y **Playwright**⁵⁰. Selenium [27] controla navegadores reales y es un estándar veterano, pero Playwright [34] es más completo. Ya que ofrece automatización multi-navegador con contextos aislados, funcionamiento *headless*, espera automática de elementos y API consistentes, lo que lo vuelve más robusto y rápido para páginas con JavaScript pesado y flujos de *login*. En la Tabla 4.1 se muestran las ventajas y desventajas de cada uno.

Tras probar ambos, en una fase inicial del *Web Scraping*, se vio que Selenium sigue siendo una apuesta segura, para *scraping* moderno con múltiples sesiones y depuración rápida. Sin embargo, Playwright requiere **menos código y es más robusto**, en su modo asíncrono gestiona de manera autónoma las esperas y los reintentos.

4.8. Gestión de dependencias y entornos Python

El proyecto requiere **entornos aislados y reproducibles** que faciliten el trabajo local, la integración continua y la generación de entregables. Se ha valorado utilizar **Poetry**⁵¹ y **UV**⁵². Poetry es una herramienta madura de gestión de dependencias y empaquetado que centraliza la configuración en `pyproject.toml`. Crea y gestiona entornos virtuales de forma automática, mantiene un archivo de bloqueo (`poetry.lock`) para asegurar instalaciones deterministas, permite definir grupos de dependencias, así como, generar de manera automática el `requirements.txt`. Por su parte UV es un gestor rápido que, al igual que Poetry, tiene soporte para `pyproject.toml`. Posee un buen rendimiento y una elevada velocidad gracias al uso de cachés eficientes. Finalmente, se ha optado por usar Poetry por su cobertura integral del ciclo de vida dentro de un flujo coherente y estable.

⁴⁹<https://selenium-python.readthedocs.io/>

⁵⁰<https://playwright.dev/>

⁵¹<http://python-poetry.org/docs/>

⁵²<https://docs.astral.sh/uv/>

Herramienta	Ventajas	Desventajas
Selenium	Utiliza el estándar W3C WebDriver [25], lo que aporta interoperabilidad y soporte a largo plazo.	Es propenso a fallos (<i>flakiness</i>) si no se dominan las esperas.
	Multilenguaje y ecosistema maduro. Permite una integración fácil. Es robusto para escalado distribuido.	La interceptación de red es menos homogénea entre navegadores.
Playwright	Es muy estable y rápido en <i>webs</i> con JavaScript pesado.	No utiliza el estándar WebDriver .
	Presenta multitud de herramientas integradas como <i>Trace Viewer</i> , capturas de pantalla y videos. Contiene selectores potentes y permite manejar los <i>iframes</i> de forma sencilla. Tiene un control de contexto aislado muy cómodo. Su modelo asíncrono permite realizar acciones concurrentes sin bloquear el hilo empleando la API <i>async/await</i> .	

Tabla 4.1: Comparativa de Selenium y Playwright.

4.9. Bases de datos

Para el desarrollo del sistema RAG es necesario contar con dos tipos de bases de datos, una base de datos vectorial (ver sección 4.9.1) y una relacional (ver sección 4.9.2). La **base de datos vectorial** permite **almacenar, indexar y buscar semánticamente** en los documentos para dar respuestas precisas y rápidas. La **base de datos relacional** que permite **gestionar la información** de la aplicación (los datos de los usuarios, los documentos, las consultas, los *chunks* y los *embeddings*).

4.9.1. Base de datos vectorial

Una parte fundamental del desarrollo del RAG es la implementación de la base de datos vectorial. Se ha valorado emplear diversas bases de datos, pero las dos que más se han estudiado son **Qdrant**⁵³ y **PyVector**⁵⁴. Qdrant [27] es una base de datos vectorial especializada, diseñada desde cero para **búsquedas de similitud de alta concurrencia y baja latencia**. Presenta equilibrio entre el rendimiento, la latencia y el tiempo de indexado [15]. Por su parte, PyVector [34] es una extensión de **PostgreSQL**⁵⁵ que permite almacenar *embeddings* en columnas vectoriales y realizar búsquedas de similitud sobre una base de datos relacional ya existente. Es útil cuando la aplicación ya se apoya en este gestor, ya que simplifica la infraestructura [37]. En la tabla 4.2 se muestran las principales ventajas y desventajas de cada opción.

Para realizar el proyecto se ha optado por utilizar Qdrant. Aunque PyVector presenta características interesantes cuando se desea mantener toda la información en una única base de datos relacional, Qdrant presenta un diseño especializado. Así como un mejor equilibrio entre rendimiento y latencia. Además, Qdrant se utiliza en proyectos reales lo que lo convierte en una muy buena opción para implementar el sistema RAG.

⁵³<https://qdrant.tech/>

⁵⁴<https://www.datacamp.com/es/tutorial/pgvector-tutorial>

⁵⁵<https://www.postgresql.org/>

Herramienta	Ventajas	Desventajas
Qdrant	Diseñada específicamente como base de datos vectorial, con índices optimizados para búsquedas de similitud y buen compromiso entre RPS, latencia y tiempo de indexado [15]. Soporta filtrado avanzado por metadatos y búsquedas híbridas (vectoriales más filtros), lo que facilita consultas complejas en RAG. Ofrece despliegue sencillo mediante contenedores y opciones gestionadas, con API HTTP y RPC bien documentadas. Integración directa con bibliotecas y orquestadores de RAG, lo que reduce el código necesario para conectarla con el resto del sistema.	Introduce un nuevo servicio en la arquitectura: es necesario administrar una base de datos adicional a la relacional. Requiere aprender herramientas y mecanismos de operación específicos (copias de seguridad, monitorización, actualización de índices, etc.). Para casos de uso pequeños puede resultar más compleja que reutilizar la base de datos transaccional existente.
PyVector	Permite reutilizar una instancia de PostgreSQL ya desplegada, unificando datos transaccionales y <i>embeddings</i> en el mismo sistema. Aprovecha todo el ecosistema SQL: transacciones, <i>joins</i>, vistas, roles de usuario y mecanismos estándar de replicación y copia de seguridad. Simplifica la operación en entornos reducidos o con restricciones de infraestructura, al requerir un único motor de base de datos.	El rendimiento en búsquedas vectoriales a gran escala (millones de vectores y alta concurrencia) suele ser inferior al de motores especializados. Dispone de menos funcionalidades específicas de bases de datos vectoriales (gestión de colecciones, métricas especializadas o afinado fino de índices). La configuración óptima de índices y parámetros depende de la versión de PostgreSQL y de la extensión, y puede requerir un ajuste cuidadoso.

Tabla 4.2: Comparativa de Qdrant y PyVector.

4.9.2. Base de datos relacional

Para la implementación de la base de datos relacional se ha valorado usar **PostgreSQL**⁵⁶ y **SQLite**⁵⁷. PostgreSQL es un sistema de gestión de bases de datos relacionales de código abierto, orientado a objetos con gran robustez transaccional. Por su parte SQLite es un sistema ligero y embebido que no funciona como servidor independiente, sino que almacena la base de datos en un fichero local. En la tabla 4.3 se muestra una comparativa entre ambos sistemas de gestión de bases de datos relacionales.

Inicialmente se comenzó integrando SQLite, ya que, se considero suficiente para un prototipo local del sistema RAG. Pero, finalmente se cambió a PostgreSQL porque en el proyecto se busca conseguir una **arquitectura realista y desplegable** que permita la **conurrencia real de usuarios** en el sistema.

4.10. Desarrollo *web*

El desarrollo de la interfaz *web* para el proyecto se ha realizado con **Flask**⁵⁸ [8]. Flask es un *framework* WSGI (*Web Server Gateway Interface*⁵⁹ [36]) que proporciona los componentes esenciales para **construir aplicaciones *web* usando Python**. Fue diseñado para la creación de aplicaciones *web* ligeras y modulares.

Se ha optado por utilizar Flask para el desarrollo *web* en lugar de otros *frameworks*, como **Django**⁶⁰ o **FastAPI**⁶¹ porque incorpora una serie de componentes que permiten **gestionar las aplicaciones *web* de forma sencilla**:

- Enrutamiento: permite asociar rutas URL a funciones Python utilizando decoradores. Lo cual permite organizar el código de manera modular. En el caso del proyecto simplifica la conexión entre la interfaz *web* y el *pipeline* de generación RAG.

⁵⁶<https://www.postgresql.org/>

⁵⁷<https://sqlite.org/>

⁵⁸<https://flask.palletsprojects.com/en/stable/>

⁵⁹Estándar Python para la comunicación entre los servidores *web* y el *framework web*

⁶⁰<https://www.djangoproject.com/>

⁶¹<https://fastapi.tiangolo.com/>

- Gestión de peticiones y respuestas: proporciona objetos que permiten acceder de manera sencilla a los datos enviados por el usuario, utilizando formularios, JSON o simplemente parámetros.
- Motor de plantillas Jinja2: permite generar HTML a partir de datos procesados en el servidor. Lo cual facilita la visualización estructurada de las distintas partes del sistema.
- Soporte WSGI: como se ha comentado anteriormente, Flask se basa en este estándar para la comunicación entre aplicaciones *web* y servidores Python. La utilización de este estándar garantiza la compatibilidad con múltiples servidores de producción y facilita su despliegue mediante Docker.
- Extensiones: a pesar de que es minimalista, permite incorporar extensiones para bases de datos, autenticación o validación de formularios.

Además de Flask, durante el desarrollo de la interfaz *web* se han utilizado diversas bibliotecas y servicios complementarios para ampliar las funcionalidades de la aplicación. Por ejemplo, se ha utilizado **Bootstrap**⁶² para facilitar el diseño *responsive* y la construcción de una interfaz moderna y consistente mediante componentes reutilizables. También, se ha utilizado **Driver.js**⁶³ para implementar tutoriales interactivos que guían al usuario a través de las distintas funcionalidades del sistema y **D3.js**⁶⁴ para desarrollar gráficos y estadísticas dinámicas para visualizar información relevante sobre el uso de la aplicación.

Se ha integrado también la API de **Emailable**⁶⁵ con el objetivo de validar las direcciones de correo electrónico durante el registro de usuarios, y la edición de perfil. Esto permite garantizar que las cuentas registradas dispongan de una dirección de correo válida para el envío de notificaciones y la recuperación de contraseñas.

4.11. Evaluación de la calidad del código

Para evaluar y mantener la calidad del código desarrollado también se han incorporado **herramientas de análisis estático**. Concretamente se ha utilizado **SonarCloud**⁶⁶ y **Ruff**⁶⁷.

⁶²<https://getbootstrap.com/>

⁶³<https://driverjs.com/>

⁶⁴<https://d3js.org/>

⁶⁵<https://emailable.com/es/>

⁶⁶<https://www.sonarsource.com/products/sonarqube/cloud/>

⁶⁷<https://docs.astral.sh/ruff/>

SonarCloud es una plataforma de análisis continuo integrada con GitHub que permite detectar automáticamente *bugs*, vulnerabilidades de seguridad, duplicidad de código, problemas de mantenibilidad, complejidad ciclomática y el *coverage* de las pruebas. Su utilización facilita identificar códigos que requieren refactorización y mejorar progresivamente la arquitectura de la aplicación.

Por su parte, Ruff es una herramienta ligera y muy rápida orientada al análisis estático y validación del estilo de código Python. Sirve para comprobar automáticamente errores de estilo, *imports* no utilizados, variables redundantes y malas prácticas de programación. Ayuda a mantener una estructura homogénea y coherente en todo el proyecto.

4.12. Despliegue de la aplicación

Para desplegar la *web* se han utilizado las herramientas Docker (ver sección 4.12.1), Nginx (ver sección 4.12.2), Gunicorn (ver sección 4.12.3), DNS (ver sección 4.12.4) y el certificado SSL/TLS (ver sección 4.12.5). El uso de estas herramientas permite separar la responsabilidad y **asegurar la portabilidad, el rendimiento y la seguridad**.

Empaquetar la aplicación en un contenedor Docker garantiza su reproducibilidad, evitando conflictos entre librerías y versiones del sistema. Gunicorn sirve para no exponer directamente la aplicación Flask en Internet. Nginx se coloca por delante actuando como un servidor *web* y como *proxy* inverso. Va recibir las conexiones externas y las va a reenviar al servicio de Gunicorn. También, se va a encargar de gestionar el cifrado y descifrado de HTTPS. El certificado SSL/TLS sirve para habilitar dicho protocolo HTTPS, en este caso demostrando control del dominio (DNS-01). En la imagen 4.2 se puede ver cómo se relacionan las distintas herramientas.


4.12.1. Docker

Docker⁶⁸ [10] es una plataforma de *software* de código abierto basada en contenedores. Permite **empaquetar una aplicación con sus dependencias para distribuirla y ejecutarla**, asegurando que funcione igual

⁶⁸<https://www.docker.com/>

Características	PostgreSQL	SQLite
Modelo	Cliente-servidor	Embebido
Concurrencia	Alta	Limitada (solo hay un escritor)
Escalabilidad	Alta	Baja
Uso recomendado	Sistemas multiusuario	Aplicaciones locales o prototipos
Integración con Docker	Muy buena	No necesaria (es un archivo local)

Tabla 4.3: Comparativa de PostgreSQL y SQLite.

Figura 4.2: Relación entre las herramientas utilizadas para desplegar la aplicación *web*.

en cualquier entorno. Esto se debe a que aísla la aplicación y sus dependencias del sistema operativo dentro de unidades ligeras y portables (los contenedores). Los conceptos clave del Docker son:

- Imagen: es una plantilla que contiene el sistema base y las dependencias necesarias.
- Contenedor: es una instancia en ejecución de la imagen.
- Dockerfile: es un archivo en el que se especifican los pasos que se deben seguir para construir la imagen.
- Docker Compose: es una herramienta que se define en un archivo de extensión `.yaml`⁶⁹ en el cual se definen todos los servicios que debe contener la imagen. Estos servicios se dividen en volúmenes.

Se decidió implementar un contenedor Docker ya que mejora la **reproductividad, la portabilidad y evita conflictos entre las dependencias** en el sistema aportando mayor aislamiento. Además, permite integrar fácilmente diversas herramientas dentro de los volúmenes lo que mejora la escalabilidad. En sistemas que combinan múltiples componentes, como ocurre en este proyecto con LLM, base de datos vectorial y relacional e interfaz *web*, el uso de contenedores simplifica considerablemente la gestión de la infraestructura.

4.12.2. Nginx

Nginx⁷⁰ es un servidor *web* que puede actuar como *proxy* inverso [3]. Un *proxy* inverso es un servidor que, a diferencia de un *proxy* normal, se sitúa delante de los servidores *web* para interpretar las solicitudes de los clientes. Se encarga de **reenviar las solicitudes** de los clientes a los servicios *web*. En el caso del proyecto Nginx se ha utilizado como intermediario entre el cliente y la aplicación Flask para recibir las peticiones externas (HTTP/HTTPS). También, se encarga de gestionar el certificado SSL y de redirigir el tráfico hacia Gunicorn.

La ventaja de utilizar Nginx es que está optimizado para manejar múltiples conexiones concurrentes de forma eficiente. Además, desacopla el servidor *web* del servidor de aplicaciones, aumentando la seguridad y el rendimiento del sistema.

⁶⁹Formato YAMAL (acrónimo recursivo de *YAMAL Ain't Markup Language*).

⁷⁰<https://nginx.org/>

4.12.3. Gunicorn

Gunicorn⁷¹ es un servidor WSGI para aplicaciones Python fácil de instalar (no requiere dependencias adicionales), pero que no es compatible con Windows. Su principal función es ejecutar la aplicación Flask en un **entorno preparado para producción**. Ya que, por defecto, el *framework* Flask incluye un servidor de desarrollo que no es adecuado para entornos reales. Por lo cual Gunicorn se encarga de sustituir este servidor por uno optimizado para producción que si que va a permitir gestionar múltiples procesos de manera simultánea y que va a mejorar la estabilidad.

4.12.4. DNS

El DNS (*Domain Name System*) permite **asociar un nombre de dominio a la dirección IP** del servidor donde se encuentra desplegada la aplicación. Asignarle un dominio a una aplicación sirve para facilitar el acceso y otorgarle mayor profesionalidad. Además, de mejorar la accesibilidad, permite la migración del servidor sin necesidad de cambiar la dirección que utiliza el usuario.

En este proyecto el dominio público se ha adquirido a través del proveedor **Hostalia**⁷². Una vez registrado el dominio, fue necesario configurar sus registros DNS para asociarlo con la dirección IP del servidor donde se encuentra desplegada la aplicación. Para vincular el dominio al servidor se configuró un registro tipo A dentro del panel de gestión DNS de Hostalia. Este registro permite que las peticiones dirigidas al dominio se redirijan a la dirección IP correspondiente del servidor.

Sin embargo, la aplicación se ejecuta en una IP privada de la Universidad de Burgos. Las direcciones IP privadas no son accesibles directamente desde Internet [26], ya que están destinadas a redes internas. Para conseguir que la aplicación sea accesible desde Internet hay que configurar el *router* de tal forma que el dominio apunte a la IP pública del dicho *router*. Mediante técnicas NAT (*Network Address Translation* [6]) se redirige el tráfico hacia la IP privada del servidor.

⁷¹<https://gunicorn.org/>

⁷²<https://www.hostalia.com/>

4.12.5. Certificado SSL/TLS

Para garantizar la seguridad de las comunicaciones se ha configurado un certificado SSL/TLS que **permite el uso del protocolo HTTPS** (*HyperText Transfer Protocol Secure*) [2]. HTTPS es la versión segura de HTTP y se basa en el protocolo TLS (*Transport Layer Security*), cuyo objetivo es cifrar la comunicación entre el cliente y el servidor. Este cifrado impide que terceros puedan interceptar, modificar o suplantar la información transmitida, protegiendo así la confidencialidad e integridad de los datos.

En este proyecto, el certificado digital se ha emitido utilizando **Certbot**⁷³ que es una herramienta oficial promovida por la **Electronic Frontier Foundation**⁷⁴ (EFF). **Certbot** automatiza la obtención e instalación de certificados gratuitos proporcionados por **Let's Encrypt**⁷⁵. La cual es una autoridad certificadora reconocida internacionalmente. El proceso de emisión del certificado se basa en un mecanismo de validación del dominio, mediante el cual se demuestra que el servidor tiene control sobre el dominio solicitado. Una vez validado, se genera un certificado digital que incluye la clave pública del servidor, la identidad del dominio y la firma digital de la autoridad certificadora. Concretamente se ha utilizado el método de validación DNS-01 que consiste en demostrar que se tiene control sobre el dominio añadiendo un registro específico tipo TXT en la configuración DNS. Este registro contiene un *token* generado por la autoridad certificadora.

4.13. Inteligencia Artificial

Se ha utilizado Inteligencia Artificial (IA) como herramienta de apoyo durante distintas fases del desarrollo del proyecto. Concretamente se ha usado **ChatGPT**⁷⁶ como herramienta generativa. Su principal aplicación ha sido la **localización rápida de información técnica y documentación especializada**, permitiendo identificar con mayor rapidez bibliotecas, tecnologías, artículos y recursos relacionados con sistemas RAG, bases de datos vectoriales, modelos de lenguaje, OCR, Docker y otras tecnologías empleadas.

⁷³<https://certbot.eff.org/>

⁷⁴<https://www.eff.org/>

⁷⁵<https://letsencrypt.org/>

⁷⁶<https://chatgpt.com/>

Además, se utilizó como herramienta de consulta para la **comprensión de conceptos técnicos complejos**. Gracias a sus capacidades de procesamiento del lenguaje natural, permitió obtener explicaciones detalladas sobre tecnologías, algoritmos, arquitecturas software y procedimientos de configuración, facilitando el aprendizaje de nuevas herramientas durante el desarrollo.

También se empleó de forma puntual para resolver dudas relacionadas con programación, configuración de entornos, interpretación de mensajes de error y búsqueda de posibles soluciones a problemas técnicos encontrados durante la implementación.

No obstante, **toda la información obtenida** mediante esta herramienta **fue contrastada** posteriormente mediante documentación oficial, artículos técnicos y pruebas experimentales realizadas sobre la propia aplicación, utilizándose ChatGPT exclusivamente como una herramienta de apoyo al desarrollo y no como fuente principal de información.

5. Aspectos relevantes del desarrollo del proyecto

En este apartado se van a explicar los aspectos más importantes del proyecto. Se van a recoger los distintos retos se han encontrado durante el desarrollo indicando como se solventaron. También, se van a explicar las decisiones más relevantes que se han tomado para llevar a cabo el proyecto.

5.1. Inicio del proyecto

Actualmente la mayor parte de las personas utilizan grandes modelos de lenguaje (LLM), ya bien sea a través de [ChatGPT](https://chat.openai.com)⁷⁷, [Claude](https://claude.ai)⁷⁸, [Gemini](https://gemini.google.com/app)⁷⁹ o [NotbookLM](https://notebooklm.google.com/)⁸⁰, pero la mayor parte de los usuarios no conocen lo suficiente de su funcionamiento como para sacarle el máximo partido. Generalmente los *prompts* de estos usuarios son escuetos, sin el contexto adecuado, lo que permite que el modelo alucine en sus respuestas dándoles información errónea que generalmente no contrastan. En este contexto surgió la idea del proyecto, construir un **sistema RAG especializado en licitaciones del estado**, concretamente en las de la Junta de Gobierno de la Diputación Provincial de Burgos.

Gracias a este sistema RAG se evita que sea el usuario el que le tenga que otorgar el contexto al modelo LLM. Ya que el sistema tiene todos los

⁷⁷<https://chat.openai.com>

⁷⁸<https://claude.ai>

⁷⁹<https://gemini.google.com/app>

⁸⁰<https://notebooklm.google.com/>

documentos de las licitaciones publicadas en la página de **Contratación del Sector Público**⁸¹. Además, para **evitar alucinaciones** se decidió limitar las respuestas de LLM a la información que le proporciona el sistema RAG. En caso de que la pregunta no esté alineada con la colección documental se informa al usuario.

Otro problema típico de los LLM es la fecha de entrenamiento, ya que no son capaces de contestar preguntas posteriores a esta fecha, ya que no conocen su respuesta. Para evitar este problema de desactualización se decidió incluir un programa de *Web Scraping* para que se pueda extraer de forma periódica las nuevas licitaciones y volver a descargar aquellas que hayan sido actualizadas.

5.2. Web Scraping

Tras formalizar la idea se comenzó con el proyecto realizando la aplicación de *Web Scraping* para **extraer las licitaciones** de la página de **Contratación del Sector Público**⁸² de **manera automática**. Se desarrollaron diferentes soluciones utilizando Selenium y Playwright, optando finalmente por el uso de Playwright en modo asíncrono, ya que permite gestionar de forma automática las esperas y la interacción con elementos dinámicos, haciendo que el sistema sea más robusto frente a fallos y *timeouts* que con los programas realizados con Selenium. Además, al usar Playwright asíncrono (*asyncio*) se pudo incorporar procesamiento concurrente, ya que permite procesar varias tareas en paralelo, para optimizar el tiempo de extracción y descarga de datos.

La elevada complejidad de la página debido al uso de contenido dinámico e *iframes* supuso un reto. Para solventarlo se tuvieron que desarrollar mecanismos específicos para la localización de elementos y la navegación entre distintos contextos. Finalmente, los datos obtenidos se normalizan y almacenan en un archivo JSON. Este archivo se usa para descargar los pliegos finales. En la Tabla 5.1 se pueden observar los datos globales obtenidos del proceso de *Web Scraping*.

Cabe destacar que durante el desarrollo del proyecto se actualizó la página **Contratación del Sector Público**⁸³, por lo cual hubo que realizar

⁸¹<https://tinyurl.com/48ay5679>

⁸²<https://tinyurl.com/48ay5679>

⁸³<https://tinyurl.com/48ay5679>

cambios en el programa ya desarrollado, modificando selectores y flujos de navegación para mantener su funcionamiento.

5.3. *Retrieval Augmented Generation* (RAG)

Durante el desarrollo del sistema RAG se han evaluado distintos enfoques para cada uno de sus componentes principales, con el objetivo de optimizar la calidad de las respuestas, la eficiencia del sistema y su facilidad de despliegue. A continuación, se describen los elementos más relevantes analizados, las pruebas realizadas y la justificación de las decisiones finales adoptadas.

5.3.1. *Tokenizer*

Uno de los primeros aspectos analizados fue el uso del *tokenizer*, ya que es el encargado de **transformar el texto en unidades básicas** (*tokens*) que son la entrada real de los modelos de lenguaje (LLM). Su correcto funcionamiento es clave tanto para el procesamiento del texto como para el control del tamaño de los fragmentos (*chunks*).

Se realizaron pruebas con diversos *tokenizers* asociados a distintos modelos de lenguaje (como LLaMA o Mistral), así como con el *tokenizer* incluido en los modelos de *embeddings*. Se observó que utilizar el *tokenizer* del propio modelo de *embeddings* simplifica el *pipeline* y evita inconsistencias entre la representación del texto y su vectorización semántica. Además, permite conocer directamente el número máximo de *tokens* admitido por el modelo, facilitando el control del tamaño de entrada y evitando superar la ventana máxima soportada.

Por este motivo, se optó por utilizar el *tokenizer* del modelo de *embeddings* (**SentenceTransformer**), garantizando coherencia entre el proceso de *chunking* y la generación de *embeddings*.

En la implementación final, el sistema **obtiene automáticamente** tanto el *tokenizer* como el **tamaño máximo de secuencia** directamente desde el modelo cargado, permitiendo adaptar dinámicamente el sistema si se cambia de modelo de *embeddings*. Esto facilita la reutilización del *pipeline* con distintos modelos sin necesidad de modificar manualmente los parámetros de tokenización.

5.3.2. *Chunking*

El *chunking* consiste en **dividir los documentos en fragmentos manejables**. Es fundamental para ajustarse a la ventana de contexto del modelo y para mejorar la recuperación semántica. El texto se puede segmentar por longitud fija (*tokens*), por secciones o párrafos o por significado semántico.

En este proceso se probaron diferentes estrategias como el *chunking* por tamaño fijo de caracteres, por *tokens* con *overlap* (solapamiento) para mantener el contexto o basado en secciones o frases. Durante las pruebas se comprobó que el uso exclusivo de *chunks* por tamaño fijo generaba fragmentos poco naturales, afectando negativamente a la recuperación. Por otro lado, el *chunking* semántico puro resultaba más complejo y costoso.

Con el objetivo de determinar la estrategia de fragmentación más adecuada, se realizaron diferentes pruebas variando tanto el criterio de división como el tamaño de los fragmentos y el porcentaje de solapamiento. Las evaluaciones se llevaron a cabo sobre documentos reales del dominio de contratación pública, analizando la coherencia de los fragmentos generados, la capacidad de recuperación de información relevante y el número de fragmentos almacenados en la base de datos vectorial (ver Tabla 5.3).

Las pruebas realizadas permitieron observar que los *chunks* demasiado pequeños reducían la capacidad contextual del sistema, obligando al recuperador a combinar un mayor número de fragmentos para responder correctamente a determinadas consultas. Por el contrario, los fragmentos excesivamente grandes disminuían la granularidad de la recuperación, incrementaban el número de *tokens* enviados al modelo generativo y aumentaban el coste computacional asociado a cada consulta. También, se comprobó que la ausencia de solapamiento provocaba pérdidas de información cuando una explicación quedaba dividida entre dos fragmentos consecutivos, mientras que porcentajes elevados introducían redundancia innecesaria en la base vectorial.

Por ello se optó por una **estrategia híbrida**, en la cual los documentos se procesan identificando títulos y secciones para preservar su estructura lógica. Posteriormente, el contenido se agrupa utilizando límites naturales de frase y, finalmente, se divide en fragmentos controlados por número de *tokens*. La configuración seleccionada utiliza fragmentos de 1500 tokens con un solapamiento de 60 *tokens* entre fragmentos consecutivos.

Métrica	Valor
Licitaciones localizadas	175
Registros documentales extraídos	734
Enlaces a documentos detectados	2.094
Expedientes procesados para el RAG	165
Documentos PDF descargados	330
Promedio de documentos descargados por expediente	2
Promedio de documentos detectados por licitación	4,19

Tabla 5.1: Resumen de resultados obtenidos mediante el proceso de *Web Scraping*.

Estrategia	Tamaño	Overlap (%)	Observaciones
Caracteres fijos	1000 caracteres	0	Genera cortes artificiales en mitad de párrafos y tablas. Recuperación poco precisa.
Tokens fijos	512 tokens	0	Fragmentos demasiado pequeños. Se pierde contexto entre apartados relacionados.
Tokens fijos	1024 tokens	5	Mejora la coherencia respecto a la configuración anterior, aunque todavía aparecen pérdidas de contexto en documentos extensos.
Tokens fijos	1536 tokens	5	Buen equilibrio entre cantidad de contexto y precisión de recuperación. Menor número de fragmentos por documento.
Frases y tokens	1536 tokens	5	Mantiene la coherencia semántica de los textos y evita cortes en mitad de frases. Resultados de recuperación más consistentes.
Secciones, frases y tokens	1536 tokens	5	Mejor comportamiento global. Conserva la estructura documental y facilita la recuperación de información contextual relevante.

Tabla 5.2: Pruebas realizadas para la selección de la estrategia de *chunking*.

5.3.3. *Embeddings*

Los *embeddings* son **representaciones vectoriales del texto** que capturan su significado semántico. Permiten comparar las consultas de los usuarios con los fragmentos de los documentos y realizar **búsquedas por similitud**. Son la base del funcionamiento del sistema de recuperación del RAG. Por lo cual para elegir el modelo final se analizaron distintos modelos comparando sus características en términos de calidad semántica, velocidad de ejecución y consumo de recursos (ver Tabla 5.3). La calidad semántica se evaluó mediante pruebas de recuperación sobre los documentos administrativos, analizando la relevancia de los fragmentos recuperados. Además, se tuvo en cuenta el tamaño de los vectores producidos por cada modelo, ya que cuanto mayor sea más memoria va a ocupar en la base de datos vectorial Qdrant. Finalmente, se seleccionó el modelo `sentence-transformers/all-MiniLM-L6-v2` debido a que proporciona vectores de 384 dimensiones, suficientes para representar adecuadamente el contenido semántico de los documentos procesados por PythIA. Además, ofrece tiempos de inferencia reducidos, un bajo consumo de memoria y una integración sencilla mediante la biblioteca `SentenceTransformer`. Estas características permiten mantener un buen equilibrio entre calidad de recuperación, velocidad de indexación y eficiencia computacional.

Modelo	Dimensión	Parámetros (M)	Velocidad	Consumo	Observaciones
<code>all-MiniLM-L6-v2</code> ⁸⁴	384	22,7	Muy alta	Bajo	Buen equilibrio entre calidad semántica y coste computacional.
<code>all-MiniLM-L12-v2</code> ⁸⁵	384	33,4	Alta	Medio	Ligera mejora semántica, pero mayor tiempo de inferencia.
<code>multi-qa-MiniLM-L6-cos-v1</code> ⁸⁶	384	22,7	Muy alta	Bajo	Optimizado para recuperación, aunque menos robusto en documentos extensos.
<code>all-mpnet-base-v2</code> ⁸⁷	768	109	Media	Alto	Excelente representación semántica, pero elevado consumo de memoria.

Tabla 5.3: Comparación de los modelos de *embeddings* evaluados durante el desarrollo.

Durante el desarrollo también se optimizó el proceso de generación de *embeddings* para mejorar el rendimiento durante la indexación documental. La implementación final detecta automáticamente el dispositivo de ejecución disponible y utiliza **aceleración mediante GPU** cuando existe soporte CUDA, recurriendo a CPU únicamente cuando no se dispone de *hardware* gráfico compatible. Esta estrategia permite aprovechar los recursos disponibles sin requerir configuración adicional por parte del usuario. Además, se incorporaron mecanismos de tolerancia a fallos para garantizar la robustez del proceso de indexación. En caso de que la memoria de CUDA sea insuficiente, el sistema libera la memoria reservada en la GPU y reintenta la operación usando la CPU.

Otra mejora relevante fue el procesamiento por lotes (*batch processing*) durante la generación de *embeddings*. En lugar de calcular los vectores de cada fragmente de forma individual, el sistema procesa los *chunks* agrupados en lotes de hasta 32 elementos, reduciendo el número de llamadas al modelo y mejorando el rendimiento global de la indexación. Por otra parte, el modelo de *embeddings* se mantiene cargado en memoria mediante un patrón *Singleton*, evitando recargas innecesarias y disminuyendo el tiempo requerido para procesar grandes volúmenes documentales.

5.3.4. Base de datos vectorial

La base de datos vectorial es la encargada de **almacenar los *embeddings*** y permitir **realizar búsquedas vectoriales** en espacios de alta dimensión. Tras estudiar diversas opciones (ver sección 4.8.1) se eligió Qdrant ya que, al tener soporte nativo para la búsqueda vectorial simplifica mucho su uso eficiente. Además, permite almacenar metadatos junto con los *chunks* y *embeddings*, lo que se consideró de utilidad para aumentar el contexto durante la recuperación. Como metadatos se incluyen los *hashes* *SHA-256* de los documentos originales para detectar automáticamente cuándo un documento ha cambiado y reindexarlo sin duplicar información.

Durante el desarrollo se implementó un sistema de creación automática de colecciones en Qdrant. Estas colecciones están configuradas con búsqueda por **similitud coseno** y una dimensión de vector ajustada dinámicamente al modelo de *embeddings* empleado. Para optimizar el rendimiento, los *chunks* se almacenan mediante operaciones *bulk upsert*, reduciendo significativamente el tiempo de indexación frente a inserciones individuales. Además, se utiliza una capa de abstracción (similar a un *Object-Vector Mapping*) para encapsular

la lógica de conexión, serialización y recuperación de datos desde Qdrant. Esta capa permite desacoplar parcialmente el sistema del motor vectorial.

5.3.5. *Retriever* (mecanismo de recuperación)

Es el componente encargado de **buscar** en la base vectorial los **fragmentos más relevantes** para responder a una consulta. Su calidad es crítica, ya que determina el contexto que se proporcionará al modelo. Por lo tanto, la calidad de la respuesta depende directamente de la capacidad del *retriever* para recuperar información relacionada con la pregunta del usuario. Se basa en la búsqueda por similitud vectorial, principalmente por similitud coseno.

En los primeros prototipos del proyecto, el sistema solo recuperaba el *chunk* más parecido a la consulta del usuario. Para ello, primero se convertía la pregunta en un *embedding* (utilizando el mismo modelo que el que se usa para indexar los documentos). Posteriormente, se calculaba la similitud entre dicho *embedding* y los almacenados en la base de datos vectorial. Finalmente, se seleccionaba el fragmento con mayor similitud y este se incorporaba directamente al *prompt* enviado al LLM. Este enfoque se planteó como punto de partida para validar el funcionamiento básico del RAG pero presentaba limitaciones importantes en la generación de la respuesta, haciendo que la mayoría de las preguntas no las pudiese contestar.

Después, se probó a cambiar el número de *chunks* recuperados (**top-k retrieval**). Se observó que recuperar pocos *chunks* produce respuestas demasiado limitadas, llevando a generalizaciones que no se cumplen en todos los documentos. En cambio, recuperar demasiados introduce ruido al modelo haciendo que responda con información irrelevante. Además, se vio que los contextos demasiado grandes hacen que el modelo utilice más *tokens* para contestar, empeorando la latencia de generación.

Otro aspecto relevante fue la evolución del propio *chunking*. Al principio los documentos se dividían utilizando tamaños fijos de texto. Sin embargo, se comprobó que esta estrategia fragmentaba información relacionada y afectaba negativamente a la recuperación semántica. Posteriormente, se introdujo el uso de solapamiento entre los *chunks*, permitiendo compartir parte del contenido entre fragmentos consecutivos. Esta mejora incrementó significativamente la coherencia del contexto recuperado y redujo la pérdida de información relevante entre fragmentos contiguos.

Además del contenido textual, también se añadieron metadatos asociados a cada *chunk* como el nombre del documento, el título de la licitación, el

identificador del fragmento, la posición dentro del documento y la información estructural obtenida durante el preprocesado. Utilizar metadatos mejoró la trazabilidad de las respuestas generadas.

Finalmente el sistema utiliza una estrategia de recuperación dinámica basada en búsqueda vectorial por similitud coseno sobre Qdrant. Para cada consulta, la pregunta del usuario se proyecta en el *embedding* y se consulta Qdrant para **recuperar los vectores más similares mediante similitud coseno**. De esta forma el sistema recupera un conjunto de *chunks* los cuales deben tener una **similitud con la pregunta de al menos 0'5** para descartar fragmentos poco relacionados con la consulta. El número de *chunks* recuperados depende del tipo de pregunta realizada, las consultas generales utilizan hasta 20 fragmentos, mientras que las consultas guiadas tienen configuraciones específicas optimizadas para cada caso. Por ejemplo, preguntas orientadas a resúmenes globales pueden recuperar hasta 80 *chunks* para proporcionar una visión completa del documento, mientras que consultas más concretas, como solvencia, garantías o duración contractual, utilizan entre 12 y 18 fragmentos para reducir el ruido y mantener la precisión. Además, de la recuperación semántica se **aplican filtros por metadatos**, como número de expediente o tipo de documento (administrativo/técnico) para limitar la búsqueda únicamente a los documentos relevantes. Este enfoque híbrido permite equilibrar cobertura contextual, precisión semántica y eficiencia en el consumo de *tokens* del LLM.

5.3.6. *Augmentation*

Este proceso consiste en **combinar la consulta del usuario con los fragmentos recuperados** para construir un *prompt* enriquecido. Esta fase incluye técnicas de ingeniería de *prompts* para mejorar la calidad de la respuesta. En el desarrollo del RAG se probaron distintas estrategias, observándose diferencias significativas en el comportamiento del sistema.

En las estrategias más simples, los *chunks* recuperados se concatenaban junto con la pregunta del usuario. Aunque este enfoque era sencillo, el modelo tendía a mezclar información o a ignorar parte del contexto recuperado.

Observadas estas limitaciones se decidió utilizar *prompts* estructurados. En los cuales se separa el contexto recuperado, la pregunta del usuario, las instrucciones del sistema y las restricciones sobre como responder.

Con este enfoque el LLM interpreta mejor el contexto recuperado y disminuye las alucinaciones. Además, se añadieron instrucciones específicas

indicando que la respuesta deben basarse únicamente en la información proporcionada por los *chunks* recuperados.

También, se han realizado pruebas modificando el orden de los fragmentos recuperados dentro del *prompt*. Se observó que colocar primero los *chunks* con mayor similitud mejora la precisión de las respuestas, especialmente en consultas complejas o ambiguas.

Otra mejora importante fue la incorporación de referencias documentales dentro del *prompt*. En lugar de proporcionar únicamente texto plano, cada fragmento incluye información sobre el documento de origen. Esto ayuda al modelo a contextualizar mejor la información y facilita mostrar al usuario la procedencia de la respuesta generada.

Finalmente, el sistema incorpora distintos *prompts* para contestar dependiendo del tipo de consulta que haga el usuario. Se ha diseñado **un *prompt* general** utilizado para preguntas abiertas, pero, además, se han definido **plantillas específicas para tareas concretas** como resúmenes globales del documento, extracción de importes económicos, plazos, solvencia, criterios de adjudicación, garantías, presupuestos, duración contractual, penalizaciones o presentación de ofertas. Cada plantilla incluye instrucciones adaptadas al tipo de información buscada y define una estructura concreta para la respuesta esperada. Por ejemplo, los *prompts* de tipo resumen solicitan una explicación global y estructurada del pliego, mientras que los orientados a criterios de adjudicación fuerzan al modelo a identificar ponderaciones, fórmulas y subcriterios. Además, el sistema utiliza un *system prompt* por defecto que obliga al modelo a responder en español de forma breve y precisa. Esta combinación de *prompts* especializados y selección dinámica del contexto permite adaptar el comportamiento del LLM al tipo de consulta realizada, mejorando la precisión, consistencia y utilidad de las respuestas generadas.

5.3.7. LLM

Es el encargado de **generar la respuesta final** utilizando el contexto proporcionado por el sistema RAG. La elección del modelo (tamaño, arquitectura, si es local o una API) afecta directamente a la calidad, latencia y coste del sistema.

Durante el desarrollo del proyecto, la integración de los modelos de lenguaje fue evolucionando progresivamente. Se comenzó realizando pruebas utilizando modelos locales (obtenidos de Hugging Face) ejecutados mediante

Ollama. Estas pruebas permitieron comprobar la viabilidad de ejecutar modelos localmente sin depender de ninguna API externa, lo que aporta un mayor control sobre el sistema y evita costes asociados al uso de servicios comerciales.

Se realizaron pruebas con diversos modelos locales como Mistral o LLaMA para probar distintas arquitecturas y tamaños. Gracias a estas pruebas se pudo ver como afecta el tamaño a la respuesta generada y al tiempo invertido. Se vio que los modelos más pequeños tardaban menos en generar las respuestas, pero dichas respuestas eran de menor calidad. Tendían a ser breves y menos precisas. Mientras que los modelos más grandes generaban mejores respuestas, pero con mayor consumo de recursos y latencias. Finalmente, se seleccionó como modelo principal del sistema **LLaMA 3.1-8B**, ya que tiene buen rendimiento en tareas de comprensión y generación. Este modelo ofrece un buen equilibrio entre la claridad de la respuesta generada, la utilización del contexto recuperado y los requisitos de *hardware*. Otro aspecto que se tuvo en cuenta a la hora de elegir el modelo fue que se pudiera **ejecutar en local usando Ollama**, para mantener el control total sobre el sistema sin dependencias externas.

Finalmente, se decidió incluir **soporte para múltiples modelos** configurables desde la propia aplicación *web*. De tal forma que la arquitectura final permite seleccionar dinámicamente entre tres modelos distintos (**LLaMA 3.1-8B**, **gemma-4B** y **qwen3-4B**, cargados desde Ollama) integrados dentro del sistema RAG. Esta evolución surgió debido a la necesidad de comparar comportamientos y ofrecer mayor flexibilidad dependiendo del tipo de consulta realizada.

Para soportar esta funcionalidad fue necesario desacoplar la lógica de generación del resto del *pipeline RAG*, implementando una capa de abstracción que permitiese cargar dinámicamente los distintos modelos y modificar sus parámetros. Además, se añadieron funciones auxiliares para gestionar las configuraciones disponibles y mostrar automáticamente las opciones en la interfaz *web*.

Además, se han ajustado parámetros de generación como el número máximo de *tokens* generados, la longitud máxima de entrada, la temperatura, el formato del *prompt* y el número de *chunks* recuperados. Lo que permitió mejorar la calidad de las respuestas, reduciendo alucinaciones y adaptándolas al contexto del sistema.

5.4. Conversión a Markdown

La conversión de los documentos PDF a Markdown permite **transformar documentos administrativos complejos en texto estructurado** apto para el proceso de *chunking*, generación de *embeddings* y recuperación semántica. Inicialmente, los documentos PDF se procesaban extrayendo texto plano. Este enfoque presentaba limitaciones como la pérdida de la estructura del documento, lo que provocaba que el sistema no pudiese diferenciar los títulos, subtítulos, tablas o las secciones. Por este motivo, durante el desarrollo se comenzó a investigar la posibilidad de convertir los PDF a Markdown de forma automática.

Las primeras aproximaciones consistieron en utilizar bibliotecas tradicionales de extracción de texto en Python. Estas herramientas permitían obtener el contenido textual de los PDF, pero perdían gran parte del formato original. Uno de los principales problemas encontrados fue que los documentos de licitaciones públicas presentan formatos extremadamente heterogéneos. Debido a esto se comenzaron a realizar pruebas utilizando OCR (*Optical Character Recognition*). Sin embargo, aunque el OCR permitía recuperar texto que anteriormente no podía extraerse, seguía presentando problemas.:

- No se reconocían correctamente todos los caracteres.
- Se seguía perdiendo parte del formato.
- Las tablas no siempre se construían bien
- El uso de OCR supuso un incremento considerable del tiempo de procesamiento.

La implementación final se basa en un sistema de **OCR multimodal** que utiliza **modelos visuales** ejecutados mediante Ollama, concretamente el modelo `blaiifa/Nanonets-OCR-s`. Este modelo recibe imágenes de las páginas del PDF junto con un *prompt* especializado que fuerza la generación de Markdown estructurado, incluyendo títulos jerárquicos, tablas HTML, ecuaciones en $\text{\LaTeX}$, listas y otros elementos relevantes del documento original.

El procesamiento se realiza de forma **asíncrona página a página**. Primero, cada página del PDF se convierte individualmente en una imagen utilizando `pdf2image`, evitando cargar el documento completo en memoria y reduciendo así el consumo de recursos. Posteriormente, las páginas se procesan concurrentemente mediante tareas asíncronas controladas con semáforos, permitiendo paralelizar parcialmente el OCR y mejorar el rendimiento glo-

bal del sistema. Esta arquitectura resulta especialmente importante debido al elevado tiempo de procesamiento de los documentos administrativos extensos.

Además, la implementación está preparada para utilizar aceleración por GPU cuando está disponible. El sistema detecta automáticamente la configuración de GPU y solicita a Ollama la ejecución del modelo visual utilizando todas las capas posibles en GPU. También se incorporaron mecanismos de *fallback* a CPU en caso de error, así como reintentos automáticos reduciendo progresivamente la resolución de las imágenes cuando el modelo produce fallos de memoria o errores internos. Estas optimizaciones fueron necesarias debido al elevado consumo computacional del OCR multimodal (ver Tabla 5.4), especialmente en documentos con muchas páginas o tablas complejas.

Tabla 5.4: Fuentes de consumo computacional durante la conversión de PDF a Markdown mediante OCR multimodal.

Etapa	Recurso principal	Impacto	Motivo del consumo computacional
Conversión PDF a imagen	CPU y memoria RAM	Alto	Cada página del documento debe renderizarse individualmente a 200 DPI antes de poder ser procesada por el modelo OCR multimodal. Cuanto mayor es el número de páginas, mayor es el tiempo de renderizado y el uso de memoria.
Almacenamiento temporal de imágenes	Memoria RAM y disco	Medio	Las páginas renderizadas se almacenan temporalmente como imágenes PNG, lo que incrementa el consumo de memoria y espacio durante el procesamiento.
Redimensionado de imágenes	CPU y memoria RAM	Medio	Las imágenes se redimensionan para limitar su tamaño máximo a 1600 píxeles por lado y evitar errores de memoria en el modelo visual.

Continúa en la siguiente página

Continúa desde la página anterior

Etapa	Recurso principal	Impacto	Motivo del consumo computacional
Inferencia OCR multimodal	GPU (o CPU) y VRAM	Muy alto	Cada página se analiza mediante el modelo visual Nanonets-OCR-s , que debe interpretar simultáneamente texto, tablas, imágenes y estructura documental para generar Markdown estructurado. Es la fase más costosa del proceso.
Codificación y envío a Ollama	CPU y memoria	Medio	Las imágenes deben convertirse a formato Base64 y enviarse al servicio Ollama para su procesamiento, incrementando el volumen de datos transferidos.
Reintentos automáticos	CPU, GPU y tiempo de ejecución	Variable	Cuando se producen errores de memoria o fallos internos del modelo, el sistema vuelve a procesar la página utilizando resoluciones progresivamente menores (1600, 1280, 1024, 896 y 768 píxeles).
Postprocesado del Markdown	CPU	Bajo	Se aplican reglas para normalizar encabezados, corregir índices y mejorar la estructura del Markdown generado por el modelo OCR.

Tras la conversión inicial, el Markdown generado pasa por una fase adicional de **normalización automática** para corregir errores frecuentes del OCR multimodal. Se aplican diversas reglas heurísticas diseñadas específicamente para los documentos de licitación pública:

- Corrección de índices: se detectan las entradas del índice que contienen secuencias de puntos suspensivos utilizadas como separadores visuales entre el título y el número de página, eliminando dichos caracteres para conservar únicamente la información relevante.
- Eliminación de líneas de relleno: se descartan líneas formadas exclusivamente por puntos u otros caracteres utilizados para maquetar los índices.
- Detección de secciones principales: las líneas con numeración del tipo 1. TÍTULO se convierten automáticamente en encabezados Markdown

de primer nivel cuando el texto asociado aparece mayoritariamente en mayúsculas.

- Detección de subsecciones: las estructuras numeradas del tipo 1.1. **Título** se transforman en encabezados Markdown de segundo nivel.
- Detección de subsubsecciones: las estructuras del tipo 1.1.1. **Título** se convierten en encabezados Markdown de tercer nivel.
- Reconocimiento de códigos alfanuméricos: se detectan identificadores frecuentes en los pliegos administrativos, como G.2.2. o A.1.3., transformándolos también en encabezados jerárquicos.
- Preservación de elementos Markdown válidos: las líneas que ya han sido reconocidas correctamente por el modelo OCR como títulos Markdown, listas, tablas, citas o elementos HTML no se modifican durante el proceso de normalización.
- Conservación de la estructura documental: las transformaciones se aplican únicamente sobre líneas situadas al nivel principal del documento, evitando alterar el contenido interno de listas, tablas o bloques especiales.

Durante el desarrollo se observó que esta aproximación mejora considerablemente la calidad del texto utilizado posteriormente por el sistema RAG, especialmente frente a OCR tradicionales basados únicamente en extracción plana de texto. Sin embargo, también se detectaron varias limitaciones importantes. La principal es el elevado tiempo de procesamiento, ya que cada página debe renderizarse como imagen y posteriormente analizarse mediante un modelo multimodal. Para cuantificar este coste computacional se analizaron los datos reales obtenidos durante la utilización de la aplicación PythIA. En total se convirtieron 132 documentos que sumaban un total de 22.544 páginas. La conversión a Markdown estuvo activa durante 244.030,29 minutos, por lo cual cada página tardó $244.030,29 \text{ minutos} / 22.544 \text{ páginas} = 10,82 \text{ minutos}$ (ver figura 5.1). Este valor incluye tanto la generación de la imagen a partir del PDF como la inferencia realizada por el modelo OCR multimodal y las fases posteriores de normalización del Markdown.

Terminal

```
SELECT
  ROUND(
    SUM(EXTRACT(EPOCH FROM (finished_at - started_at))) / 60,
    2
  ) AS minutos_totales
FROM markdown_conversion_state
```

```
WHERE progress > 0
    AND started_at IS NOT NULL
    AND finished_at IS NOT NULL;

# Comando SQL utilizado para conocer el número total
# de documentos convertidos a Markdown
SELECT COUNT(*) AS documentos_convertidos
FROM documents
WHERE markdown_content IS NOT NULL
    AND length(markdown_content) > 0;

# Script Python utilizado para obtener el número total
# de páginas de los documentos convertidos
from pathlib import Path
from pypdf import PdfReader
total_pages = 0
for pdf in Path('/data/pliegos').glob('*.pdf'):
    try:
        pages = len(PdfReader(str(pdf)).pages)
        total_pages += pages
    except Exception as e:
        print(f'ERROR {pdf.name}: {e}')
print('TOTAL PAGINAS:', total_pages)
```

Además, aunque el sistema consigue detectar correctamente gran parte de la estructura documental, no siempre identifica de forma precisa todas las secciones, tablas o jerarquías debido a que los formatos de los documentos son poco homogéneos.

5.5. Evaluación RAG

Un aspecto relevante del proyecto fue incluir una evaluación del sistema RAG implementado. Para dicha evaluación se ha utilizado un ***pipeline de evaluación RAG propio***. El cual se inspira en *frameworks* existentes como ARES (*Automated RAG Evaluation System*) y RAGAS (*Retrieval-Augmented Generation Assessment*). El objetivo principal era construir un **sistema de evaluación reproducible, automatizable y completamente local**, evitando dependencias de API externas y garantizando la confidencialidad de los documentos utilizados.

```
>>> print("TOTAL PAGINAS:", total_pages)
TOTAL PAGINAS: 22544
```

(a) Total de páginas convertidas a Markdown.

```
mydatabase=# SELECT
    ROUND(
        SUM(EXTRACT(EPOCH FROM (finished_at - started_at))) / 60,
        2
    ) AS minutos_totales
FROM markdown_conversion_state
WHERE progress > 0
    AND started_at IS NOT NULL
    AND finished_at IS NOT NULL;
minutos_totales
-----
          244030.29
(1 row)

mydatabase=# SELECT COUNT(*) AS documentos_convertidos
FROM documents
WHERE markdown_content IS NOT NULL
    AND length(markdown_content) > 0;
documentos_convertidos
-----
                  132
(1 row)
```

(b) Datos temporales totales de la conversión y número de expedientes convertidos.

Figura 5.1: Datos obtenidos de la conversión a Markdown del sistema.

La arquitectura implementada combina distintos enfoques de evaluación con la generación automática de *datasets* de evaluación. Para la generación de dichos *datasets* se utiliza ARES, el cual genera de manera automática preguntas, respuestas y evidencias documentales a partir de los propios *chunks* almacenados en la base de datos vectorial.

Respecto a la evaluación, por un lado, se utiliza RAGAS para calcular métricas semánticas relacionadas con la calidad de la recuperación y de la generación utilizando un enfoque *LLM-as-a-judge*. Las métricas utilizadas son:

- *Faithfulness*
- *Answer relevance*
- *Answer correctness*
- *Context precision y recall*

- *Context relevance*

Las cuales permiten analizar si la respuesta realmente está fundamentada en el contexto recuperado y si dicho contexto es adecuado para responder la consulta. Esta evaluación se combina con métricas de respaldo basadas en *embeddings* y similitud coseno. Estas métricas permiten calcular automáticamente el grado de similitud semántica entre preguntas, respuestas, contexto recuperado y *ground truth* utilizando representaciones vectoriales. Finalmente, **ambas métricas se combinan mediante medias ponderadas**. Consiguiendo una evaluación híbrida más robusta y estable. Esta combinación permitió reducir la variabilidad típica de los sistemas basados únicamente en *LLM-as-a-judge* y mejorar la reproducibilidad de los resultados.

5.6. Tareas asíncronas

Para **evitar el bloqueo de la aplicación** mientras se realizan tareas largas del proyecto se ha decidido ejecutarlas de manera asíncrona. Concretamente se ha usado este sistema para el Web Scraping, la conversión de documentos PDF a Markdown, la actualización de la base de datos vectorial y la evaluación del RAG. Permitiendo que estas tareas largas se ejecuten en segundo plano, sin bloquear el uso de la interfaz *web*.

Para implementarlo se han usado ejecutores basados en `ThreadPoolExecutor`. Se ha separado el ejecutor de las tareas de Markdown del resto de tareas del sistema. Esta separación permite controlar de forma independiente el número máximo de tareas concurrentes y evitar que procesos intensivos consuman todos los recursos disponibles. Además, se asocia un objeto `Future` a cada una de las tareas que se envían al ejecutor, de tal forma que se pueda realizar un seguimiento de su estado, cancelando trabajos que aún no hayan comenzado y liberando los recursos cuando finalizan.

Un reto que se planteó fue que la ejecución de las tareas largas (como la conversión a Markdown) no aumentasen la latencia en las respuestas del sistema RAG. Para solventar este problema se ha implementado un **sistema de prioridades** basado en un indicador global de actividad del RAG. Cuando un usuario realiza una consulta, el sistema activa una marca de prioridad que indica que existe una generación RAG en curso. Mientras la marca esté activa, el resto de tareas asíncronas que también estén activas esperan antes de lanzar nuevas peticiones al modelo.

Cuando un proceso largo finaliza se envía por correo electrónico una notificación para evitar que el usuario tenga que estar esperando en la aplicación hasta que el proceso finalice. Por ejemplo, se envía cuando finaliza la conversión a Markdown, la actualización vectorial o el *Web Scraping*. En el correo que se envía al usuario se indica el resultado de la operación, incluyendo el número de documentos convertidos, indexados o extraídos, respectivamente.


5.7. Desarrollo *web*

Tras realizar un primer prototipo RAG, el cual se ejecutaba desde a terminal, se comenzó el diseño de una aplicación *web* para permitir a los usuarios **interactuar con el sistema de manera sencilla y visual**. Para ello se decidió utilizar Flask como *framework* de desarrollo *web*.

Flask es un *framework* ligero para Python basado en la arquitectura WSGI que permite desarrollar aplicaciones web de manera modular y escalable. Una de las razones principales para su elección fue su flexibilidad, ya que facilita integrar distintos componentes del sistema RAG, como el *retriever*, el procesamiento documental o los modelos LLM, dentro de una misma aplicación. Además, Flask permite estructurar el proyecto utilizando *blueprints*, lo que facilitó dividir la aplicación en módulos independientes y mejorar su mantenibilidad.


Durante las primeras fases del desarrollo *web* se realizaron prototipos muy simples cuyo objetivo principal era únicamente permitir realizar consultas al sistema RAG desde una interfaz básica. Estas primeras versiones consistían en páginas HTML estáticas con formularios mínimos para introducir preguntas y mostrar respuestas del modelo. Conforme el proyecto evolucionó, la aplicación fue creciendo progresivamente hasta convertirse en una plataforma *web* completa con autenticación, gestión documental, historial de consultas, paneles administrativos y procesamiento asíncrono de tareas.

Desde el punto de vista arquitectónico, la aplicación se divide en *frontend* y *backend*. El *frontend* se encarga de la interacción visual con el usuario y el *backend* se encarga de la lógica de negocio, procesamiento documental, acceso a bases de datos y comunicación con el sistema RAG.



(a) Diseño de los prototipos iniciales de la aplicación.

(b) Primeras iteraciones en el diseño de la interfaz.



(c) Interfaz final de la aplicación.

Figura 5.2: Evolución de la interfaz desde los prototipos iniciales hasta el diseño final.

5.7.1. Frontend

El *frontend* de PythIA ha evolucionado respecto a los primeros prototipos desarrollados durante el proyecto (ver figura 5.2). Las primeras interfaces eran simples y estaban centradas en validar el funcionamiento técnico del sistema RAG. Sin embargo, conforme el proyecto avanzó, se comenzó a trabajar en el diseño de una interfaz más moderna, usable y adaptada a distintos tipos de usuarios. En la cual la **complejidad** del sistema RAG es **transparente para el usuario**.




Figura 5.3: Distintas pantallas de la aplicación vistas desde un teléfono móvil.

El diseño visual de la aplicación se ha ido desarrollando a lo largo de todo el proyecto mediante distintas iteraciones de las páginas. Uno de los cambios más importantes respecto a los primeros prototipos fue la incorporación de soporte completo para modo claro y modo oscuro (dejando por defecto el modo del sistema salvo que el usuario indique otra preferencia en su perfil) mejorando así la accesibilidad y la experiencia de usuario.

Para implementar la interfaz se utilizó Bootstrap como *framework* CSS principal. Bootstrap permitió acelerar el desarrollo del *frontend* gracias a su sistema de componentes reutilizables, facilitando mantener una coherencia visual entre todas las páginas de la aplicación. La utilización de Bootstrap también permitió implementar un **diseño *responsive*** para que los usuarios puedan usar la aplicación desde distintos dispositivos (ver figura ??).

Otro aspecto importante del *frontend* fue la **internacionalización** de la aplicación. Para esto se ha desarrollado un sistema de traducción basado en diccionarios de claves y funciones auxiliares que permiten traducir los textos de la interfaz, los formularios, los mensajes de error, las validaciones, las notificaciones y los componentes dinámicos del JavaScript. Esto permitió desacoplar completamente los textos de la interfaz del código HTML y Python.

Además del diseño visual, también se incorporaron componentes **gráficos interactivos** utilizando D3.js. Lo que permitió generar visualizaciones mucho

más dinámicas y personalizables. Además, facilitó adaptar las gráficas al diseño visual de la aplicación y a los distintos temas claro y oscuro.

Por otro lado, conforme el sistema fue incorporando más funcionalidades, se observó que algunos usuarios podían tener dificultades para comprender ciertos flujos de uso. Para mejorar la experiencia de usuario se han incorporado Driver.js como sistema de **tutoriales interactivos guiados**. Facilitando el aprendizaje inicial de la plataforma y mejorando la accesibilidad del sistema.

5.7.2. *Backend*

El *backend* de PythIA es el **núcleo funcional de la aplicación** y el encargado de integrar todas las partes del sistema RAG. Durante el desarrollo ha ido evolucionando desde *scripts* independientes hasta una arquitectura modular basada en Flask y organizada mediante *blueprints*, servicios y capas desacopladas.

La aplicación se organizó utilizando **controladores** Flask agrupados mediante *blueprints*. Cada *blueprint* encapsula un conjunto concreto de funcionalidades, como autenticación, administración, consultas RAG, gestión documental y páginas principales. Esta organización ha permitido desacoplar las distintas partes del sistema y mejorar la escalabilidad del proyecto.

Por debajo de los controladores se implementó una **capa de servicios** encargada de la lógica de negocio. Esta separación fue especialmente importante conforme el proyecto fue creciendo, ya que evita sobrecargar los controladores Flask con lógica de negocio. Permitiendo reutilizar código entre distintas partes de la aplicación y facilitando el mantenimiento.

En cuanto a los modelos de datos, la aplicación utiliza SQLAlchemy como ORM principal.

Además de la base de datos relacional utilizada para la gestión general de la aplicación, el *backend* también integra Qdrant como base de datos vectorial para almacenar los *embeddings* utilizados por el sistema RAG.

La comunicación entre las distintas capas de la aplicación sigue una arquitectura multicapa donde el usuario interactúa con el *frontend*. A continuación los controladores reciben las peticiones y los servicios ejecutan la lógica de negocio. Los modelos gestionan el acceso a los datos y los resultados se devuelven al *frontend*.

Otro aspecto importante fue la seguridad y el control de acceso. La aplicación implementa **autenticación** mediante Flask-Login y utiliza distintos roles de usuario para restringir determinadas funcionalidades administrativas.

También se ha desarrollado un sistema centralizado de **control de excepciones** para evitar errores no controlados dentro de la aplicación y evitar así caídas del sistema. Concretamente se registran los errores (mediante *loggers*) mostrándose mensajes de error amigables.

Debido al elevado coste computacional de algunas operaciones, se incorporó soporte para **tareas asíncronas**. Esto fue especialmente importante en procesos como la conversión de PDF a Markdown, el *Web Scraping*, la generación de *embeddings*, la indexación documental y la generación de la respuesta. Permite evitar bloqueos en la interfaz web, ya que los procesos pesados pueden ejecutarse en segundo plano mientras el usuario continua usando la aplicación (ver sección 5.6).

Otro aspecto relevante fue la **validación de las direcciones de correo electrónico** durante el proceso de registro y edición de usuarios. Inicialmente se valoró realizar comprobaciones de formato mediante expresiones regulares, pero este enfoque no permite detectar direcciones inexistentes o dominios incapaces de recibir mensajes. Para solucionar esta limitación se integró la API de Emailable. De tal forma que antes de completar el registro de usuario o la actualización del perfil, el servidor consulta la API para verificar que la dirección introducida posee una sintaxis válida, un dominio existente y que puede recibir correos electrónicos.

5.8. Evaluación de la calidad del código

A medida que el proyecto fue creciendo y la aplicación pasó de estar formada por pequeños prototipos experimentales a convertirse en un sistema *web* completo surgió la necesidad de incorporar mecanismos que permitiesen evaluar y controlar la calidad de código desarrollado.

Durante las primeras fases del proyecto, la prioridad principal era desarrollar *scripts* funcionales sin tener en cuenta el código duplicado, las funciones demasiado complejas, la escasa modularización, la baja reutilización o las dependencias acopladas. Para facilitar la mantenibilidad y la escalabilidad se decidió incorporar herramientas automáticas de análisis estático de código.

Concretamente se decidió usar **SonarCloud**⁸⁸. La cual se integró directamente con el repositorio **GitHub** del proyecto, para **analizar automáticamente** distintos indicadores relacionados con **la calidad del *software***. Su uso permitió detectar y solucionar *bugs*, vulnerabilidades de seguridad, código duplicado, funciones extremadamente complejas, funciones demasiado largas, variables sin utilizar, problemas de mantenibilidad, incumplimientos de estándares de calidad y problemas con tipado y control de excepciones.

Como consecuencia de estos análisis, se realizaron diversas refactorizaciones importantes dentro del proyecto. Por ejemplo, se realizó una separación más estricta entre los controladores y los servicios, se modularizaron las funciones más complejas, se reutilizó la lógica común reduciendo el código duplicado y se mejoró el control de excepciones.

Además, de SonarCloud también se utilizó **Ruff**⁸⁹ como herramienta complementaria para el análisis estático y mejora de la calidad del código. Ruff se integró dentro del flujo de desarrollo para realizar comprobaciones rápidas relacionadas con el estilo, complejidad y consistencia del código. Su principal ventaja es su gran velocidad de ejecución que permitió utilizarlo frecuentemente durante el desarrollo sin afectar significativamente al tiempo de trabajo. Gracias a Ruff se detectaron automáticamente problemas como *imports* no utilizados, variables redundantes, código muerto, errores de estilo, complejidad innecesaria y diversas malas prácticas de programación en Python. Además, se empleó para mantener una estructura homogénea en todo el proyecto, como por ejemplo, en los nombres de las funciones y variables. Esto ayudó a mejorar la legibilidad, consistencia y mantenibilidad del código, especialmente en un proyecto grande y modular como PythIA, donde coexistían múltiples componentes relacionados con Flask, el sistema RAG, el procesamiento documental y las tareas asíncronas.

Para mejorar la legibilidad también se añadieron comentarios y documentación y se realizó separación de responsabilidades.

Además del análisis estático, la calidad del código también se complementó con **pruebas unitarias, pruebas funcionales y pruebas de interfaz** desarrolladas durante distintas fases del proyecto. Estas pruebas permitieron verificar el correcto funcionamiento de los formularios, la gestión de usuarios, las validaciones, los servicios principales, la integración del sistema RAG y el procesamiento documental.

⁸⁸https://sonarcloud.io/project/overview?id=lbr1014_TFG_RAG

⁸⁹<https://docs.astral.sh/ruff/>

5.9. Despliegue

Uno de los aspectos más importantes durante el desarrollo de PythIA fue el diseño de un **entorno de despliegue estable, reproducible y preparado para producción**.

En las primeras fases del proyecto, la aplicación se ejecutaba en entornos locales de desarrollo utilizando el servidor integrado de Flask. Aunque esta aproximación era suficiente para validar prototipos y desarrollar funcionalidades, presentaba importantes limitaciones relacionadas con el rendimiento, la escalabilidad, la seguridad y la reproducibilidad del entorno.

Para resolver estos problemas se decidió utilizar Docker. Lo que permitió encapsular los componentes necesarios de la aplicación dentro de **contenedores independientes**, garantizando que el sistema se ejecute de manera consistente independientemente del entorno donde fuese desplegado.

La utilización de Docker aportó múltiples ventajas al proyecto, por ejemplo permitió aumentar la reproducibilidad del entorno, aislar los servicios y simplificar la gestión de dependencias. Mejorando la mantenibilidad y la portabilidad entre distintos entornos. Además, hizo que el despliegue fuese más fácil.

En las primeras versiones, Flask seguía ejecutándose utilizando su servidor de desarrollo integrado. Sin embargo, este servidor no está diseñado para entornos productivos, ya que no gestiona adecuadamente múltiples peticiones concurrentes ni ofrece suficiente robustez frente a cargas elevadas. Para solucionar estos problemas se **integró Gunicorn como servidor WSGI** de producción. El cual se encarga de ejecutar múltiples *workers* de Flask de manera concurrente, mejorando significativamente el rendimiento y la estabilidad del sistema. Permitiendo gestionar mejor las peticiones simultáneas, el tiempo de espera, los procesos bloqueantes y la recuperación frente a fallos.

Otro aspecto importante fue la **incorporación de Nginx como proxy inverso**. Nginx se sitúa delante de Gunicorn y asume la gestión de conexiones HTTP, el balanceo interno de peticiones, la gestión de cabeceras, la optimización de rendimiento, la seguridad básica de acceso y se encarga de servir los archivos estáticos. Su utilización de manera conjunta con Gunicorn permitió separar las responsabilidades del sistema *web*, mejorando tanto el rendimiento como la seguridad de la aplicación.

La configuración de Docker presento alguna dificultad, por ejemplo, en la integración entre Flask, Qdrant y PostgreSQL, ya que la aplicación dependía

simultáneamente de una base de datos relacional y otra vectorial. Lo que obligó a diseñar cuidadosamente la inicialización y configuración de los servicios para evitar errores durante el arranque del sistema.

Otro aspecto relevante fue la gestión de las variables sensibles y claves privadas. Para ello se utilizaron archivos de variables de entorno diferenciados, separando las configuraciones públicas de las credenciales privadas del sistema. Esto permitió mejorar la seguridad y facilitar la configuración en distintos entornos.

La arquitectura final del despliegue está dividida en varios contenedores especializados que se comunican entre sí mediante redes Docker internas. El sistema se divide principalmente en cinco servicios, un contenedor PostgreSQL para la persistencia de datos relacionales de la aplicación, un contenedor Qdrant encargado de la base de datos vectorial, un contenedor Ollama responsable de ejecutar los modelos de lenguaje y OCR multimodal utilizando aceleración por GPU, un contenedor principal con la aplicación Flask ejecutada mediante Gunicorn y un contenedor Nginx utilizado como *proxy* inverso y punto de entrada HTTPS del sistema. Es decir, la aplicación *web* no se comunica directamente con el exterior, sino que todas las peticiones pasan previamente por *Nginx*. Esto permite mejorar la seguridad y gestionar certificados TLS y balanceo de peticiones. Además, se incorporan volúmenes persistentes para almacenar datos de *PostgreSQL*, índices vectoriales de Qdrant, modelos descargados de Ollama y cachés de HuggingFace, evitando perder información al reiniciar los contenedores. La arquitectura también incluye comprobaciones automáticas de estado (*healthchecks*) y dependencias entre servicios para asegurar que cada componente esté disponible antes de iniciar los demás.

5.10. Integración CI/CD

Durante el desarrollo también se incorporaron mecanismos de **integración continua y automatización del flujo de desarrollo** mediante GitHub Actions.

En las primeras fases del proyecto, todas las comprobaciones del sistema se realizaban manualmente. Cada modificación requería ejecutar localmente las pruebas, comprobar dependencias y verificar manualmente el correcto funcionamiento de la aplicación. Conforme el proyecto fue creciendo, este enfoque comenzó a resultar poco escalable y propenso a errores.

Para mejorar este proceso se decidió incorporar un *pipeline* CI/CD utilizando GitHub Actions. La integración se configuró para ejecutarse automáticamente tanto al realizar *commits* sobre la rama principal (*main*) como al abrir o actualizar *pull requests*. De esta forma cada cambio realizado en el repositorio desencadena las comprobaciones de calidad del sistema.

El *pipeline* CI/CD comienza clonando el repositorio y configurando el entorno Python utilizado por el proyecto. Luego instala las dependencias definidas para el entorno Docker de producción. Esto garantiza que las comprobaciones se realicen en un entorno lo más parecido posible al despliegue real. Una vez preparado el entorno, se ejecutan de manera automática los *test* del proyecto mediante `unittest`. Además, durante la ejecución de las pruebas se calcula la cobertura de código utilizando `coverage.py`, generándose informes detallados sobre qué partes del sistema están siendo verificadas por los *tests* y cuáles no. Tras la ejecución de las pruebas, GitHub Actions integra automáticamente el proyecto con SonarCloud para realizar el análisis estático del código.

6. Trabajos relacionados

En este apartado se analizan diferentes trabajos y proyectos que, aunque no constituyen modelos RAG idénticos al desarrollado en este trabajo, comparten principios fundamentales relacionados con el uso de LLM, recuperación de información, agentes inteligentes y gestión de contexto. Su estudio permite contextualizar el proyecto dentro del marco actual de aplicaciones basadas en LLM y comprender distintas aproximaciones al diseño de inteligencias artificiales.

6.1. TFG relacionados

6.1.1. *Retrieval-Augmented Generation* para la Extracción de Información de Documentos Inteligente

En este TFG [19] se desarrolla un **sistema RAG orientado al ámbito sanitario** con el propósito de optimizar la recuperación y generación de información médica. El trabajo plantea una arquitectura basada en la recuperación y generación, que indexa documentación médica, crea *embeddings* y orquesta *prompts* para aportar contexto fiable al modelo generativo. Emplea técnicas de *chunking* con solapamiento y un enfoque **MultiQuery Retriever** para mejorar la cobertura y la precisión de la recuperación previa a la síntesis con un LLM. La solución se implementa sobre la API de Azure OpenAI, utilizando LangChain y FAISS como motor de búsqueda vectorial, e integra una interfaz web en Flask para simular consultas clínicas reales. Para la evaluación del sistema se emplea el *framework* RAGAS, valorando

métricas de precisión, relevancia y coherencia de las respuestas generadas, demostrando mejoras significativas frente a enfoques puramente generativos.

6.2. Proyectos relacionados

6.2.1. *LLM Twin Course: Building Your Production-Ready AI Replica*

Este proyecto [13] propone la construcción de un **asistente conversacional** que actúa como el usuario. Su objetivo principal es crear un sistema capaz de responder, razonar y comunicarse tal y como lo haría un usuario concreto. Para ello debe adaptarse al conocimiento, las preferencias y el estilo de dicho usuario. A nivel técnico, el proyecto emplea una arquitectura modular que combina los modelos LLM para la generación de respuestas, con sistemas de memoria persistentes, recuperación de información contextual y orquestación de flujos conversacionales. Uno de los aspectos más relevantes es la integración de memoria externa, que permite almacenar conocimiento personalizado y recuperarlo de manera dinámica durante la conversación. Aunque no se presenta como un RAG clásico tiene el mismo objetivo, ampliar la memoria paramétrica del modelo mediante información recuperada.

6.2.2. *Building Your Second Brain AI Assistant Using Agents, LLMs and RAG*

Este proyecto [14] plantea la creación de un **asistente para que organice, recupere y sintetice información personal o profesional**. Para realizar esto emplea técnicas de agentes inteligentes y RAG. Su arquitectura combina sistemas de recuperación semántica basados en *embeddings*, orquestación mediante agentes, gestión de memoria persistente e integración directa con LLM para síntesis de información. Para implementar el modelo RAG la información se indexa, se recupera según la consulta del usuario y se incorpora al *prompt* aumentado del modelo. A este flujo se le añaden agentes que coordinan las tareas de búsqueda, filtrado y razonamiento para ampliar las capacidades del sistema.

6.2.3. ChatALL

Este proyecto [9] consiste en diseñar una herramienta que **permite interactuar de manera simultánea con múltiples modelos de lenguaje** (LLM). Su objetivo principal es permitir la comparación de respuestas entre distintos LLM desde una única interfaz. Su arquitectura se centra en la orquestación de múltiples API de modelos, en la gestión concurrente de respuestas y en el desarrollo de una interfaz unificada para la conversación. Aunque no amplía el conocimiento del modelo mediante el uso de RAG es relevante como herramienta comparativa. Facilita evaluar el comportamiento de distintos LLM ante una misma consulta.

6.2.4. NotebookLM

NotebookLM⁹⁰ [24] [23] es una herramienta orientada a la **interacción inteligente con colecciones de documentos** proporcionados por el usuario. Permite cargar documentos, analizarlos y generar respuestas fundamentadas en su contenido. Se basa en la indexación de documentos, la recuperación contextual y la generación asistida por LLM. Implementa un modelo RAG ya que responde utilizando el contenido recuperado. Esto reduce las alucinaciones y mejora la respuesta.

6.3. Análisis de las características de los proyectos

En la tabla 6.1 se muestra una comparativa entre las características de los distintos proyectos explicados previamente y las del modelo RAG desarrollado en el TFG.

La comparativa realizada permite observar que PythIA adopta una aproximación intermedia entre los sistemas RAG clásicos orientados a recuperación documental y las soluciones comerciales más avanzadas. Frente a proyectos como *LLM Twin Course* o *Second Brain AI Assistant*, que están más orientados a asistentes personales y gestión general del conocimiento, PythIA se centra específicamente en la consulta inteligente de licitaciones públicas, incorporando una recuperación semántica especializada y adaptada

⁹⁰<https://notebooklm.google.com/notebook/4696bf9f-51cb-42c0-8805-401c6286dbec>

al dominio jurídico-administrativo. Frente a *ChatAll*, cuyo objetivo principal es comparar respuestas entre distintos modelos sin implementar recuperación documental, PythIA integra un sistema RAG completo con recuperación vectorial, uso de metadatos y trazabilidad de las respuestas. En comparación con *NotebookLM*, PythIA comparte características como la contextualización documental y la referencia a fuentes, aunque utiliza una arquitectura abierta y modular basada en tecnologías *open-source*, permitiendo el uso de modelos locales y configuraciones personalizadas.

Características	<i>LLM Twin Course</i>	<i>Second Brain AI Assistant</i>	<i>ChatAll</i>	<i>NotebookLM</i>	PythIA
Enfoque principal	Réplica digital personalizada	Gestión inteligente del conocimiento	Comparación de LLM	Consulta documental guiada	Consulta inteligente de licitaciones públicas
Uso de RAG	Clásico modular	Híbrido con agentes	✗	Propietario integrado	Clásico modular
<i>Chunking</i>	Tokens	Semántico	✗	Propietario	Híbrido (tokens + semántico previo)
Solapamiento	✓	✗	✗	No se sabe	✓
Recuperación semántica	Similitud vectorial	Similitud vectorial + agentes	✗	Contextual propietaria	Similitud coseno
Metadatos en recuperación	Parcial	✓	✗	✓	✓
Soporte multi LLM	Parcial	✓	✓	✗	✓
Uso de modelos locales	Opcional	Parcial	✓	✗	✓
Multiagente	✗	✓	✗	✗	✗
Trazabilidad respuesta	Parcial	Parcial	✗	✓	✓
Comparación de modelos	✗	✗	✓	✗	✓
Evaluación RAG	Limitada	Limitada	✗	Desconocido	✓

Tabla 6.1: Comparativa de las características de los proyectos.

7. Conclusiones y Líneas de trabajo futuras

El desarrollo de este Trabajo Fin de Grado ha permitido **diseñar, implementar y desplegar un sistema completo** basado en la técnica *Retrieval-Augmented Generation* (RAG) aplicado a la consulta inteligente de licitaciones públicas. El proyecto ha demostrado que la combinación de modelos de lenguaje de gran tamaño con sistemas de recuperación semántica permite superar gran parte de las limitaciones tradicionales de los LLM, especialmente aquellas relacionadas con el conocimiento estático, la falta de acceso a información específica y las alucinaciones generadas por el modelo.

Uno de los principales logros del proyecto ha sido la construcción de un *pipeline* completo de indexación documental capaz de automatizar la obtención de licitaciones públicas mediante técnicas de *Web Scraping*, procesar los documentos PDF, fragmentarlos en *chunks*, generar *embeddings* y almacenarlos en una base de datos vectorial Qdrant. Gracias a ello, el sistema es capaz de **recuperar información contextual relevante y utilizarla para enriquecer el contexto** del modelo de lenguaje.

A nivel técnico, el proyecto ha permitido profundizar en múltiples áreas de la Ingeniería Informática relacionadas con la inteligencia artificial, el procesamiento del lenguaje natural, las bases de datos vectoriales, el desarrollo *web* y el despliegue de aplicaciones en producción. La implementación de la aplicación *web* mediante Flask, junto con el uso de Docker, Gunicorn y Nginx, ha permitido construir un entorno reproducible, escalable y preparado para un despliegue real. Además, la integración de autenticación de usuarios, gestión documental, internacionalización, soporte *responsive* y

paneles de administración ha permitido transformar el prototipo inicial en una **aplicación funcional** y utilizable.

Otro aspecto especialmente relevante ha sido la incorporación de mecanismos automáticos de evaluación del sistema RAG mediante *frameworks* como RAGAS y ARES. Esto ha permitido analizar métricas relacionadas con la relevancia, fidelidad y precisión de las respuestas generadas, aportando una base objetiva para comparar configuraciones y mejorar el comportamiento del sistema. La evaluación ha puesto de manifiesto que la calidad final de las respuestas no depende únicamente del modelo LLM utilizado, sino también del proceso de *chunking*, de los *embeddings*, de la calidad de los documentos y de la estrategia de recuperación semántica empleada.

Durante el desarrollo del proyecto también se han identificado diversas dificultades técnicas. Una de las más importantes ha sido la gran heterogeneidad de formatos presentes en los documentos PDF de licitaciones, especialmente en el proceso de conversión automática a Markdown y detección de secciones. Esto ha demostrado que, aunque existen herramientas avanzadas de OCR y procesamiento documental, la extracción estructurada de información sigue siendo uno de los retos más complejos en sistemas RAG aplicados a documentación real.

Por otro lado, el proyecto ha permitido comprobar la importancia de una buena planificación incremental basada en metodologías ágiles como *Scrum*. La organización del desarrollo en *sprints* facilitó la adaptación continua del proyecto ante problemas técnicos, cambios en la página sobre la que se realiza el *Web Scraping* o modificaciones en las decisiones arquitectónicas tomadas inicialmente.

Desde un punto de vista personal y académico, este trabajo ha supuesto una oportunidad para aplicar de forma práctica numerosos conocimientos adquiridos durante el grado, así como para profundizar en tecnologías emergentes relacionadas con los LLM y los sistemas RAG. Además, el proyecto ha permitido adquirir experiencia en investigación, diseño de arquitecturas *software*, despliegue de aplicaciones, evaluación de sistemas de inteligencia artificial y documentación técnica de proyectos complejos.

7.1. Líneas de trabajo futuras

Aunque el sistema desarrollado cumple los objetivos planteados inicialmente, existen múltiples líneas de mejora y ampliación que podrían desarrollarse en trabajos futuros.

Una de las mejoras más importantes sería **optimizar el *pipeline* de recuperación semántica** incorporando técnicas avanzadas de *chunking* semántico y modelos de *reranking*. Actualmente, el sistema emplea recuperación semántica basada en similitud coseno sobre los *embeddings* almacenados en Qdrant, junto con filtros híbridos por número de expediente y tipo documental. Además, los fragmentos recuperados se ordenan según su puntuación de similitud antes de incorporarse al *prompt* del LLM. Sin embargo, la arquitectura no incorpora todavía una etapa de *reranking* semántico especializada. Como línea de trabajo futura, podría integrarse un modelo *Cross-Encoder* capaz de reevaluar y reordenar los *chunks* recuperados teniendo en cuenta conjuntamente la consulta del usuario y el contenido completo de cada fragmento. Esto permitiría mejorar significativamente la precisión contextual y la relevancia de las respuestas generadas, especialmente en consultas complejas, ambiguas o sobre documentos extensos donde múltiples fragmentos presentan similitudes vectoriales próximas.

Otra línea de desarrollo futuro podría ser incorporar **memoria conversacional** persistente. Actualmente, las consultas se procesan de forma independiente, aunque el sistema ya almacena historiales y resultados en base de datos. Una posible evolución consistiría en permitir conversaciones con contexto acumulado, de forma que el usuario pudiera realizar preguntas encadenadas sobre una misma licitación sin necesidad de repetir información previa.

A nivel de modelos de lenguaje, una posible mejora consistiría en incorporar **sistemas de inferencia** más eficientes que permitan ejecutar modelos de gran tamaño con menores requisitos *hardware*. Actualmente, el sistema integra Ollama con soporte configurable para CPU y GPU, así como carga dinámica de distintos modelos configurables desde variables de entorno. En este contexto, sería especialmente interesante investigar la integración del proyecto *AirLLM* [20], desarrollado para ejecutar modelos LLM de gran tamaño mediante técnicas de carga dinámica y reducción del consumo de memoria VRAM. Su integración permitiría utilizar modelos más avanzados manteniendo un consumo de recursos reducido, mejorando la escalabilidad y facilitando el despliegue en equipos con recursos limitados.

Otra línea de mejora especialmente relevante sería **ampliar el sistema de evaluación automática** ya implementado en el proyecto. Actualmente, el sistema incorpora métricas y herramientas de evaluación orientadas al análisis de relevancia y calidad de las respuestas generadas. Como evolución futura, sería especialmente interesante integrar el *framework DeepEval* [12], orientado específicamente a la evaluación y *benchmarking* de aplicaciones basadas en LLM y sistemas RAG. Esto permitiría automatizar pruebas de regresión, comparar modelos y configuraciones de recuperación, detectar degradaciones de calidad y construir un entorno de validación continua para futuras versiones del sistema.

A nivel documental, otra mejora importante consistiría en perfeccionar el procesamiento estructural de los PDF. Durante el desarrollo del proyecto se detectó que la gran heterogeneidad de formatos presentes en los pliegos, dificulta la extracción correcta de secciones y subsecciones. Como línea futura podrían investigarse técnicas multimodales, modelos OCR avanzados o herramientas de análisis estructural capaces de generar documentos Mark-down más precisos y estructurados. Esto permitiría enriquecer los metadatos asociados a cada *chunk* y mejorar la recuperación semántica.

Bibliografía

- [1] Alejandro Alija. Técnicas RAG: cómo funcionan y ejemplos de casos de uso. <https://datos.gob.es/es/blog/tecnicas-rag-como-funcionan-y-ejemplos-de-casos-de-uso>, 2024. [Online; Accedido 6-Febrero-2026].
- [2] Inc. Cloudflare. ¿Por qué el HTTP no es seguro? | HTTP vs. HTTPS. <https://www.cloudflare.com/es-es/learning/ssl/why-is-http-not-secure/>, 2026. [Online; Accedido 26-Febrero-2026].
- [3] Inc. Cloudflare. ¿Qué es un proxy inverso? | Servidores proxy explicados. <https://www.cloudflare.com/es-es/learning/cdn/glossary/reverse-proxy/>, 2026. [Online; Accedido 26-Febrero-2026].
- [4] Columbia University Mailman School of Public Health. Web Scraping. <https://www.publichealth.columbia.edu/research/population-health-methods/web-scraping>, -. [Online; Accedido 28-Septiembre-2025].
- [5] Shahul Es, Jithin James, Luis Espinosa Anke, and Steven Schockaert. RAGAs: Automated Evaluation of Retrieval Augmented Generation. pages 150–158, mar 2024. doi: 10.18653/v1/2024.eacl-demo.16. URL <https://aclanthology.org/2024.eacl-demo.16/>.
- [6] Pandora FMS. Qué es NAT y cómo actúa en nuestra red. <https://pandorafms.com/es/it-topics/que-es-nat/>, 2005-2026. [Online; Accedido 26-Febrero-2026].
- [7] Gobierno. ¿Qué es la contratación pública. <https://www.gobierno.es/blog/que-es-la-contratacion-publica>, 2024. [Online; Accedido 22-Febrero-2026].

- [8] Juan José Lozano Gómez. Tutorial de Flask en español: Desarrollando una aplicación web en Python. <https://j2logo.com/tutorial-flask-espanol/>, 2018-2025. [Online; Accedido 2-Diciembre-2025].
- [9] Peter Dave Hello. Chat with ALL AI Bots Concurrently, Discover the Best. <https://github.com/ai-shifu/ChatALL>, 2025. [Online; Accedido 21-Diciembre-2025].
- [10] Docker Inc. What is Docker?. <https://docs.docker.com/get-started/docker-overview/>, 2013-2026. [Online; Accedido 3-Febrero-2026].
- [11] GitHub Inc. Acerca de GitHub y Git. <https://docs.github.com/es/get-started/start-your-journey/about-github-and-git>, 2025. [Online; Accedido 22-Septiembre-2025].
- [12] Jeffrey Ip. The LLM Evaluation Framework. <https://github.com/confident-ai/deepeval>, 2026. [Online; Accedido 29-Abril-2026].
- [13] Paul Iusztin. LLM Twin Course: Building Your Production-Ready AI Replica. <https://github.com/decodingai-magazine/llm-twin-course?tab=readme-ov-file>, 2025. [Online; Accedido 9-Febrero-2026].
- [14] Paul Iusztin. Building Your Second Brain AI Assistant Using Agents, LLMs and RAG. <https://github.com/decodingai-magazine/second-brain-ai-assistant-course>, 2025. [Online; Accedido 9-Febrero-2026].
- [15] Paul Iusztin and Maxime Labonne. *The LLM Engineer's Handbook*. Packt Publishing, October 2024. ISBN 9781836200079. [Consultado 30-Octubre-2025 a 27-Noviembre-2025].
- [16] Abhinav Kimothi. *A Simple Guide to Retrieval Augmented Generation*. Manning Publications, July 2025. ISBN 9781633435858. [Consultado 8-Septiembre-2025 a 26-Septiembre-2025].
- [17] Martijn Koster, G. Illyes, H. Zeller, and L. Sassman. Robots Exclusion Protocol (RFC 9309). <https://datatracker.ietf.org/doc/html/rfc9309>, 2022. [Online; Accedido 07-Octubre-2025].
- [18] Tom Krant and Alexandra Jonker. ¿Qué es el envenenamiento de datos? <https://www.ibm.com/es-es/think/topics/data-poisoning>, 2024. [Online; Accedido 15-Mayo-2026].

- [19] Daniel Laparra Osca. Retrieval-Augmented Generation para la Extracción de Información de Documentos Inteligente. Trabajo fin de grado, Universitat Politècnica de València, Escuela Técnica Superior de Ingeniería de Telecomunicación, 2024. URL <https://riunet.upv.es/server/api/core/bitstreams/c775be7d-8724-476b-b0a4-73e055d03d50/content>. [Accedido 02-Octubre-2025].
- [20] Gavin Li. AirLLM. <https://github.com/lyogavin/airllm>, 2026. [Online; Accedido 25-Marzo-2026].
- [21] Lofred Madzou. What is the RAG Triad? <https://truera.com/ai-quality-education/generative-ai-rags/what-is-the-rag-triad/>. [Online; Accedido 24-Septiembre-2025].
- [22] Julia Martins. ¿Qué es la metodología Kanban y cómo funciona?. <https://asana.com/es/resources/what-is-kanban>, 2026. [Online; Accedido 27-Febrero-2026].
- [23] Emergent Mind. NotebookLM: Document-Grounded AI by Google. <https://www.emergentmind.com/topics/notebooklm>, 2025. [Online; Accedido 10-Febrero-2026].
- [24] Emergent Mind. NotebookLM Enterprise. <https://docs.cloud.google.com/gemini/enterprise/notebooklm-enterprise/docs/overview?hl=es>, 2026. [Online; Accedido 10-Febrero-2026].
- [25] W3C Working Group on Browser Testing and Tools. WebDriver — W3C Working Draft (Level 2). <https://www.w3.org/TR/webdriver2/>, 2025. [Online; Accedido 15-Octubre-2025].
- [26] Orange. Diferencias entre IP Pública e IP Privada. <https://ayuda.orange.es/particulares/internet-y-wifi/configuracion-e-instalacion/6860-diferencias-entre-ip-publica-e-ip-privada>, 2026. [Online; Accedido 26-Febrero-2026].
- [27] Selenium Project. Selenium Documentation. <https://www.selenium.dev/documentation/>, 2025. [Online; Accedido 10-Octubre-2025].
- [28] Ragas. Ragas Documentation. <https://docs.ragas.io/en/stable/>, 2025. [Online; Accedido 05-Octubre-2025].
- [29] Megan Rogge and microsoft. Visual Studio Code - Open Source (Code – OSS). <https://github.com/microsoft/vscode>, 2026. [Online; Accedido 27-Febrero-2026].

- [30] Jon Saad-Falcon, Omar Khattab, Christopher Potts, and Matei Zaharia. ARES: An Automated Evaluation Framework for Retrieval-Augmented Generation Systems. 2024. URL <https://arxiv.org/abs/2311.09476>. [Online; Accedido 05-Octubre-2025].
- [31] Josh Schneider and Ian Smalley. ¿Qué es un entorno de desarrollo integrado (IDE)?. <https://www.ibm.com/es-es/think/topics/integrated-development-environment>, 2018-2026. [Online; Accedido 27-Febrero-2026].
- [32] Ken Schwaber and Jeff Sutherland. The Scrum Guide. <https://scrumguides.org/docs/scrumguide/v2020/2020-Scrum-Guide-US.pdf>, 2020. [Online; Accedido 22-Septiembre-2025].
- [33] Q2B Studio. Por qué «Lost in the Middle» rompe la mayoría de los sistemas RAG. <https://www.q2bstudio.com/nuestro-blog/429461/descubre-por-que-lost-in-the-middle-puede-causar-problemas-en-los-sistemas-rag-y-como-evitarlos>, 2026. [Online; Accedido 15-Mayo-2026].
- [34] Microsoft Playwright Team. Playwright Documentation: Actionability. <https://playwright.dev/docs/actionability>, 2025. [Online; Accedido 10-Octubre-2025].
- [35] Joseph Wright. TEX on Windows: MiKTEX or TEX Live? *TUGboat*, 33(1):53, 2012. URL <https://www.tug.org/TUGboat/tb33-1/tb103wright.pdf>. [Online; Accedido 22-Septiembre-2025].
- [36] WSGI.org. WSGI. <https://wsgi.readthedocs.io/en/latest/>, 2016-2026. [Online; Accedido 25-Febrero-2026].
- [37] Zilliz. Qdrant vs. pgvector. <https://zilliz.com/comparison/qdrant-vs-pgvector>, 2025. [Online; Accedido 10-Noviembre-2025].