



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática



TFG del Grado en Ingeniería
Informática

Creación de *RAG* para pliegos
de la Diputación



Presentado por Lydia Blanco Ruiz
en Universidad de Burgos — 3 de junio
de 2026

Tutor: Álgvar Arnaiz González
y César Ignacio García Osorio



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática



Los doctores César Ignacio García Osorio y Álgvar Arnaiz González, profesores del departamento de Ingeniería Informática, área de Lenguajes y Sistemas Informáticos.

Exponen:

Que la alumna D^a. Lydia Blanco Ruiz, ha realizado el Trabajo final de Grado en Ingeniería Informática titulado Creación de *RAG* para pliegos de la Diputación.

Y que dicho trabajo ha sido realizado por la alumna bajo la dirección de los que suscriben, en virtud de lo cual se autoriza su presentación y defensa.

En Burgos, 3 de junio de 2026

Vº. Bº. del Tutor:

Vº. Bº. del co-tutor:

D. Álgvar Arnaiz González

D. César Ignacio García Osorio

Resumen

La contratación pública genera una gran cantidad de documentación técnica y administrativa cuya consulta manual resulta compleja debido a su volumen, heterogeneidad y especialización. En este Trabajo Fin de Grado se presenta PythIA, un sistema basado en la técnica *Retrieval-Augmented Generation* (*RAG*) diseñado para facilitar la consulta inteligente de las licitaciones públicas mediante el uso de modelos de lenguaje de gran tamaño (*LLM*).

El proyecto integra un *pipeline* completo de recuperación semántica capaz de automatizar la obtención de documentos mediante técnicas de *Web Scraping*, convertir los documentos PDF extraídos a formato **Markdown**, fragmentar el contenido en *chunks*, generar *embeddings* y almacenarlos en una base de datos vectorial **Qdrant**. A partir de las consultas realizadas por el usuario, el sistema recupera los fragmentos documentales más relevantes y los incorpora al contexto del modelo generativo para mejorar la precisión, actualidad y fiabilidad de las respuestas. Permitiendo analizar la relevancia, fidelidad y precisión de las respuestas generadas mediante la combinación de los *frameworks* **RAGAS** y **ARES** con métricas de *embeddings*.

Además del diseño e implementación del sistema *RAG*, el proyecto desarrolla una aplicación *web* utilizando **Flask**. Incorporando autenticación de usuarios, historial de consultas, gestión documental, internacionalización, visualización de estadísticas y soporte responsive. Desplegada mediante **Docker**, **Gunicorn** y **Nginx**.

El proyecto demuestra la viabilidad de aplicar arquitecturas *RAG* en entornos reales de documentación pública, reduciendo las limitaciones tradicionales de los *LLM* y facilitando el acceso contextualizado a grandes colecciones documentales.

Descriptores

Modelos de Lenguaje a Gran Escala, Generación Aumentada por recuperación, evaluación *RAG*, chunks, embeddings, búsqueda semántica, aplicación web, Flask, Web Scraping, licitaciones públicas, bases de datos vectoriales, Docker.

Abstract

Public procurement generates a large amount of technical and administrative documentation whose manual consultation is complex due to its volume, heterogeneity, and specialization. This Bachelor's Thesis presents PythIA, a system based on the Retrieval-Augmented Generation (*RAG*) technique designed to facilitate the intelligent consultation of public tenders through the use of Large Language Models (*LLMs*).

The project integrates a complete semantic retrieval pipeline capable of automating document acquisition through *Web Scraping* techniques, converting extracted PDF documents into **Markdown** format, splitting the content into *chunks*, generating *embeddings*, and storing them in a **Qdrant** vector database. Based on user queries, the system retrieves the most relevant document fragments and incorporates them into the context of the generative model to improve the precision, relevance, and reliability of the generated responses. In addition, the system enables the analysis of the relevance, faithfulness, and accuracy of the generated answers by combining the **RAGAS** and **ARES** frameworks with embedding-based metrics.

Besides the design and implementation of the *RAG* system, the project also develops a web application using **Flask**. The application incorporates user authentication, query history, document management, internationalization, statistics visualization, and responsive support. The entire system is deployed using **Docker**, **Gunicorn**, and **Nginx**.

The project demonstrates the feasibility of applying *RAG* architectures in real-world public documentation environments, reducing the traditional limitations of *LLMs* and facilitating contextualized access to large document collections.

Keywords

Large Language Models, Retrieval Augmented Generation, RAG evaluation, chunks, embeddings, semantics search, web application, Flask, Web Scraping, public tenders, vector databases, Docker.

Índice general

Índice general	iii
Índice de figuras	v
Índice de tablas	vi
1. Introducción	1
2. Objetivos del proyecto	5
2.1. Objetivos específicos	5
2.2. Objetivos personales	7
3. Conceptos teóricos	9
3.1. <i>Web Scraping</i>	9
3.2. <i>LLM</i>	10
3.3. <i>RAG</i>	11
3.4. Conexión del <i>LLM</i> con el <i>RAG</i>	13
3.5. Diseño del <i>RAG</i>	13
3.6. Evaluación de la calidad del <i>RAG</i>	18
4. Técnicas y herramientas	21
4.1. Metodologías	21
4.2. Repositorio	22
4.3. Gestión de tareas	23
4.4. $\text{\LaTeX}$	24
4.5. Entorno de desarrollo	24
4.6. Patrones de diseño	25

4.7. <i>Web Scraping</i>	26
4.8. Gestión de dependencias y entornos <i>Python</i>	26
4.9. Bases de datos	28
4.10. Desarrollo <i>web</i>	30
4.11. Evaluación de la calidad del código	31
4.12. Despliegue de la aplicación	31
5. Aspectos relevantes del desarrollo del proyecto	37
5.1. Inicio del proyecto	37
5.2. Web Scraping	38
5.3. <i>Retrieval Augmented Generation (RAG)</i>	39
5.4. Conversión a Markdown	46
5.5. Evaluación <i>RAG</i>	47
5.6. Tareas asíncronas	48
5.7. Desarrollo <i>web</i>	49
5.8. Evaluación de la calidad del código	52
5.9. Despliegue	53
5.10. Integración CI/CD	55
6. Trabajos relacionados	57
6.1. TFG relacionados	57
6.2. Proyectos relacionados	58
6.3. Análisis de las características de los proyectos	59
7. Conclusiones y Líneas de trabajo futuras	63
7.1. Líneas de trabajo futuras	65
Bibliografía	67

Índice de figuras

3.1. Diagrama del funcionamiento del <i>RAG</i>	12
3.2. Funcionamiento de un modelo <i>LLM</i> con <i>RAG</i> y otro sin él [1]. .	13
3.3. Tríada de evaluación TruEra.	19
4.1. Metodología <i>Scrum</i>	22
4.2. Relación entre las herramientas utilizadas para desplegar la aplicación <i>web</i>	32

Índice de tablas

4.1. Comparativa de Selenium y Playwright.	27
4.2. Comparativa de Qdrant y pgvector.	29
4.3. Comparativa de PostgreSQL y SQLite.	36
6.1. Comparativa de las características de los proyectos.	61

1. Introducción

La contratación pública [6] constituye uno de los pilares fundamentales del sector público. A través de este proceso, las administraciones adquieren bienes, servicios y obras necesarias para el desarrollo de sus competencias, garantizando los principios de transparencia, libre concurrencia, igualdad de trato y eficiencia en el uso de los recursos públicos. En España, este procedimiento se materializa en la publicación de licitaciones que incluyen pliegos administrativos y técnicos, resoluciones, anexos y diversa documentación normativa que regula cada contrato.

Sin embargo, aunque la información es pública y accesible, su volumen, complejidad técnica y extensión documental dificultan enormemente su creación, consulta y análisis. Los pliegos de contratación pueden superar fácilmente decenas o incluso cientos de páginas, contienen lenguaje jurídico-administrativo especializado y presentan estructuras heterogéneas. Para empresas licitadoras, profesionales del sector o incluso para ciudadanos interesados, localizar información concreta puede convertirse en una tarea lenta y costosa.

En este contexto surge la necesidad de herramientas inteligentes que permitan consultar grandes volúmenes de documentación pública de forma eficiente, precisa y contextualizada. Los modelos de lenguaje de gran tamaño (*LLM*) han demostrado un gran potencial para la generación de texto y la comprensión del lenguaje natural. Sin embargo, presentan limitaciones importantes, ya que su conocimiento es estático (fecha de corte), pueden generar respuestas incorrectas con aparente seguridad (alucinaciones) y no tienen acceso directo a información específica o actualizada, como documentos concretos de licitación.

Para solventar estas limitaciones, en este Trabajo Fin de Grado se ha desarrollado *PythIA*. Un proyecto que propone el diseño e implementación de un sistema basado en la técnica *Retrieval-Augmented Generation* (*RAG*), cuyo objetivo es combinar la capacidad generativa de un *LLM* con un sistema de recuperación semántica de información sobre una colección documental formada por licitaciones públicas. El sistema permite indexar automáticamente los documentos, fragmentarlos en unidades manejables (*chunks*), representarlos mediante vectores lineales (*embeddings*) y almacenarlos en una base de datos vectorial especializada (*Qdrant*). Ante una consulta del usuario, el sistema recupera los fragmentos más relevantes y los incorpora al *prompt* del modelo generativo, mejorando la precisión, actualidad y fiabilidad de la respuesta.

El proyecto no se limita al diseño conceptual del sistema *RAG*, sino que aborda su implementación completa en un entorno realista y desplegable. Para ello, se ha desarrollado una aplicación *web* con *Flask* que permite la interacción del usuario con el sistema de forma transparente, se integra una base de datos relacional para la gestión de usuarios y consultas, y se utiliza una base de datos vectorial (*Qdrant*) para la recuperación semántica. Además, se emplea *Docker* para garantizar la reproducibilidad del entorno y facilitar el despliegue de la aplicación en producción.

Este documento es la memoria principal del proyecto. En él se describe el contexto en el que surge el proyecto, y los objetivos que se persiguen conseguir. Se incluye una explicación de los fundamentos teóricos necesarios para comprender el proyecto, y de las herramientas empleadas para su desarrollo indicando el valor que aportan al proyecto frente a otras alternativas del mercado. También, se exponen los aspectos más relevantes que tuvieron lugar durante el desarrollo explicando sus dificultades y como se solventaron. Para poner en valor real el proyecto es importante conocer el estado del arte en el campo de los modelos de lenguaje alimentados con *RAG*, explicando y comparando el proyecto con otros similares ya existentes. Finalmente, se detallan las conclusiones obtenidas tras finalizar el proyecto y se proponen vías de mejoras para futuros desarrollos.

Junto con la memoria se entrega los siguientes materiales adjuntos:

- Documentación técnica: detallada en los anexos. En ella se describe la planificación temporal del proyecto, explicando la planificación de cada *sprint* y comparándola con lo que se realizó en realidad. Se realiza un estudio sobre la viabilidad del proyecto teniendo en cuenta tanto si es económicamente rentable como su viabilidad legal. Se

especifican tanto los requisitos, funcionales y no funcionales explicando de manera detallada los casos de uso del proyecto, como el diseño de las distintas partes de la aplicación (arquitectura, datos, procedimientos e interfaces). En este documento, también, se incluyen los manuales del programador y del usuario. Finalmente, se realiza un estudio sobre la sostenibilidad del proyecto.

- *PythIA*: página *web* del proyecto. Accesible a través de la dirección de dominio: <https://pythia.es/>
- Repositorio *GitHub*¹ del proyecto. Donde se encuentra el código, la documentación y el desarrollo del proyecto. Pudiendo verse en él la planificación, ya que cada *milestone* se corresponde con un *sprint*.
- Progreso del proyecto: ha sido gestionado utilizando *ZenHub*² mediante la utilización de un tablero *kanban*, los *story points* y de los *Milestone Burndown*. Este proyecto asociado al de *GitHub*.
El progreso del proyecto también puede verse en un *GitHub Project*³ asociado al repositorio de *GitHub*, en el cual puede observarse una tabla con las *issues* de cada *sprint* y un tablero *kanban*. Además en el apartado *insights*⁴ se han generado los *Burndown chart* de cada *sprint*.
- Informe de calidad: para analizar la calidad del código de la aplicación definitiva (la que se encuentra dentro de la carpeta *PythIA* en *GitHub*) se ha utilizado *SonarCloud*⁵.

¹https://github.com/lbr1014/TFG_RAG.git

²[https://app.zenhub.com/workspaces/tfgrag-68d94a186434450034791a44/
board](https://app.zenhub.com/workspaces/tfgrag-68d94a186434450034791a44/board)

³<https://github.com/users/lbr1014/projects/1>

⁴<https://github.com/users/lbr1014/projects/1/insights>

⁵https://sonarcloud.io/project/overview?id=lbr1014_TFG_RAG

2. Objetivos del proyecto

El objetivo principal del proyecto es diseñar e implementar un sistema de *Retrieval-Augmented Generation* (*RAG*) que permita enriquecer las respuestas de un modelo de lenguaje mediante la recuperación y utilización de información contextual proveniente de una colección documental.

2.1. Objetivos específicos

Los objetivos identificados en el presente trabajo fin de grado son los siguientes:

- Recopilar la colección documental.
 - Automatizar la obtención de los documentos (licitaciones del estado) a través de *Web Scraping*.
- Preprocesar la colección documental.
 - Convertir la colección documental (recopilada en PDF) a **Markdown**.
 - Normalizar y limpiar el texto eliminando ruido, caracteres no deseados y formatos inconsistentes..
 - Segmentar los documentos en fragmentos (*chunks*).
 - Generar *embeddings* para representar semánticamente los fragmentos.
 - Incorporar metadatos asociados a cada *chunk*.
- Implementar y gestionar un índice vectorial.
 - Almacenar los *embeddings* en una base de datos vectorial.

- Optimizar consultas de similitud para recuperar contexto relevante.
- Implementar mecanismos de búsqueda semántica mediante similitud coseno.
- Gestionar la persistencia y actualización de los *embeddings* conforme se incorporen nuevos documentos.
- Incluir mecanismos de evaluación automática del sistema *RAG*.
- Desarrollar la capa de interacción con el usuario
 - Transformar la consulta del usuario en su representación vectorial.
 - Recuperar los fragmentos más relevantes de la base de datos vectorial.
 - Utilizar los fragmentos recuperados para enriquecer el *prompt* del usuario y así construir el *prompt* aumentado que finalmente se pasa al *Large Language Model (LLM)*.
 - Integrar distintos modelos *LLM* y evaluar su comportamiento dentro del sistema *RAG*.
 - Mostrar la trazabilidad de la respuesta al usuario.
 - Implementar un historial de consultas.
- Desarrollar interfaz que facilite al usuario la interacción con el modelo para que el proceso de aumentado del *prompt* le sea transparente.
 - Desarrollar una aplicación *web* con *Flask* para que el usuario pueda interactuar con el modelo.
 - Implementar soporte *responsive* para distintos tamaños de pantalla.
 - Incorporar modo claro y oscuro.
 - Implementar internacionalización y soporte multilenguaje.
 - Incorporar autenticación, gestión de usuarios, recuperación de contraseña y control de acceso basado en roles.
 - Implementar paneles de administración para la gestión de documentos y usuarios.
 - Incorporar gráficos interactivos y estadísticas mediante D3.js.
 - Implementar tutoriales interactivos para mejorar la experiencia de usuario.
- Desplegar y mantener la aplicación
 - Levantar la aplicación *Flask* con *Docker* para la reproducibilidad y el correcto funcionamiento en distintos entornos.
 - Desplegar la aplicación en un entorno preparado para producción utilizando Gunicorn y Nginx.

- Garantizar la seguridad de las comunicaciones mediante certificados SSL/TLS.
- Asignar un dominio DNS a la aplicación para facilitar el acceso.
- Implementar análisis estático y evaluación de calidad del código mediante SonarCloud y Ruff.

2.2. Objetivos personales

- Adquirir conocimientos sobre los sistemas *RAG*, comprendiendo sus fundamentos, componentes y aplicaciones en el ámbito de la inteligencia artificial.
- Profundizar en el estudio de los modelos de lenguaje de gran tamaño (*LLM*).
- Desarrollar habilidades prácticas en la implementación de sistemas basados en *RAG* y *LLM*.
- Aprender a aplicar los sistemas *RAG* y los *LLM* en la resolución de problemas reales.
- Aplicar los conocimientos adquiridos durante la carrera.

3. Conceptos teóricos

En este apartado se van a definir los conceptos más relevantes a tener en cuenta sobre el proyecto, por lo cual se considera importante definir qué es el *Web Scraping*, qué es un *RAG* y cuáles son sus aportaciones más significativas a los *LLM* que ya existen. Además, se considera importante contextualizar su origen, y para ello se va a comenzar explicando que son los *LLM* y sus principales limitaciones.

3.1. *Web Scraping*

Web Scraping es el proceso automático de extraer información expuesta en páginas web y transformarla en datos estructurados. Se realiza mediante programas que descargan y analizan el código HTML o emulan la navegación de un usuario con un navegador controlado por código. Se apoya en técnicas de rastreo (*crawling*), *parseo* y normalización para preparar el dato para su análisis o integración en sistemas [24].

Existe una convención estándar, llamada *Robots Exclusion Protocol* (`robots.txt`), mediante la cual un servidor web indica qué *URLs* se deben evitar rastrear. En este archivo se especifica qué partes del sistema están permitidas o prohibidas para cada tipo de *bot*. Aunque, el incumplimiento de este protocolo no tiene consecuencias legales es éticamente correcto cumplirlo [16].

3.2. *LLM*

Los *Large Language Model (LLM)*, que se traduce como los grandes modelos del lenguaje, son modelos de aprendizaje automático que han sido entrenados con grandes conjuntos de datos generados por humanos. Estos datos se usan para encontrar patrones estadísticos y replicar nuestras habilidades lingüísticas. Por lo cual, se puede decir que en esencia son modelos de predicción del siguiente *token* o lo que es lo mismo de la siguiente palabra [15].

Algunos ejemplos de *LLM* son [ChatGPT \(OpenAI\)](https://chat.openai.com)⁶, [Claude \(Anthropic\)](https://claude.ai)⁷ o [Ollama \(Meta AI\)](https://ai.meta.com/llama/)⁸.

Las principales características de los *LLM* son las siguientes:

- Naturaleza de predicción del próximo *token*: como se ha mencionado anteriormente los *LLM* seleccionan la palabra más probable de una distribución. La elección de esta palabra se basa en los patrones estadísticos que ha aprendido con los datos del entrenamiento.
- Memoria paramétrica: es el conocimiento interno del *LLM*. Consiste en la información con la que ha sido entrenado y se basa únicamente en sus parámetros. Por lo cual es una memoria limitada y estática.

Las principales limitaciones de los *LLM* son las siguientes:

- Desactualizado: los *LLM* solo pueden acceder a la información presente en sus datos de entrenamiento, que tienen una fecha límite específica conocida como «fecha de corte del conocimiento». Cualquier evento, descubrimiento o información posterior a esta fecha no estará disponible para el modelo, lo que puede generar respuestas desactualizadas. Además, el entrenamiento de un *LLM* es muy costoso y requiere mucho tiempo, por lo que estos modelos no se reentrenan con frecuencia, perpetuando esta limitación temporal.
- Alucinaciones: a veces los *LLM* dan respuestas incorrectas con gran confianza de manera que parece que la información que te está proporcionando es verdadera. Esto se debe a su naturaleza de predicción del próximo *token*.

⁶<https://chat.openai.com>

⁷<https://claude.ai>

⁸<https://ai.meta.com/llama/>

- Limitación de conocimiento: los *LLM* se entrenan con datos públicos, lo que limita su conocimiento, ya que no tienen conocimientos de información que no sea pública, como, por ejemplo, documentos internos de una empresa, información de los clientes o de los productos.

Para solventar las limitaciones que se han comentado, la solución es darle al *LLM* el contexto que le falta. El contexto del *LLM* es la información no paramétrica que se le proporciona en la consulta o *prompt* para que el modelo genere una respuesta más precisa, actual y fundamentada. Para proporcionarle este contexto se puede expandir la memoria del *LLM* mediante generación aumentada, es decir, incorporando un *RAG*.

3.3. *RAG*

Retrieval Augmented Generation (RAG), o en español, generación aumentada por recuperación, es una técnica que consiste en recuperar la información que sea relevante de una fuente externa. Con dicha información se aumenta la entrada al *LLM*, lo que permite que el *LLM* genere una respuesta mucho más precisa, contextual y confiable (ver pasos en la imagen 3.1). Para realizar esto, el *RAG* usa tres pasos: recuperar, aumentar y generar.

El *RAG* combina dos tipos de memoria:

- La memoria paramétrica: es la que típicamente tienen los *LLM*, que como se ha visto es limitada al conocimiento disponible en el momento del entrenamiento y estática.
- La memoria no paramétrica: es información externa al *LLM* que se le puede proporcionar. Es un conocimiento externo y dinámico que se puede extender tanto como se desee y que puede contener documentos propietarios.

Por lo cual conociendo esto, se puede decir que la generación aumentada por recuperación (*RAG*) es una metodología que busca ampliar la memoria paramétrica de un *LLM* incorporando una memoria no paramétrica explícita. A través de un recuperador, se obtiene información relevante de esta memoria externa, la cual se añade al *prompt* y luego se envía al *LLM*. De esta forma, el modelo puede producir respuestas más contextuales, confiables y precisas [15].




Figura 3.1: Diagrama del funcionamiento del *RAG*.

Los objetivos de *RAG* son:

- Hacer que los *LLM* respondan con información actualizada.
- Hacer que los *LLM* respondan información precisa, contextual y confiable.
- Hacer que los *LLM* conozcan información propietaria.

Las principales ventajas de *RAG* son:

- Conocimiento del contexto profundo: esto se debe a que la información adicional ayuda al *LLM* a generar respuestas contextualmente apropiadas, ya que, las respuestas se basan en datos específicos. Esto aumenta la confianza del usuario.
- Citar fuentes: como la información se extrae de fuentes conocidas las puede citar en su respuesta. Esto dispara la fiabilidad y permite a los usuarios comprobar la información obtenida.
- Reduce las alucinaciones: el sistema está anclado a los hechos, por lo que se reducen las respuestas inexactas o falsas.




Figura 3.2: Funcionamiento de un modelo *LLM* con *RAG* y otro sin él [1].

3.4. Conexión del *LLM* con el *RAG*

El primer paso es el de recopilar los documentos externos y convertirlos a vectores numéricos (*embeddings*) y almacenarlos. Cuando llega una consulta (*prompt*), en lugar de buscar coincidencias por palabras, se busca en ese espacio vectorial los fragmentos que son semánticamente más parecidos. A esto se le conoce como búsqueda por significado. Esos fragmentos se incorporan como contexto al *LLM*, de modo que el *RAG* combina la capacidad de razonamiento del modelo con una recuperación de información altamente precisa. En la imagen 3.2 se puede ver la diferencia de funcionamiento entre un modelo que emplea *RAG* y uno que no lo hace [1].

3.5. Diseño del *RAG*

Un sistema *RAG* se construye en dos *pipelines* complementarios, el de indexación (*offline*/asíncrono), y el de generación (*online*/ tiempo real). El primero crea y mantiene la memoria no paramétrica o base de conocimiento. El segundo gestiona la interacción con el usuario, realizando la recuperación, el aumento del *prompt* y la generación de la respuesta. Esta separación

es estructural en el diseño de *RAG* y permite optimizar la precisión y la latencia del sistema [15].

***Pipeline* de indexación (*offline*)**

Su objetivo es consolidar y preparar el conocimiento para que el *pipeline* de generación pueda consultarlo eficientemente. Consta de cinco pasos:

1. Conectarse a las fuentes externas.
2. Extraer y *parsear* los documentos.
3. Dividir textos largos en fragmentos más pequeños denominados *chunks*.
4. Convertir los *chunks* a un formato adecuado.
5. Almacenar en una base de datos vectorial los *embeddings*.

Además de crearlo, este *pipeline* mantiene y actualiza el conocimiento base, por lo que debe ejecutarse de forma periódica [15].

Los componentes clave del *pipeline* de indexación son:

- Carga de datos (*data loading*): consiste en conectarse a las fuentes, por ejemplo, sistemas de ficheros, *data lakers*, CMS o APIs, para la extracción del texto en bruto y el parsing de este en formatos heterogéneos, como pueden ser PDF, DOCX, JSON o HTML. Luego se le añaden metadatos y finalmente se hace limpieza quitando código, etiquetas raras y enmascarando datos confidenciales.
- División de texto (*chunking*): segmentación en unidades manejables, los *chunks*, para mejorar la recuperación y el alineamiento con las capacidades de contexto *LLM*. Ayuda a respetar la ventana de contexto, mitiga el problema de pérdida en el medio⁹ y facilita la búsqueda eficiente. Para dividir el texto puede usar diversos métodos:
 - Tamaño fijo: divide el texto en longitudes uniformes, como un número de caracteres o *tokens*.
 - Especializados: divide el texto basándose en su estructura como encabezados o párrafos.
 - Semántico: divide el texto basándose en su similitud de significado usando *embeddings*, aunque este método aun es experimental.

⁹El problema de la pérdida en el medio ocurre cuando los LLM pierden precisión al procesar mucha información, priorizando el inicio y el final [33].

La estrategia elegida dependerá del tipo de contenido, la longitud y complejidad de la consulta, el caso de uso y el modelo de *embeddings*.

- Conversión a vectores (*embeddings*): transforma el texto a representaciones numéricas de n dimensiones. Para conocer si los *chunks* se parecen a la consulta, el sistema mide la distancia entre sus vectores, ya que la proximidad refleja similitud semántica. Hay diversas técnicas para medir la distancia entre los vectores, una de las más utilizadas es la similitud coseno que consiste en que si el ángulo entre dos vectores es muy pequeño su similitud es casi uno, pero hay otras como la distancia euclidiana. Hay modelos preentrenados abiertos y propietarios, la elección dependerá de su uso, rendimiento, recuperación y coste.
- Almacenamiento: los *embeddings* se almacenan en bases de datos vectoriales diseñadas para vectores de altas dimensiones. Estas bases de datos vectoriales permiten la búsqueda eficiente sobre *embeddings* y metadatos. Hay diversas opciones:
 - Índices vectoriales: son bibliotecas mínimas centradas en indexación y búsqueda de alta dimensión, no gestionan datos ni ofrecen consultas ricas o interfaces de bases de datos. Ejemplos: [FAISS¹⁰](#), [NMSLIB¹¹](#), [ANNOY¹²](#), [ScaNN¹³](#). Son útiles cuando se desea máximo control y rendimiento sin sobrecarga de base de datos.
 - Bases de datos vectoriales especializadas: añaden a lo anterior gestión de datos, seguridad, escalado, extensibilidad y metadatos, manteniendo búsqueda/similitud vectorial eficiente. Ejemplos: [Pinecone¹⁴](#), [ChromaDB¹⁵](#), [Milvus¹⁶](#), [Qdrant¹⁷](#).
 - Plataformas de búsqueda: son motores de texto tradicional ([Solr¹⁸](#), [Elasticsearch¹⁹](#), [OpenSearch²⁰](#), [Lucene²¹](#)) que han incorporado similitud vectorial a sus capacidades.

¹⁰<https://faiss.ai/index.html>

¹¹<https://nmslib.github.io/nmslib/>

¹²<https://github.com/spotify/annoy>

¹³<https://milvus.io/docs/es/scann.md>

¹⁴<https://www.pinecone.io/>

¹⁵<https://www.trychroma.com/>

¹⁶<https://milvus.io/es>

¹⁷<https://qdrant.tech/>

¹⁸<https://solr.apache.org/>

¹⁹<https://www.elastic.co/es/enterprise-search/vector-search>

²⁰<https://opensearch.org/platform/vector-search/>

²¹<https://lucene.apache.org/core/>

- Motores SQL/NoSQL con capacidad vectorial: son bases de datos ya existentes que añaden tipos y operadores vectoriales. Ejemplos: [Azure SQL](#)²², [PostgreSQL/pgvector](#)²³ o en NoSQL [MongoDB](#)²⁴. Son útiles para consolidar datos, pero son menos especialización que una vector DB dedicada.
- Bases de datos gráficas con funciones vectoriales: grafos como [Neo4j](#)²⁵ que añaden búsqueda vectorial. Permiten combinar relaciones explícitas (grafos) con similitud semántica (vectores). Ejemplos: *path finding* sujeto a similitud.

Cuando la recuperación se externaliza, es decir, cuando la búsqueda y obtención de información no la realiza el sistema sobre su propia base vectorial, sino que se delega en un tercero (como por ejemplo una API) o en el documento que aporta el usuario, no es imprescindible construir un *pipeline* de indexación ni mantener una base vectorial. En cambio, en un *RAG* clásico, donde el sistema recupera conocimiento de su repositorio interno, sí se recomienda diseñar el *pipeline* de indexación y mantener una base vectorial propia [15].

***Pipeline* de generación (*online*)**

Gestiona la consulta del usuario de extremo a extremo. Este *pipeline* recibe la pregunta del usuario, recupera el contexto relevante de la base de datos vectorial, los *chunks*, aumenta el *prompt* con ese contexto y genera la respuesta con el *LLM*. Se compone de tres fases: *retrieval*, *augmentation* y *generation* [15].

Los componentes clave del *pipeline* de generación son:

- *Retriever*: es el motor de búsqueda sobre la base vectorial, es decir, la base de conocimiento. Devuelve los documentos más relevantes. Es crítico para la precisión del sistema y contribuye a la latencia, su calidad condiciona el rendimiento del *RAG*. El método más frecuente son los *embeddings* gracias a su capacidad semántica.
- Gestión del *prompt* (*Augmentation*): combina la consulta y el contexto recuperado. Además, aplica estrategias de ingeniería de *prompt* para

²²<https://azure.microsoft.com/es-es/products/azure-sql/database>

²³<https://www.postgresql.org/about/news/pgvector-070-released-2852/>

²⁴<https://www.mongodb.com/>

²⁵<https://neo4j.com/>

maximizar la calidad de la respuesta. Las estrategias recomendadas son:

- *Contextual prompting*: consiste en instruir al modelo para que solo responda con el contexto proporcionado.
 - *Controlled generation prompting*: consiste en indicarle al modelo que no conteste si el contexto no permite responder a la pregunta.
 - *Few-shot prompting*: consiste en incluir ejemplos para forzar el formato de la respuesta.
 - *Chain-of-thought*: consiste en pedir pasos intermedios cuando los razonamientos son complejos.
- Configuración *LLM (Generation)*: es la selección del modelo que va a generar la respuesta final. Pueden ser modelos:
- Originales o *fine-tuned*: los originales facilitan un arranque rápido, mientras que los *fine-tuned* mejoran la adaptación de dominio, la integración del contexto y formato de salida.
 - Abiertos o propietarios: los abiertos ofrecen control y despliegue flexible, mientras que los propietarios simplifican el uso y el mantenimiento.
 - Tamaño del modelo: los grandes tienen un razonamiento mejor y un contexto más amplio. Los pequeños tienen un coste y latencia menor.

Capas de soporte

Además de los dos *pipelines*, un sistema en producción requiere orquestación, evaluación y monitorización continua, caché semántico para reducir coste y latencia, controles de seguridad para cumplimiento normativo y seguridad frente a inyecciones en el *prompt*, envenenamiento de dato²⁶ o fugas de información. Todo ello se sostiene sobre una infraestructura de servicio y un *RAGOps stack* formado por capas críticas, esenciales y de mejora que aseguran operación, calidad y seguridad extremo a extremo [15].

1. Capas críticas: son las capas imprescindibles del *RAGOps stack*.

- Capa de datos: es la encargada de crear la base de conocimiento, para ello recolecta datos desde sistemas origen, los transforma y los almacena.

²⁶El envenenamiento de datos es un ciberataque que corrompe los conjuntos de datos de entrenamiento utilizados para el proceso de entrenamiento del modelo de Inteligencia Artificial [17].

- Capa de modelos: se incluyen los modelos de embeddings, de los LLM y de las tareas. Incluye el entrenamiento y la optimización de inferencia.
 - Despliegue de modelos: pueden ser servicios gestionados, auto-hospedados o locales.
 - Orquestación de la aplicación: se encarga de coordinar la consulta, la recuperación de datos y la generación. Incluye soporte multiagente y automatización de flujos de trabajo.
2. **Capas esenciales:** son las capas que necesita el sistema, se encargan del rendimiento, la fiabilidad y de la seguridad.
- Capa de *prompt*: diseño, versión y evaluación de *prompts* para guiar al *LLM* y reducir las alucinaciones.
 - Capa de evaluación: se encarga de medir, de forma periódica, la relevancia del contexto, fidelidad y relevancia de la respuesta.
 - Capa de monitorización: observa el proceso del *RAG* para encontrar fallos. Para ello monitoriza la latencia y el error.
 - Seguridad y privacidad del *LLM*: es la encargada de emplear métodos para evitar el *prompt injection*. Algunos de los métodos que se emplean son validar las entradas, realizar encriptados y emplear control de accesos.
 - Capa de caché: emplea caché para reducir los costes y la latencia en consultas frecuentes.
3. **Capas de mejora:** son capas opcionales que pueden aportar beneficios dependiendo del caso de uso. Se centran en la eficiencia, usabilidad y escalabilidad del sistema.

3.6. Evaluación de la calidad del *RAG*

Se suele hacer mediante la tríada de evaluación propuesta por TruEra [20] (ver imagen 3.3). Estructura la calidad en tres comprobaciones entre consulta (*prompt*), contexto recuperado y respuesta. Complementariamente, se emplean métricas como relevancia, precisión y *recall*, y conjuntos *ground truth* para validación objetiva y monitorización continua en producción [15].

Las tres dimensiones de la tríada son:

- Relevancia del contexto: la información que se haya recuperado tiene que ver con la pregunta.



Figura 3.3: Tríada de evaluación TruEra.

- *Groundedness* o fidelidad: la respuesta que da el *LLM* se basa de verdad en el contexto que le hemos dado, sin alucinaciones ni omisiones clave.
- Relevancia de la respuesta: la respuesta es útil y adecuada respecto a la intención y el contexto de la consulta original.

Aparte de las dimensiones de la tríada, otros aspectos relevantes que el sistema debe incorporar son:

- Robustez al ruido: el sistema debe distinguir aquellos documentos relacionados pero que sean poco útiles.
- Rechazo en negativo: el sistema no debe responder cuando no hay evidencias relevantes.
- Integración de información: el sistema debe ser capaz de sintetizar múltiples documentos que posean información relevante.
- Robustez contrafactual: el sistema tiene que detectar y evitar la información inexacta en el propio *knowledge base*.

Hay dos herramientas principales de evaluación:

- *Retrieval-Augmented Generation Assessment* (**RAGAs**²⁷) [4]: es un *framework* que genera datos sintéticos y calcula métricas de la tríada. Es útil para ciclos rápidos [28].
- *Automated RAG Evaluation System* (**ARES**²⁸) [30]: es un *framework* con un funcionamiento similar al RAGAs, pero con mayor complejidad y cantidad de datos generados. Es más robusto.

²⁷<https://github.com/vibrantlabsai/ragas>

²⁸<https://github.com/stanford-futuredata/ARES>

4. Técnicas y herramientas


En este apartado se va a realizar una breve explicación de la metodología empleada, así como de las herramientas utilizadas para el desarrollo del proyecto. En dicha explicación se va a incluir una comparación con otras herramientas similares en la cual se muestre el motivo de la selección de dicha herramienta.

4.1. Metodologías

Para llevar a cabo el proyecto se han seguido diversas metodologías de desarrollo ágil. Estas metodologías definen la forma en la que se planifica, organiza y gestiona el desarrollo de un proyecto, permitiendo estructurar las tareas, coordinar el progreso y mejorar la calidad del resultado.

Scrum

Scrum es un marco de trabajo ágil orientado a la gestión y desarrollo de proyectos de manera iterativa e incremental. Se organiza en ciclos cortos denominados *sprints*, al final de los cuales se entrega un incremento funcional del producto (ver imagen 4.1 para ver el proceso *Scrum* completo). Estos *sprints* favorecen la mejora continua y la adaptación al cambio, además, aseguran una entrega temprana de valor. A diferencia de metodologías tradicionales, *Scrum* aporta mayor flexibilidad y retroalimentación constante [32].

Figura 4.1: Metodología *Scrum*.

Kanban

Para la gestión del flujo de trabajo y organización de tareas se ha adoptado la metodología **Kanban** [21]. La cual consiste en un enfoque ágil orientado a la visualización del trabajo, la optimización del flujo y la mejora continua. Se basa en la idea de que el trabajo debe gestionarse como un flujo continuo en lugar de dividirse en iteraciones cerradas. Se centra en representar el estado de las tareas de forma visual, lo que facilita la planificación, el seguimiento y la detección de cuellos de botella. Este enfoque es útil en proyectos de desarrollo *software* en los que los requisitos puedan evolucionar, haciendo necesario tener una planificación flexible.

4.2. Repositorio

Para alojar el repositorio se han valorado distintas alternativas como **Bitbucket**²⁹, **GitHub**³⁰, **GitLab**³¹ o **Trello**³². Finalmente se ha elegido

²⁹<https://bitbucket.org/>

³⁰<https://github.com/>

³¹<https://gitlab.com/>

³²<https://trello.com/>

GitHub que es una plataforma basada en la nube que permite alojar repositorios de código. GitHub ofrece funciones muy útiles como ramas (*branches*), *pull requests*, seguimiento de cambios (*commits*), historial del proyecto, gestión de incidencias (*issues*). Además, permite la colaboración entre usuarios, lo que es muy útil para la revisión del proyecto.

Otra ventaja es que GitHub es compatible con herramientas de integración y despliegue continuo (Github Actions), lo que facilita la automatización de pruebas y la entrega de *software*. Asimismo, permite incluir documentación directamente en el repositorio, ya sea mediante archivos README o a través de *wikis*, lo que mejora la claridad y la reproducibilidad del trabajo. Finalmente, al tratarse de la plataforma más utilizada a nivel mundial, cuenta con abundante documentación, lo que la convierte en una alternativa sólida y con amplio soporte [10].

4.3. Gestión de tareas

Para la gestión de las tareas del proyecto se han valorado diversas herramientas, como ZenHub³³, GitHub Projects³⁴ o Asana³⁵. Principalmente se ha optado por usar ZenHub que es una herramienta de gestión de proyectos fácilmente integrable con GitHub. Debido a que tiene mayor funcionalidad que GitHub Projects. Ambos permiten hacer tableros Kanban para organizar las tareas (*to-do*, *in progress*, *doing*). Pero, ZenHub, además, permite asignar *story points* a las tareas y generar los gráficos *burndown* de los *sprints* de manera sencilla. Sin embargo, también se ha asociado un GitHub Project en el cual se ha definido una tabla que organiza las tareas por *sprints* y se han guardado los *Burndown* de cada *sprint*, así como, otras gráficas de interés.

³³<https://www.zenhub.com/>

³⁴<https://github.com/>

³⁵<https://asana.com/es>

4.4. L^AT_EX

Para la edición de los documentos en L^AT_EX se ha considerado usar **T_EXMaker**³⁶, **T_EXStudio**³⁷, **Visual Studio Code**³⁸ y **Overleaf**³⁹. Finalmente se ha optado por usar T_EXMaker, ya que es un editor multiplataforma, gratuito y de código abierto. Tiene un visor PDF integrado, así como herramientas para gestionar la bibliografía mediante BibT_EX. Además, tiene una interfaz simple que facilita el aprendizaje, incorpora funciones como el auto-completado, el plegado de código y la detección de errores de compilación, sin necesidad de instalar complementos adicionales.

Como distribución L^AT_EX para procesar los documentos `.tex` se ha valorado el uso de **MikT_EX**⁴⁰ y **T_EXLive**⁴¹, al final se ha elegido usar MikT_EX ya que permite realizar una instalación mínima e ir añadiendo automáticamente los paquetes necesarios durante la compilación. Además, presenta un buen soporte para Windows, lo que se adapta bien a mi entorno de trabajo [35].

4.5. Entorno de desarrollo

Para el desarrollo del proyecto se ha utilizado **Visual Studio Code**⁴² [29] como entorno de desarrollo integrado (IDE) [31]. Un IDE es una aplicación que integra en un único entorno herramientas esenciales para el desarrollo de software, como editor de código, compilador, depurador y utilidades de automatización.

Visual Studio Code es un editor de código fuente multiplataforma, gratuito y muy utilizado en el ámbito profesional. Se ha seleccionado frente a otras alternativas como **PyCharm**⁴³ o entornos más pesados debido a su flexibilidad, su facilidad para incorporar extensiones y su buena integración con herramientas modernas de desarrollo como son Git, Docker y Poetry. Permitiendo mantener un entorno de desarrollo coherente, modular y fácilmente reproducible.

³⁶<http://www.xmlmath.net/texmaker/>

³⁷<https://www.texstudio.org/>

³⁸<https://code.visualstudio.com/>

³⁹<https://es.overleaf.com/>

⁴⁰<https://miktex.org/>

⁴¹<https://www.tug.org/texlive/>

⁴²<https://code.visualstudio.com/>

⁴³<https://www.jetbrains.com/es-es/pycharm/>

4.6. Patrones de diseño

Durante el desarrollo del sistema se han aplicado distintos patrones de diseño *software* con el objetivo de mejorar la modularidad, reutilización, mantenibilidad y eficiencia de la aplicación.

Patrón *Singleton*

El patrón **Singleton** es un patrón de diseño creacional cuyo objetivo es garantizar que una clase tenga una única instancia durante toda la ejecución de la aplicación, proporcionando además un punto global de acceso a dicha instancia. Este patrón resulta especialmente útil cuando se trabaja con recursos costosos de inicializar o que deben compartirse entre múltiples componentes del sistema.

En el proyecto se ha elegido utilizar un patrón de diseño **Singleton** para gestionar los componentes del *RAG* cuya creación tiene un elevado coste computacional o de memoria, como el modelo de generación de *embeddings* mediante **SentenceTransformers**, la conexión con la base de datos vectorial **Qdrant** y la gestión del cliente de comunicación con **Ollama**.

Como alternativa se valoró utilizar una inicialización desacoplada basada en inyección de dependencias (*Dependency Injection*). Este enfoque aporta una mayor flexibilidad y facilita las pruebas unitarias, ya que permite sustituir fácilmente las dependencias por objetos simulados (*mocks*).

Otra alternativa considerada fue utilizar variables globales simples para almacenar los recursos compartidos. Aunque esta solución es más sencilla, presenta inconvenientes importantes relacionados con el acoplamiento, la mantenibilidad y el control del ciclo de vida de los objetos.

Sin embargo, para este proyecto se optó por una aproximación basada en **Singleton** debido a que su utilización evita realizar inicializaciones repetidas de modelos de inteligencia artificial, conexiones de red o clientes pesados cada vez que se procesa una consulta. Esto reduce considerablemente el consumo de memoria, disminuye la latencia y mejora el rendimiento general del sistema. Además, permite centralizar la configuración de dichos recursos, facilitando el mantenimiento y la coherencia interna de la aplicación.

4.7. *Web Scraping*

Para el *web scraping* se ha valorado usar **Selenium**⁴⁴ y **Playwright**⁴⁵. **Selenium** [27] controla navegadores reales y es un estándar veterano, pero **Playwright** [34] es más completo. Ya que ofrece automatización multi-navegador con contextos aislados, funcionamiento *headless*, espera automática de elementos y API consistentes, lo que lo vuelve más robusto y rápido para páginas con JavaScript pesado y flujos de *login*. En la tabla 4.1 se muestran las ventajas y desventajas de cada uno.

Tras probar ambos, en una fase inicial del *web scraping*, se vio que **Selenium** sigue siendo una apuesta segura, para *scraping* moderno con multiples sesiones y depuración rápida Sin embargo, **Playwright** requiere menos código y es más robusto, en su modo asíncrono gestiona de manera autónoma las esperas y los reintentos.

4.8. Gestión de dependencias y entornos *Python*

El proyecto requiere entornos aislados y reproducibles que faciliten el trabajo local, la integración continua y la generación de entregables. Se ha valorado utilizar **Poetry**⁴⁶ y *uv*⁴⁷. **Poetry** es una herramienta madura de gestión de dependencias y empaquetado que centraliza la configuración en `pyproject.toml`. Crea y gestiona entornos virtuales de forma automática, mantiene un archivo de bloqueo (`poetry.lock`) para asegurar instalaciones deterministas, permite definir grupos de dependencias, así como, generar de manera automática el `requirements.txt`. Por su parte *uv* es un gestor rápido que, al igual que **Poetry**, tiene soporte para `pyproject.toml`. Posee un buen rendimiento y una elevada velocidad gracias al uso de cachés eficientes. Finalmente, se ha optado por usar **Poetry** por su cobertura integral del ciclo de vida dentro de un flujo coherente y estable.

⁴⁴<https://selenium-python.readthedocs.io/>

⁴⁵<https://playwright.dev/>

⁴⁶<http://python-poetry.org/docs/>

⁴⁷<https://docs.astral.sh/uv/>

Herramienta	Ventajas	Desventajas
Selenium	Utiliza el estándar W3C WebDriver [25], lo que aporta interoperabilidad y soporte a largo plazo. Multilenguaje y ecosistema maduro. Permite una integración fácil. Es robusto para escalado distribuido.	Es propenso a fallos (<i>flakiness</i>) si no se dominan las esperas. La intercepción de red es menos homogénea entre navegadores.
Playwright	Es muy estable y rápido en webs con JavaScript pesado. Presenta multitud de herramientas integradas como Trace Viewer, capturas de pantalla y videos. Contiene selectores potentes y permite manejar los <i>inframes</i> de forma sencilla. Tiene un control de contexto aislado muy cómodo. Su modelo asíncrono permite realizar acciones concurrentes sin bloquear el hilo empleando la API <i>async/await</i> .	No utiliza el estándar WebDriver.

Tabla 4.1: Comparativa de Selenium y Playwright.

4.9. Bases de datos

Para el desarrollo del sistema *RAG* es necesario contar con dos tipos de bases de datos, una base de datos vectorial (ver sección 4.9.1) y una relacional (ver sección 4.9.2). La base de datos vectorial permite almacenar, indexar y buscar semánticamente en los documentos para dar respuestas precisas y rápidas. La base de datos relacional que permite gestionar la información de la aplicación (los datos de los usuarios, los documentos, las consultas, los *chunks* y los *embeddings*).

Base de datos vectorial

Una parte fundamental del desarrollo del *RAG* es la implementación de la base de datos vectorial. Se han valorado emplear diversas bases de datos, pero las dos que más se han estudiado son **Qdrant**⁴⁸ y **pgvector**⁴⁹. **Qdrant** [27] es una base de datos vectorial especializada, diseñada desde cero para búsquedas de similitud de alta concurrencia y baja latencia. Presenta equilibrio entre el rendimiento, la latencia y el tiempo de indexado [14]. Por su parte, **pgvector** [34] es una extensión de **PostgreSQL**⁵⁰ que permite almacenar embeddings en columnas vectoriales y realizar búsquedas de similitud sobre una base de datos relacional ya existente. Es útil cuando la aplicación ya se apoya en este gestor, ya que simplifica la infraestructura [37]. En la tabla 4.2 se muestran las principales ventajas y desventajas de cada opción.

Para realizar el proyecto se ha optado por utilizar **Qdrant**. Aunque **pgvector** presenta características interesantes cuando se desea mantener toda la información en una única base de datos relacional, **Qdrant** presenta un diseño especializado. Así como un mejor equilibrio entre rendimiento y latencia. Además, **Qdrant** se utiliza en proyectos reales lo que lo convierte en una muy buena opción para implementar el sistema *RAG*.

⁴⁸<https://qdrant.tech/>

⁴⁹<https://www.datacamp.com/es/tutorial/pgvector-tutorial>

⁵⁰<https://www.postgresql.org/>

Herramienta	Ventajas	Desventajas
Qdrant	Diseñada específicamente como base de datos vectorial, con índices optimizados para búsquedas de similitud y buen compromiso entre RPS, latencia y tiempo de indexado [14].	Introduce un nuevo servicio en la arquitectura: es necesario administrar una base de datos adicional a la relacional.
	Soporta filtrado avanzado por metadatos y búsquedas híbridas (vectoriales más filtros), lo que facilita consultas complejas en <i>RAG</i> .	Requiere aprender herramientas y mecanismos de operación específicos (copias de seguridad, monitorización, actualización de índices, etc.).
	Ofrece despliegue sencillo mediante contenedores y opciones gestionadas, con API HTTP y RPC bien documentadas.	Para casos de uso pequeños puede resultar más compleja que reutilizar la base de datos transaccional existente.
pgvector	Integración directa con bibliotecas y orquestadores de <i>RAG</i> , lo que reduce el código necesario para conectarla con el resto del sistema.	
	Permite reutilizar una instancia de PostgreSQL ya desplegada, unificando datos transaccionales y <i>embeddings</i> en el mismo sistema.	El rendimiento en búsquedas vectoriales a gran escala (millones de vectores y alta concurrencia) suele ser inferior al de motores especializados.
	Aprovecha todo el ecosistema SQL: transacciones, <i>joins</i> , vistas, roles de usuario y mecanismos estándar de replicación y copia de seguridad.	Dispone de menos funcionalidades específicas de bases de datos vectoriales (gestión de colecciones, métricas especializadas o afinado fino de índices).
	Simplifica la operación en entornos reducidos o con restricciones de infraestructura, al requerir un único motor de base de datos.	La configuración óptima de índices y parámetros depende de la versión de PostgreSQL y de la extensión, y puede requerir un ajuste cuidadoso.

Tabla 4.2: Comparativa de Qdrant y pgvector.

Base de datos relacional

Para la implementación de la base de datos relacional se ha valorado usar **PostgreSQL**⁵¹ y **SQLite**⁵². **PostgreSQL** es un sistema de gestión de bases de datos relacionales de código abierto, orientado a objetos con gran robustez transaccional. Por su parte **SQLite** es un sistema ligero y embebido que no funciona como servidor independiente, sino que almacena la base de datos en un fichero local. En la tabla 4.3 se muestra una comparativa entre ambos sistemas de gestión de bases de datos relacionales.

Inicialmente se comenzó integrando **SQLite**, ya que, se considero suficiente para un prototipo local del sistema *RAG*. Pero, finalmente se cambió a **PostgreSQL** porque en el proyecto se busca conseguir una arquitectura realista y desplegable que permita la concurrencia real de usuarios en el sistema.

4.10. Desarrollo *web*

El desarrollo de la interfaz *web* para el proyecto se ha realizado con **Flask**⁵³ [7]. *Flask* es un *framework WSGI* (*Web Server Gateway Interface* [36] es un estándar *Python* para la comunicación entre los servidores *web* y el *framework web*) que proporciona los componentes esenciales para construir aplicaciones *web* usando *Python*. Fue diseñado para la creación de aplicaciones *web* ligeras y modulares.

Se ha optado por utilizar **Flask** para el desarrollo *web* en lugar de otros *frameworks*, como **Django**⁵⁴ o **FastAPI**⁵⁵ porque incorpora una serie de componentes que permiten gestionar las aplicaciones *web* de forma sencilla:

- Enrutamiento: permite asociar rutas URL a funciones *Python* utilizando decoradores. Lo cual permite organizar el código de manera modular. En el caso del proyecto simplifica la conexión entre la interfaz *web* y el *pipeline* de generación *RAG*.
- Gestión de peticiones y respuestas: proporciona objetos que permiten acceder de manera sencilla a los datos enviados por el usuario, utilizando formularios, JSON o simplemente parámetros.

⁵¹<https://www.postgresql.org/>

⁵²<https://sqlite.org/>

⁵³<https://flask.palletsprojects.com/en/stable/>

⁵⁴<https://www.djangoproject.com/>

⁵⁵<https://fastapi.tiangolo.com/>

- Motor de plantillas Jinja2: permite generar HTML a partir de datos procesados en el servidor. Lo cual facilita la visualización estructurada de las distintas partes del sistema.
- Soporte WSGI: como se ha comentado anteriormente, *Flask* se basa en este estándar para la comunicación entre aplicaciones *web* y servidores *Python*. La utilización de este estándar garantiza la compatibilidad con múltiples servidores de producción y facilita su despliegue mediante *Docker*.
- Extensiones: a pesar de que es minimalista, permite incorporar extensiones para bases de datos, autenticación o validación de formularios.

4.11. Evaluación de la calidad del código

Para evaluar y mantener la calidad del código desarrollado también se han incorporado herramientas de análisis estático. Concretamente se ha utilizado **SonarCloud**⁵⁶ y **Ruff**⁵⁷.

SonarCloud es una plataforma de análisis continuo integrada con **GitHub** que permite detectar automáticamente *bugs*, vulnerabilidades de seguridad, duplicidad de código, problemas de mantenibilidad, complejidad ciclomática y el *coverage* de las pruebas. Su utilización facilita identificar códigos que requieren refactorización y mejorar progresivamente la arquitectura de la aplicación.

Por su parte, **Ruff** es una herramienta ligera y muy rápida orientada al análisis estático y validación del estilo de código *Python*. Sirve para comprobar automáticamente errores de estilo, *imports* no utilizados, variables redundantes y malas prácticas de programación. Ayuda a mantener una estructura homogénea y coherente en todo el proyecto.

4.12. Despliegue de la aplicación

Para desplegar la *web* se han utilizado las herramientas **docker** (ver sección 4.12.1), **nginx** (ver sección 4.12.2), **gunicorn** (ver sección 4.12.3), **DNS** (ver sección 4.12.4) y el certificado **SSL/TLS** (ver sección 4.12.5). El

⁵⁶<https://www.sonarsource.com/products/sonarqube/cloud/>

⁵⁷<https://docs.astral.sh/ruff/>




Figura 4.2: Relación entre las herramientas utilizadas para desplegar la aplicación *web*.

uso de estas herramientas permite separar la responsabilidad y asegurar la portabilidad, el rendimiento y la seguridad.

Empaquetar la aplicación en un contenedor **docker** garantiza su reproducibilidad, evitando conflictos entre librerías y versiones del sistema. **Gunicorn** sirve para no exponer directamente la aplicación **Flask** en Internet. **Nginx** se coloca por delante actuando como un servidor *web* y como *proxy* inverso. Va recibir las conexiones externas y las va a reenviar al servicio de **gunicorn**. También, se va a encargar de gestionar el cifrado y descifrado de **HTTPS**. El certificado **SSL/TLS** sirve para habilitar dicho protocolo **HTTPS**, en este caso demostrando control del dominio (DNS-01). En la imagen 4.2 se puede ver cómo se relacionan las distintas herramientas.

Docker

Docker⁵⁸ [9] es una plataforma de *software* de código abierto basada en contenedores. Permite empaquetar una aplicación con sus dependencias para distribuirla y ejecutarla, asegurando que funcione igual en cualquier entorno. Esto se debe a que aísla la aplicación y sus dependencias del sistema operativo dentro de unidades ligeras y portables (los contenedores). Los conceptos clave del **Docker** son:

- **Imagen**: es una plantilla que contiene el sistema base y las dependencias necesarias.
- **Contenedor**: es una instancia en ejecución de la imagen.
- **Dockerfile**: es un archivo en el que se especifican los pasos que se deben seguir para construir la imagen.
- **Docker Compose**: es una herramienta que se define en un archivo `yaml` en el cual se definen todos los servicios que debe contener la imagen. Estos servicios se dividen en volúmenes.

Se decidió implementar un contenedor **Docker** ya que mejora la reproductividad, la portabilidad y evita conflictos entre las dependencias en el sistema aportando mayor aislamiento. Además, permite integrar fácilmente diversas herramientas dentro de los volúmenes lo que mejora la escalabilidad. En sistemas que combinan múltiples componentes, como ocurre en este proyecto con *LLM*, base de datos vectorial y relacional e interfaz *web*, el uso de contenedores simplifica considerablemente la gestión de la infraestructura.

Nginx

Nginx⁵⁹ es un servidor *web* que puede actuar como *proxy* inverso [3]. Un *proxy* inverso es un servidor que, a diferencia de un *proxy* normal, se sitúa delante de los servidores *web* para interpretar las solicitudes de los clientes. Se encarga de reenviar las solicitudes de los clientes a los servicios *web*. En el caso del proyecto **Nginx** se ha utilizado como intermediario entre el cliente y la aplicación **Flask** para recibir las peticiones externas (HTTP/ HTTPS). También, se encarga de gestionar el certificado SSL y de redirigir el tráfico hacia **Gunicorn**.

⁵⁸<https://www.docker.com/>

⁵⁹<https://nginx.org/>

La ventaja de utilizar **Nginx** es que está optimizado para manejar múltiples conexiones concurrentes de forma eficiente. Además, desacopla el servidor *web* del servidor de aplicaciones, aumentando la seguridad y el rendimiento del sistema.

Gunicorn

Gunicorn⁶⁰ es un servidor WSGI para aplicaciones **Python** fácil de instalar (no requiere dependencias adicionales), pero que no es compatible con **Windows**. Su principal función es ejecutar la aplicación **Flask** en un entorno preparado para producción. Ya que, por defecto, el *framework* **Flask** incluye un servidor de desarrollo que no es adecuado para entornos reales. Por lo cual **Gunicorn** se encarga de sustituir este servidor por uno optimizado para producción que si que va a permitir gestionar múltiples procesos de manera simultánea y que va a mejorar la estabilidad.

DNS

El DNS (*Domain Name System*) permite asociar un nombre de dominio a la dirección IP del servidor donde se encuentra desplegada la aplicación. Asignarle un dominio a una aplicación sirve para facilitar el acceso y otorgarle mayor profesionalidad. Además, de mejorar la accesibilidad, permite la migración del servidor sin necesidad de cambiar la dirección que utiliza el usuario.

En este proyecto el dominio público se ha adquirido a través del proveedor **Hostalia**⁶¹. Una vez registrado el dominio, fue necesario configurar sus registros DNS para asociarlo con la dirección IP del servidor donde se encuentra desplegada la aplicación. Para vincular el dominio al servidor se configuró un registro tipo A dentro del panel de gestión DNS de **Hostalia**. Este registro permite que las peticiones dirigidas al dominio se redirijan a la dirección IP correspondiente del servidor.

Sin embargo, la aplicación se ejecuta en una IP privada de la Universidad de Burgos. Las direcciones IP privadas no son accesibles directamente desde Internet [26], ya que están destinadas a redes internas. Para conseguir que la aplicación sea accesible desde Internet hay que configurar el *router* de

⁶⁰<https://gunicorn.org/>

⁶¹<https://www.hostalia.com/>

tal forma que el dominio apunte a la IP pública del dicho *router*. Mediante técnicas NAT (*Network Address Translation* [5]) se redirige el tráfico hacia la IP privada del servidor.

Certificado SSL/TLS

Para garantizar la seguridad de las comunicaciones se ha configurado un certificado SSL/TLS que permite el uso del protocolo HTTPS (*HyperText Transfer Protocol Secure*) [2]. HTTPS es la versión segura de HTTP y se basa en el protocolo TLS (*Transport Layer Security*), cuyo objetivo es cifrar la comunicación entre el cliente y el servidor. Este cifrado impide que terceros puedan interceptar, modificar o suplantar la información transmitida, protegiendo así la confidencialidad e integridad de los datos.

En este proyecto, el certificado digital se ha emitido utilizando **Certbot**⁶² que es una herramienta oficial promovida por la *Electronic Frontier Foundation*⁶³ (EFF). *Certbot* automatiza la obtención e instalación de certificados gratuitos proporcionados por **Let's Encrypt**⁶⁴. La cual es una autoridad certificadora reconocida internacionalmente. El proceso de emisión del certificado se basa en un mecanismo de validación del dominio, mediante el cual se demuestra que el servidor tiene control sobre el dominio solicitado. Una vez validado, se genera un certificado digital que incluye la clave pública del servidor, la identidad del dominio y la firma digital de la autoridad certificadora. Concretamente se ha utilizado el método de validación DNS-01 que consiste en demostrar que se tiene control sobre el dominio añadiendo un registro específico tipo TXT en la configuración DNS. Este registro contiene un *token* generado por la autoridad certificadora.

⁶²<https://certbot.eff.org/>

⁶³<https://www.eff.org/>

⁶⁴<https://letsencrypt.org/>

Características	PostgreSQL	SQLite
Modelo	Cliente-servidor	Embebido
Concurrencia	Alta	Limitada (solo hay un escritor)
Escalabilidad	Alta	Baja
Uso recomendado	Sistemas multiusuario	Aplicaciones locales o prototipos
Integración con Docker	Muy buena	No necesaria (es un archivo local)

Tabla 4.3: Comparativa de PostgreSQL y SQLite.

5. Aspectos relevantes del desarrollo del proyecto

En este apartado se van a explicar los aspectos más importantes del proyecto. Se van a recoger los distintos retos se han encontrado durante el desarrollo indicando como se solventaron. También, se van a explicar las decisiones más relevantes que se han tomado para llevar a cabo el proyecto.

5.1. Inicio del proyecto

Actualmente la mayor parte de las personas utilizan grandes modelos de lenguaje, ya bien sea a través de [ChatGPT](https://chat.openai.com)⁶⁵, [Claude](https://claude.ai)⁶⁶, [Gemini](https://gemini.google.com/app)⁶⁷ o [NotbookLM](https://notebooklm.google.com/)⁶⁸, pero la mayor parte de los usuarios no conocen lo suficiente de su funcionamiento como para sacarle el máximo partido. Generalmente los *prompts* de estos usuarios son escuetos, sin el contexto adecuado, lo que permite que el modelo alucine en sus respuestas dándoles información errónea que generalmente no contrastan. En este contexto surgió la idea del proyecto, generar un *LLM* especializado en licitaciones del estado, concretamente en las de la Junta de Gobierno de la Diputación Provincial de Burgos.

Para evitar que fuese el usuario el que le tuviera que otorgar el contexto al modelo se decidió implementar un *RAG* que contuviera todos las licitaciones

⁶⁵<https://chat.openai.com>

⁶⁶<https://claude.ai>

⁶⁷<https://gemini.google.com/app>

⁶⁸<https://notebooklm.google.com/>

de la Junta de Gobierno de la Diputación Provincial de Burgos publicadas en la página de [Contratación del Sector Público](#)⁶⁹. Además, para evitar alucinaciones del modelo se decidió limitar sus respuestas a la información que le proporciona el *RAG*.

Otro problema típico de los *LLM* es la fecha de entrenamiento, ya que no son capaces de contestar preguntas posteriores a esta fecha, ya que no conocen su respuesta. Para evitar este problema de desactualización se decidió incluir un programa de *web scraping* para que se pueda extraer de forma periódica las nuevas licitaciones y volver a descargar aquellas que hayan sido actualizadas.

5.2. Web Scraping

Tras formalizar la idea se comenzó con el proyecto realizando la aplicación de *Web Scraping* para extraer las licitaciones de la página de [Contratación del Sector Público](#)⁷⁰ de manera automática. Se desarrollaron diferentes soluciones utilizando *Selenium* y *Playwright*, optando finalmente por el uso de *Playwright* en modo asíncrono, ya que permite gestionar de forma automática las esperas y la interacción con elementos dinámicos, haciendo que el sistema sea más robusto frente a fallos y *timeouts* que con los programas realizados con *Selenium*. Además, al usar *Playwright* asíncrono (*asyncio*) se pudo incorporar procesamiento concurrente, ya que permite procesar varias tareas en paralelo, para optimizar el tiempo de extracción y descarga de datos.

La elevada complejidad de la página debido al uso de contenido dinámico e *iframes* supuso un reto. Para solventarlo se tuvieron que desarrollar mecanismos específicos para la localización de elementos y la navegación entre distintos contextos. Finalmente, los datos obtenidos se normalizan y almacenan en un archivo *JSON*. Este archivo se usa para descargar los pliegos finales.

Cabe destacar que durante el desarrollo del proyecto se actualizó la página [Contratación del Sector Público](#)⁷¹, por lo cual hubo que realizar cambios en el programa ya desarrollado, modificando selectores y flujos de navegación para mantener su funcionamiento.

⁶⁹<https://tinyurl.com/48ay5679>

⁷⁰<https://tinyurl.com/48ay5679>

⁷¹<https://tinyurl.com/48ay5679>

5.3. *Retrieval Augmented Generation (RAG)*

Durante el desarrollo del sistema *RAG* se han evaluado distintos enfoques para cada uno de sus componentes principales, con el objetivo de optimizar la calidad de las respuestas, la eficiencia del sistema y su facilidad de despliegue. A continuación, se describen los elementos más relevantes analizados, las pruebas realizadas y la justificación de las decisiones finales adoptadas.

Tokenizer

Uno de los primeros aspectos analizados fue el uso del *tokenizer*, ya que es el encargado de transformar el texto en unidades básicas (*tokens*) que son la entrada real de los modelos de lenguaje (*LLM*). Su correcto funcionamiento es clave tanto para el procesamiento del texto como para el control del tamaño de los fragmentos (*chunks*).

Se realizaron pruebas con diversos *tokenizers* asociados a distintos modelos de lenguaje (como *LLaMA* o *Mistral*), así como con el *tokenizer* incluido en los modelos de *embeddings*. Se observó que utilizar el *tokenizer* del propio modelo de *embeddings* simplifica el *pipeline* y evita inconsistencias entre la representación del texto y su vectorización semántica. Además, permite conocer directamente el número máximo de *tokens* admitido por el modelo, facilitando el control del tamaño de entrada y evitando superar la ventana máxima soportada.

Por este motivo, se optó por utilizar el *tokenizer* del modelo de *embeddings* (*SentenceTransformer*), garantizando coherencia entre el proceso de *chunking* y la generación de *embeddings*.

En la implementación final, el sistema obtiene automáticamente tanto el *tokenizer* como el tamaño máximo de secuencia directamente desde el modelo cargado, permitiendo adaptar dinámicamente el sistema si se cambia de modelo de *embeddings*. Esto facilita la reutilización del *pipeline* con distintos modelos sin necesidad de modificar manualmente los parámetros de tokenización.

Chunking

El *chunking* consiste en dividir los documentos en fragmentos manejables. Es fundamental para ajustarse a la ventana de contexto del modelo y para mejorar la recuperación semántica. El texto se puede segmentar por longitud fija (*tokens*), por secciones o párrafos o por significado semántico.

Este proceso fue uno de los procesos más experimentados, probándose diferentes estrategias como el *chunking* por tamaño fijo de caracteres, por *tokens* con *overlap* (solapamiento) para mantener el contexto o basado en secciones o frases. Durante las pruebas se comprobó que el uso exclusivo de *chunks* por tamaño fijo generaba fragmentos poco naturales, afectando negativamente a la recuperación. Por otro lado, el *chunking* semántico puro resultaba más complejo y costoso.

Por ello se optó por una estrategia híbrida, en la cual primero se realiza una agrupación lógica del texto utilizando frases y separadores naturales del documento y posteriormente se divide en *chunks* controlados por número de *tokens*, incorporando solapamiento entre fragmentos consecutivos. Este solapamiento permite conservar información contextual relevante entre fragmentos cercanos, reduciendo la pérdida de información cuando una explicación queda dividida entre dos *chunks*.

Además, durante el desarrollo se realizaron pruebas variando tanto el tamaño de los *chunks* como el porcentaje de solapamiento. Se observó que *chunks* demasiado pequeños reducían la capacidad contextual del modelo, mientras que fragmentos demasiado grandes empeoraban la precisión de la recuperación y aumentaban el número de *tokens* enviados al *LLM*. La estrategia híbrida seleccionada consiguió un equilibrio entre coherencia semántica, precisión en la recuperación y eficiencia computacional.

Embeddings

Los *embeddings* son representaciones vectoriales del texto que capturan su significado semántico. Permiten comparar las consultas de los usuarios con los fragmentos de los documentos y realizar búsquedas por similitud. Son la base del funcionamiento del sistema de recuperación del *RAG*. Por lo cual para elegir el modelo final se probaron varios comparando su calidad semántica, la velocidad de ejecución y el consumo de recursos. Finalmente, se seleccionó el modelo `sentence-transformers/all-MiniLM-L6-v2` debido a que ofrece buen equilibrio entre rendimiento y coste computacional. Además,

su integración mediante **SentenceTransformer** es sencilla y su dimensión de *embedding* es suficiente para tareas de recuperación semántica sobre documentos administrativos.

Durante las pruebas también se evaluó el comportamiento del sistema en CPU y GPU. La implementación final permite detectar automáticamente el dispositivo disponible y ejecutar el cálculo de *embeddings* utilizando aceleración por GPU cuando está disponible. Además, se incorporaron mecanismos de recuperación ante errores de memoria en **CUDA**, permitiendo continuar automáticamente la generación de *embeddings* en CPU si la memoria de la GPU resulta insuficiente.

Otra mejora relevante implementada fue el procesamiento por lotes (*batch processing*) durante la generación de *embeddings*. En lugar de vectorizar cada *chunk* individualmente, el sistema procesa múltiples fragmentos simultáneamente, reduciendo significativamente el tiempo de indexación.

Base de datos vectorial

La base de datos vectorial es la encargada de almacenar los *embeddings* y permitir realizar búsquedas en espacios de alta dimensión. Tras estudiar diversas opciones (ver sección 4.8.1) se eligió **Qdrant** ya que, al tener soporte nativo para la búsqueda vectorial simplifica mucho su uso eficiente. Además, permite almacenar metadatos junto con los *chunks* y *embeddings*, lo que se consideró de utilidad para aumentar el contexto durante la recuperación. Como metadatos se incluyen los *hashes* *SHA-256* de los documentos originales para detectar automáticamente cuándo un documento ha cambiado y reindexarlo sin duplicar información.

Durante el desarrollo se implementó un sistema de creación automática de colecciones en **Qdrant**. Estas colecciones están configuradas con búsqueda por similitud coseno y una dimensión de vector ajustada dinámicamente al modelo de *embeddings* empleado. Para optimizar el rendimiento, los *chunks* se almacenan mediante operaciones **bulk upsert**, reduciendo significativamente el tiempo de indexación frente a inserciones individuales. Además, se utiliza una capa de abstracción (similar a un *Object-Vector Mapping*) para encapsular la lógica de conexión, serialización y recuperación de datos desde **Qdrant**. Esta capa permite desacoplar parcialmente el sistema del motor vectorial.

***Retriever* (mecanismo de recuperación)**

Es el componente encargado de buscar en la base vectorial los fragmentos más relevantes para responder a una consulta. Su calidad es crítica, ya que determina el contexto que se proporcionará al modelo. Por lo tanto, la calidad de la respuesta depende directamente de la capacidad del *retriever* para recuperar información relacionada con la pregunta del usuario. Se basa en la búsqueda por similitud vectorial, principalmente por similitud coseno.

En los primeros prototipos del proyecto, el sistema solo recuperaba el *chunk* más parecido a la consulta del usuario. Para ello, primero se convertía la pregunta en un *embedding* (utilizando el mismo modelo que el que se usa para indexar los documentos). Posteriormente, se calculaba la similitud entre dicho *embedding* y los almacenados en la base de datos vectorial. Finalmente, se seleccionaba el fragmento con mayor similitud y este se incorporaba directamente al *prompt* enviado al *LLM*. Este enfoque se planteó como punto de partida para validar el funcionamiento básico del *RAG* pero presentaba limitaciones importantes en la generación de la respuesta, haciendo que la mayoría de las preguntas no las pudiese contestar.

Después, se probó a cambiar el número de *chunks* recuperados (**top-k retrieval**). Se observó que recuperar pocos *chunks* produce respuestas demasiado limitadas, llevando a generalizaciones que no se cumplen en todos los documentos. En cambio, recuperar demasiados introduce ruido al modelo haciendo que responda con información irrelevante. Además, se vio que los contextos demasiado grandes hacen que el modelo utilice más *tokens* para contestar, empeorando la latencia de generación.

Otro aspecto relevante fue al evolución del propio *chunking*. Al principio los documentos se dividían utilizando tamaños fijos de texto. Sin embargo, se comprobó que esta estrategia fragmentaba información relacionada y afectaba negativamente a la recuperación semántica. Posteriormente, se introdujo el uso de solapamiento entre los *chunks*, permitiendo compartir parte del contenido entre fragmentos consecutivos. Esta mejora incrementó significativamente la coherencia del contexto recuperado y redujo la pérdida de información relevante entre fragmentos contiguos.

Además, del contenido textual, también se añadieron metadatos asociados a cada *chunk* como el nombre del documento, el título de la licitación, el identificados del fragmento, la posición dentro del documento y la información estructural obtenida durante el preprocesado. Utilizar metadatos mejoró la trazabilidad de las respuestas generadas.

Finalmente el sistema utiliza una estrategia de recuperación dinámica basada en búsqueda vectorial por similitud coseno sobre **Qdrant**. Para cada consulta, la pregunta del usuario se transforma en un *embedding* y posteriormente se calcula la similitud con todos los *embedding* almacenados en la base vectorial. Pero, ahora el sistema recupera un conjunto de *chunks* los cuales deben tener una similitud con la pregunta de al menos 0'5 para descartar fragmentos poco relacionados con la consulta. El número de *chunks* recuperados depende del tipo de pregunta realizada, las consultas generales utilizan hasta 20 fragmentos, mientras que las consultas guiadas tienen configuraciones específicas optimizadas para cada caso. Por ejemplo, preguntas orientadas a resúmenes globales pueden recuperar hasta 80 *chunks* para proporcionar una visión completa del documento, mientras que consultas más concretas, como solvencia, garantías o duración contractual, utilizan entre 12 y 18 fragmentos para reducir el ruido y mantener la precisión. Además, de la recuperación semántica se aplican filtros por metadatos, como número de expediente o tipo de documento (administrativo/técnico) para limitar la búsqueda únicamente a los documentos relevantes. Este enfoque híbrido permite equilibrar cobertura contextual, precisión semántica y eficiencia en el consumo de *tokens* del *LLM*.

Augmentation

Este proceso consiste en combinar la consulta del usuario con los fragmentos recuperados para construir un *prompt* enriquecido. Esta fase incluye técnicas de ingeniería de *prompts* para mejorar la calidad de la respuesta. En el desarrollo del *RAG* se probaron distintas estrategias, observándose diferencias significativas en el comportamiento del sistema.

En las estrategias más simples, los *chunks* recuperados se concatenaban junto con la pregunta del usuario. Aunque este enfoque era sencillo, el modelo tendía a mezclar información o a ignorar parte del contexto recuperado.

Observadas estas limitaciones se decidió utilizar *prompts* estructurados. En los cuales se separa el contexto recuperado, la pregunta del usuario, las instrucciones del sistema y las restricciones sobre como responder.

Con este enfoque el *LLM* interpreta mejor el contexto recuperado y disminuye las alucinaciones. Además, se añadieron instrucciones específicas indicando que la respuesta deben basarse únicamente en la información proporcionada por los *chunks* recuperados.

También, se han realizado pruebas modificando el orden de los fragmentos recuperados dentro del *prompt*. Se observó que colocar primero los *chunks* con mayor similitud mejora la precisión de las respuestas, especialmente en consultas complejas o ambiguas.

Otra mejora importante fue la incorporación de referencias documentales dentro del *prompt*. En lugar de proporcionar únicamente texto plano, cada fragmento incluye información sobre el documento de origen. Esto ayuda al modelo a contextualizar mejor la información y facilita mostrar al usuario la procedencia de la respuesta generada.

Finalmente, el sistema incorpora distintos *prompts* para contestar dependiendo del tipo de consulta que haga el usuario. Se ha diseñado un *prompt* general utilizado para preguntas abiertas, pero, además, se han definido plantillas específicas para tareas concretas como resúmenes globales del documento, extracción de importes económicos, plazos, solvencia, criterios de adjudicación, garantías, presupuestos, duración contractual, penalizaciones o presentación de ofertas. Cada plantilla incluye instrucciones adaptadas al tipo de información buscada y define una estructura concreta para la respuesta esperada. Por ejemplo, los *prompts* de tipo resumen solicitan una explicación global y estructurada del pliego, mientras que los orientados a criterios de adjudicación fuerzan al modelo a identificar ponderaciones, fórmulas y subcriterios. Además, el sistema utiliza un *system prompt* por defecto que obliga al modelo a responder en español de forma breve y precisa. Esta combinación de *prompts* especializados y selección dinámica del contexto permite adaptar el comportamiento del *LLM* al tipo de consulta realizada, mejorando la precisión, consistencia y utilidad de las respuestas generadas.

LLM

Es el encargado de generar la respuesta final utilizando el contexto proporcionado por el sistema *RAG*. La elección del modelo (tamaño, arquitectura, si es local o una *API*) afecta directamente a la calidad, latencia y coste del sistema.

Durante el desarrollo del proyecto, la integración de los modelos de lenguaje fue evolucionando progresivamente. Se comenzó realizando pruebas utilizando modelos locales (obtenidos de **Hugging Face**) ejecutados mediante **Ollama**. Estas pruebas permitieron comprobar la viabilidad de ejecutar modelos localmente sin depender de ninguna *API* externa, lo que aporta un

mayor control sobre el sistema y evita costes asociados al uso de servicios comerciales.

Inicialmente se realizaron pruebas con diversos modelos locales como *Mistral* o *LLaMA* para probar distintas arquitecturas y tamaños. Gracias a estas pruebas se pudo ver como afecta el tamaño a la respuesta generada y al tiempo invertido. Se vio que los modelos más pequeños tardaban menos en generar las respuestas, pero dichas respuestas eran de menor calidad. Tendían a ser breves y menos precisas. Mientras que los modelos más grandes generaban mejores respuestas, pero con mayor consumo de recursos y latencias. Finalmente, se seleccionó como modelo principal del sistema *LLaMA 3.1-8B*, ya que tiene buen rendimiento en tareas de comprensión y generación. Este modelo ofrece un buen equilibrio entre la claridad de la respuesta generada, la utilización del contexto recuperado y los requisitos de *hardware*. Otro aspecto que se tuvo en cuenta a la hora de elegir el modelo fue que permite la ejecución en local usando *Ollama*. Lo que permite mantener el control total sobre el sistema sin dependencias externas.

Finalmente, se decidió incluir soporte para múltiples modelos configurables desde la propia aplicación *web*. De tal forma que la arquitectura final permite seleccionar dinámicamente entre tres modelos distintos (*LLaMA 3.1-8B*, *gemma-4B* y *qwen3-4B*, cargados desde *Ollama*) integrados dentro del sistema *RAG*. Esta evolución surgió debido a la necesidad de comparar comportamientos y ofrecer mayor flexibilidad dependiendo del tipo de consulta realizada.

Para soportar esta funcionalidad fue necesario desacoplar la lógica de generación del resto del *pipeline RAG*, implementando una capa de abstracción que permitiese cargar dinámicamente los distintos modelos y modificar sus parámetros. Además, se añadieron funciones auxiliares para gestionar las configuraciones disponibles y mostrar automáticamente las opciones en la interfaz *web*.

Además, se han ajustado parámetros de generación como el número máximo de *tokens* generados, la longitud máxima de entrada, la temperatura, el formato del *prompt* y el número de *chunks* recuperados. Lo que permitió mejorar la calidad de las respuestas, reduciendo alucinaciones y adaptandolas al contexto del sistema.

5.4. Conversión a Markdown

La conversión de los documentos PDF a Markdown permite transformar documentos administrativos complejos en texto estructurado apto para el proceso de *chunking*, generación de *embeddings* y recuperación semántica. Inicialmente, los documentos PDF se procesaban extrayendo texto plano. Este enfoque presentaba limitaciones como la pérdida de la estructura del documento, lo que provocaba que el sistema no pudiese diferenciar los títulos, subtítulos, tablas o las secciones. Por este motivo, durante el desarrollo se comenzó a investigar la posibilidad de convertir los PDF a Markdown de forma automática.

Las primeras aproximaciones consistieron en utilizar bibliotecas tradicionales de extracción de texto en Python. Estas herramientas permitían obtener el contenido textual de los PDF, pero perdían gran parte del formato original. Uno de los principales problemas encontrados fue que los documentos de licitaciones públicas presentan formatos extremadamente heterogéneos. Debido a esto se comenzaron a realizar pruebas utilizando OCR (*Optical Character Recognition*). Sin embargo, aunque el OCR permitía recuperar texto que anteriormente no podía extraerse, seguía presentando problemas. No se reconocían correctamente todos los caracteres, se seguía perdiendo parte del formato, las tablas no siempre se construían bien. Además, el uso de OCR supuso un incremento considerable del tiempo de procesamiento.

La implementación final se basa en un sistema de OCR multimodal que utiliza modelos visuales ejecutados mediante Ollama, concretamente el modelo blaifa/Nanonets-OCR-s. Este modelo recibe imágenes de las páginas del PDF junto con un *prompt* especializado que fuerza la generación de Markdown estructurado, incluyendo títulos jerárquicos, tablas HTML, ecuaciones en L^AT_EX, listas y otros elementos relevantes del documento original.

El procesamiento se realiza de forma asíncrona página a página. Primero, cada página del PDF se convierte individualmente en una imagen utilizando pdf2image, evitando cargar el documento completo en memoria y reduciendo así el consumo de recursos. Posteriormente, las páginas se procesan concurrentemente mediante tareas asíncronas controladas con semáforos, permitiendo paralelizar parcialmente el OCR y mejorar el rendimiento global del sistema. Esta arquitectura resulta especialmente importante debido al elevado tiempo de procesamiento de los documentos administrativos extensos.

Además, la implementación está preparada para utilizar aceleración por GPU cuando está disponible. El sistema detecta automáticamente la configuración de GPU y solicita a **Ollama** la ejecución del modelo visual utilizando todas las capas posibles en GPU. También se incorporaron mecanismos de *fallback* a CPU en caso de error, así como reintentos automáticos reduciendo progresivamente la resolución de las imágenes cuando el modelo produce fallos de memoria o errores internos. Estas optimizaciones fueron necesarias debido al elevado consumo computacional del OCR multimodal, especialmente en documentos con muchas páginas o tablas complejas.

Tras la conversión inicial, el **Markdown** generado pasa por una fase adicional de normalización automática. En esta etapa se corrigen índices con puntos suspensivos, se detectan encabezados numerados y se transforman en títulos **Markdown** jerárquicos, incluso cuando el modelo OCR no los reconoce correctamente. Para ello se desarrollaron reglas específicas adaptadas a la estructura habitual de los pliegos.

Durante el desarrollo se observó que esta aproximación mejora considerablemente la calidad del texto utilizado posteriormente por el sistema *RAG*, especialmente frente a OCR tradicionales basados únicamente en extracción plana de texto. Sin embargo, también se detectaron varias limitaciones importantes. La principal es el elevado tiempo de procesamiento, ya que cada página debe renderizarse como imagen y posteriormente analizarse mediante un modelo multimodal. Además, aunque el sistema consigue detectar correctamente gran parte de la estructura documental, no siempre identifica de forma precisa todas las secciones, tablas o jerarquías debido a que los formatos de los documentos son poco homogéneos.

5.5. Evaluación *RAG*

Un aspecto relevante del proyecto fue incluir una evaluación del sistema *RAG* implementado. Para dicha evaluación se ha utilizado un *pipeline* de evaluación *RAG* propio. El cual se inspira en *frameworks* existentes como **ARES** (*Automated RAG Evaluation System*) y **RAGAS** (*Retrieval-Augmented Generation Assessment*). El objetivo principal era construir un sistema de evaluación reproducible, automatizable y completamente local, evitando dependencias de API externas y garantizando la confidencialidad de los documentos utilizados.

La arquitectura implementada combina distintos enfoques de evaluación con la generación automática de *datasets* de evaluación. Para la generación

de dichos *datasets* se utiliza **ARES**, el cual genera de manera automática preguntas, respuestas y evidencias documentales a partir de los propios *chunks* almacenados en la base de datos vectorial.

Respecto a la evaluación, por un lado, se utiliza *RAGAS* para calcular métricas semánticas relacionadas con la calidad de la recuperación y de la generación utilizando un enfoque *LLM-as-a-judge*. Las métricas utilizadas son *Faithfulness*, *Answer relevance*, *Answer correctness*, *Context precision y recall* y *Context relevance*. Las cuales permiten analizar si la respuesta realmente está fundamentada en el contexto recuperado y si dicho contexto es adecuado para responder la consulta. Esta evaluación se combina con métricas de respaldo basadas en *embeddings* y similitud coseno. Estas métricas permiten calcular automáticamente el grado de similitud semántica entre preguntas, respuestas, contexto recuperado y *ground truth* utilizando representaciones vectoriales. Finalmente, ambas métricas se combinan mediante medias ponderadas. Consiguiendo una evaluación híbrida más robusta y estable. Esta combinación permitió reducir la variabilidad típica de los sistemas basados únicamente en *LLM-as-a-judge* y mejorar la reproducibilidad de los resultados.

5.6. Tareas asíncronas

Para que se realicen las tareas largas del proyecto se ha decidido ejecutarlas de manera asíncrona. Concretamente se ha usado este sistema para el **Web Scraping**, la conversión de documentos PDF a **Markdown**, la actualización de la base de datos vectorial y la evaluación del *RAG*. Permitiendo que estas tareas largas se ejecuten en segundo plano, sin bloquear el uso de la interfaz *web*.

Para implementarlo se han usado ejecutores basados en **ThreadPoolExecutor**. Se ha separado el ejecutor de las tareas de **Markdown** del resto de tareas del sistema. Esta separación permite controlar de forma independiente el número máximo de tareas concurrentes y evitar que procesos intensivos consuman todos los recursos disponibles. Además, se asocia un objeto **Future** a cada una de las tareas que se envían al ejecutor, de tal forma que se pueda realizar un seguimiento de su estado, cancelando trabajos que aún no hayan comenzado y liberando los recursos cuando finalizan.

Un reto que se planteó fue que la ejecución de las tareas largas (como la conversión a **Markdown**) no aumentasen la latencia en las respuestas del sistema *RAG*. Para solventar este problema se ha implementado un sistema

de prioridades basado en un indicador global de actividad del *RAG*. Cuando un usuario realiza una consulta, el sistema activa una marca de prioridad que indica que existe una generación *RAG* en curso. Mientras la marca este activa, el resto de tareas asíncronas que también estén activas esperan antes de lanzar nuevas peticiones al modelo.

Cuando un proceso largo finaliza se envía por correo electrónico una notificación para evitar que el usuario tenga que estar esperando en la aplicación hasta que el proceso finalice. Por ejemplo, se envía cuando finaliza la conversión a **Markdown**, la actualización vectorial o el *web scraping*. En el correo que se envía al usuario se indica el resultado de la operación, incluyendo el número de documentos convertidos, indexados o extraídos, respectivamente.

5.7. Desarrollo *web*

Tras realizar un primer prototipo *RAG* se comenzó el diseño de una aplicación *web* para permitir a los usuarios interactuar con el sistema de manera sencilla y visual. Para ello se decidió utilizar **Flask** como *framework* de desarrollo *web*.

Flask es un *framework* ligero para **Python** basado en la arquitectura **WSGI** que permite desarrollar aplicaciones web de manera modular y escalable. Una de las razones principales para su elección fue su flexibilidad, ya que facilita integrar distintos componentes del sistema *RAG*, como el *retriever*, el procesamiento documental o los modelos *LLM*, dentro de una misma aplicación. Además, **Flask** permite estructurar el proyecto utilizando *blueprints*, lo que facilitó dividir la aplicación en módulos independientes y mejorar su mantenibilidad.

Durante las primeras fases del desarrollo *web* se realizaron prototipos muy simples cuyo objetivo principal era únicamente permitir realizar consultas al sistema *RAG* desde una interfaz básica. Estas primeras versiones consistían en páginas **HTML** estáticas con formularios mínimos para introducir preguntas y mostrar respuestas del modelo. Conforme el proyecto evolucionó, la aplicación fue creciendo progresivamente hasta convertirse en una plataforma *web* completa con autenticación, gestión documental, historial de consultas, paneles administrativos y procesamiento asíncrono de tareas.

Desde el punto de vista arquitectónico, la aplicación se divide en *frontend* y *backend*. El *frontend* se encarga de la interacción visual con el usuario y

el *backend* se encarga de la lógica de negocio, procesamiento documental, acceso a bases de datos y comunicación con el sistema *RAG*.

Frontend

El *frontend* de PythIA ha evolucionado respecto a los primeros prototipos desarrollados durante el proyecto. Las primeras interfaces eran simples y estaban centradas en validar el funcionamiento técnico del sistema *RAG*. Sin embargo, conforme el proyecto avanzó, se comenzó a trabajar en el diseño de una interfaz más moderna, usable y adaptada a distintos tipos de usuarios. En la cual la complejidad del sistema *RAG* es transparente para el usuario.

El diseño visual de la aplicación se ha ido desarrollando a lo largo de todo el proyecto mediante distintas iteraciones de las páginas. Uno de los cambios más importantes respecto a los primeros prototipos fue la incorporación de soporte completo para modo claro y modo oscuro (dejando por defecto el modo del sistema salvo que el usuario indique otra cosa en su perfil) mejorando así la accesibilidad y la experiencia de usuario.

Para implementar la interfaz se utilizó **Bootstrap** como *framework CSS* principal. **Bootstrap** permitió acelerar el desarrollo del *frontend* gracias a su sistema de componentes reutilizables, facilitando mantener una coherencia visual entre todas las páginas de la aplicación. La utilización de **Bootstrap** también permitió implementar un diseño *responsive* para que los usuarios puedan usar la aplicación desde distintos dispositivos.

Otro aspecto importante del *frontend* fue la internacionalización de la aplicación. Para esto se ha desarrollado un sistema de traducción basado en diccionarios de claves y funciones auxiliares que permiten traducir los textos de la interfaz, los formularios, los mensajes de error, las validaciones, las notificaciones y los componentes dinámicos del **JavaScript**. Esto permitió desacoplar completamente los textos de la interfaz del código **HTML** y **Python**.

Además del diseño visual, también se incorporaron componentes gráficos interactivos utilizando **D3.js**. Lo que permitió generar visualizaciones mucho más dinámicas y personalizables. Además, facilitó adaptar las gráficas al diseño visual de la aplicación y a los distintos temas claro y oscuro.

Por otro lado, conforme el sistema fue incorporando más funcionalidades, se observó que algunos usuarios podían tener dificultades para comprender ciertos flujos de uso. Para mejorar la experiencia de usuario se han incorporado **Driver.js** como sistema de tutoriales interactivos guiados. Facilitando el aprendizaje inicial de la plataforma y mejorando la accesibilidad del sistema.

Backend

El *backend* de PythIA es el núcleo funcional de la aplicación y el encargado de integrar todas las partes del sistema *RAG*. Durante el desarrollo ha ido evolucionando desde *scripts* independientes hasta una arquitectura modular basada en **Flask** y organizada mediante *blueprints*, servicios y capas desacopladas.

La aplicación se organizó utilizando controladores **Flask** agrupados mediante *blueprints*. Cada *blueprint* encapsula un conjunto concreto de funcionalidades, como autenticación, administración, consultas *RAG*, gestión documental y páginas principales. Esta organización ha permitido desacoplar las distintas partes del sistema y mejorar la escalabilidad del proyecto.

Por debajo de los controladores se implementó una capa de servicios encargada de la lógica de negocio. Esta separación fue especialmente importante conforme el proyecto fue creciendo, ya que evita sobrecargar los controladores **Flask** con lógica de negocio. Permitiendo reutilizar código entre distintas partes de la aplicación y facilitando el mantenimiento.

En cuanto a los modelos de datos, la aplicación utiliza **SQLAlchemy** como ORM principal.

Además de la base de datos relacional utilizada para la gestión general de la aplicación, el *backend* también integra **Qdrant** como base de datos vectorial para almacenar los *embeddings* utilizados por el sistema *RAG*.

La comunicación entre las distintas capas de la aplicación sigue una arquitectura multicapa donde el usuario interactúa con el *frontend*. A continuación los controladores reciben las peticiones y los servicios ejecutan la lógica de negocio. Los modelos gestionan el acceso a los datos y los resultados se devuelven al *frontend*.

Otro aspecto importante fue la seguridad y el control de acceso. La aplicación implementa autenticación mediante **Flask-Login** y utiliza distintos roles de usuario para restringir determinadas funcionalidades administrativas.

También se ha desarrollado un sistema centralizado de control de excepciones para evitar errores no controlados dentro de la aplicación y evitar así caídas del sistema. Concretamente se registran los errores (mediante *loggers*) mostrándose mensajes de error amigables.

Finalmente, debido al elevado coste computacional de algunas operaciones, se incorporó soporte para tareas asíncronas. Esto fue especialmente

importante en procesos como la conversión de PDF a Markdown, el *web scraping*, la generación de *embeddings*, la indexación documental y la generación de la respuesta. Permite evitar bloqueos en la interfaz web, ya que los procesos pesados pueden ejecutarse en segundo plano mientras el usuario continua usando la aplicación (ver sección 5.6).

5.8. Evaluación de la calidad del código

A medida que el proyecto fue creciendo y la aplicación pasó de estar formada por pequeños prototipos experimentales a convertirse en un sistema *web* completo surgió la necesidad de incorporar mecanismos que permitiesen evaluar y controlar la calidad de código desarrollado.

Durante las primeras fases del proyecto, la prioridad principal era desarrollar *scripts* funcionales sin tener en cuenta el código duplicado, las funciones demasiado complejas, la escasa modularización, la baja reutilización o las dependencias acopladas. Para facilitar la mantabilidad y la escalabilidad se decidió incorporar herramientas automáticas de análisis estático de código.

Concretamente se decidió usar **SonarCloud**⁷². La cual se integró directamente con el repositorio **GitHub** del proyecto, para analizar automáticamente distintos indicadores relacionados con la calidad del software. Su uso permitió detectar y solucionar *bugs*, vulnerabilidades de seguridad, código duplicado, funciones extremadamente complejas, funciones demasiado largas, variables sin utilizar, problemas de mantenibilidad, incumplimientos de estándares de calidad y problemas con tipado y control de excepciones.

Como consecuencia de estos análisis, se realizaron diversas refactorizaciones importantes dentro del proyecto. Por ejemplo se realizó una separación más estricta entre los controladores y los servicios, se modularizaron las funciones más complejas, se reutilizó la lógica común reduciendo el código duplicado y se mejoró el control de excepciones.

Además, de **SonarCloud** también se utilizó **Ruff**⁷³ como herramienta complementaria para el análisis estático y mejora de la calidad del código. **Ruff** se integró dentro del flujo de desarrollo para realizar comprobaciones rápidas relacionadas con el estilo, complejidad y consistencia del código. Su principal ventaja es su gran velocidad de ejecución que permitió utilizarlo frecuentemente durante el desarrollo sin afectar significativamente al tiempo

⁷²https://sonarcloud.io/project/overview?id=lbr1014_TFG_RAG

⁷³<https://docs.astral.sh/ruff/>

de trabajo. Gracias a **Ruff** se detectaron automáticamente problemas como *imports* no utilizados, variables redundantes, código muerto, errores de estilo, complejidad innecesaria y diversas malas prácticas de programación en **Python**. Además, se empleó para mantener una estructura homogénea en todo el proyecto, como por ejemplo, en los nombres de las funciones y variables. Esto ayudó a mejorar la legibilidad, consistencia y mantenibilidad del código, especialmente en un proyecto grande y modular como **PythIA**, donde coexistían múltiples componentes relacionados con **Flask**, el sistema *RAG*, el procesamiento documental y las tareas asíncronas.

Para mejorar la legibilidad también se añadieron comentarios y documentación y se realizó separación de responsabilidades.

Además del análisis estático, la calidad del código también se complementó con pruebas unitarias y pruebas funcionales desarrolladas durante distintas fases del proyecto. Estas pruebas permitieron verificar el correcto funcionamiento de los formularios, la gestión de usuarios, las validaciones, los servicios principales, la integración del sistema *RAG* y el procesamiento documental.

5.9. Despliegue

Uno de los aspectos más importantes durante el desarrollo de **PythIA** fue el diseño de un entorno de despliegue estable, reproducible y preparado para producción.

En las primeras fases del proyecto, la aplicación se ejecutaba en entornos locales de desarrollo utilizando el servidor integrado de **Flask**. Aunque esta aproximación era suficiente para validar prototipos y desarrollar funcionalidades, presentaba importantes limitaciones relacionadas con el rendimiento, la escalabilidad, la seguridad y la reproducibilidad del entorno.

Para resolver estos problemas se decidió utilizar **Docker**. Lo que permitió encapsular los componentes necesarios de la aplicación dentro de contenedores independientes, garantizando que el sistema se ejecute de manera consistente independientemente del entorno donde fuese desplegado.

La utilización de **Docker** aportó múltiples ventajas al proyecto, por ejemplo permitió aumentar la reproductibilidad del entorno, aislar los servicios y simplificar la gestión de dependencias. Mejorando la mantenibilidad y la portabilidad entre distintos entornos. Además, hizo que el despliegue fuese más fácil.

En las primeras versiones, **Flask** seguía ejecutándose utilizando su servidor de desarrollo integrado. Sin embargo, este servidor no está diseñado para entornos productivos, ya que no gestiona adecuadamente múltiples peticiones concurrentes ni ofrece suficiente robustez frente a cargas elevadas. Para solucionar estos problemas se integró **Gunicorn** como servidor **WSGI** de producción. El cual se encarga de ejecutar múltiples *workers* de **Flask** de manera concurrente, mejorando significativamente el rendimiento y la estabilidad del sistema. Permitiendo gestionar mejor las peticiones simultáneas, el tiempo de espera, los procesos bloqueantes y la recuperación frente a fallos.

Otro aspecto importante fue la incorporación de **Nginx** como *proxy* inverso. **Nginx** se sitúa delante de **Gunicorn** y asume la gestión de conexiones **HTTP**, el balanceo interno de peticiones, la gestión de cabeceras, la optimización de rendimiento, la seguridad básica de acceso y se encarga de servir los archivos estáticos. Su utilización de manera conjunta con **Gunicorn** permitió separar las responsabilidades del sistema *web*, mejorando tanto el rendimiento como la seguridad de la aplicación.

La configuración de **Docker** presento alguna dificultad, por ejemplo, en la integración entre **Flask**, **Qdrant** y **PostgreSQL**, ya que la aplicación dependía simultáneamente de una base de datos relacional y otra vectorial. Lo que obligó a diseñar cuidadosamente la inicialización y configuración de los servicios para evitar errores durante el arranque del sistema.

Otro aspecto relevante fue la gestión de las variables sensibles y claves privadas. Para ello se utilizaron archivos de variables de entorno diferenciados, separando las configuraciones públicas de las credenciales privadas del sistema. Esto permitió mejorar la seguridad y facilitar la configuración en distintos entornos.

La arquitectura final del despliegue está dividida en varios contenedores especializados que se comunican entre sí mediante redes **Docker** internas. El sistema se divide principalmente en cinco servicios, un contenedor **PostgreSQL** para la persistencia de datos relacionales de la aplicación, un contenedor **Qdrant** encargado de la base de datos vectorial, un contenedor **Ollama** responsable de ejecutar los modelos de lenguaje y **OCR** multimodal utilizando aceleración por **GPU**, un contenedor principal con la aplicación **Flask** ejecutada mediante **Gunicorn** y un contenedor **Nginx** utilizado como *proxy* inverso y punto de entrada **HTTPS** del sistema. Es decir, la aplicación *web* no se comunica directamente con el exterior, sino que todas las peticiones pasan previamente por *Nginx*. Esto permite mejorar la seguridad y gestionar certificados **TLS** y balanceo de peticiones. Además, se incorporan volúmenes

persistentes para almacenar datos de *PostgreSQL*, índices vectoriales de *Qdrant*, modelos descargados de *Ollama* y cachés de *HuggingFace*, evitando perder información al reiniciar los contenedores. La arquitectura también incluye comprobaciones automáticas de estado (*healthchecks*) y dependencias entre servicios para asegurar que cada componente esté disponible antes de iniciar los demás.

5.10. Integración CI/CD

Durante el desarrollo también se incorporaron mecanismos de integración continua y automatización del flujo de desarrollo mediante **GitHub Actions**.

En las primeras fases del proyecto, todas las comprobaciones del sistema se realizaban manualmente. Cada modificación requería ejecutar localmente las pruebas, comprobar dependencias y verificar manualmente el correcto funcionamiento de la aplicación. Conforme el proyecto fue creciendo, este enfoque comenzó a resultar poco escalable y propenso a errores.

Para mejorar este proceso se decidió incorporar un *pipeline* CI/CD utilizando **GitHub Actions**. La integración se configuró para ejecutarse automáticamente tanto al realizar *commits* sobre la rama principal (*main*) como al abrir o actualizar *pull requests*. De esta forma cada cambio realizado en el repositorio desencadena las comprobaciones de calidad del sistema.

El *pipeline* CI/CD comienza clonando el repositorio y configurando el entorno **Python** utilizado por el proyecto. Luego instala las dependencias definidas para el entorno **Docker** de producción. Esto garantiza que las comprobaciones se realicen en un entorno lo más parecido posible al despliegue real. Una vez preparado el entorno, se ejecutan de manera automática los *tests* del proyecto mediante **unittest**. Además, durante la ejecución de las pruebas se calcula la cobertura de código utilizando **coverage.py**, generándose informes detallados sobre qué partes del sistema están siendo verificadas por los *tests* y cuales no. Tras la ejecución de las pruebas, **GitHub Actions** integra automáticamente el proyecto con **SonarCloud** para realizar el análisis estático del código.

6. Trabajos relacionados

En este apartado se analizan diferentes trabajos y proyectos que, aunque no constituyen modelos *RAG* idénticos al desarrollado en este trabajo, comparten principios fundamentales relacionados con el uso de *LLM*, recuperación de información, agentes inteligentes y gestión de contexto. Su estudio permite contextualizar el proyecto dentro del marco actual de aplicaciones basadas en *LLM* y comprender distintas aproximaciones al diseño de inteligencias artificiales.

6.1. TFG relacionados

***Retrieval-Augmented Generation* para la Extracción de Información de Documentos Inteligente**

En este TFG [18] se desarrolla un sistema *RAG* orientado al ámbito sanitario con el propósito de optimizar la recuperación y generación de información médica. El trabajo plantea una arquitectura basada en la recuperación y generación, que indexa documentación médica, crea *embeddings* y orquesta *prompts* para aportar contexto fiable al modelo generativo. Emplea técnicas de *chunking* con solapamiento y un enfoque **MultiQuery Retriever** para mejorar la cobertura y la precisión de la recuperación previa a la síntesis con un *LLM*. La solución se implementa sobre la API de **Azure OpenAI**, utilizando **LangChain** y **FAISS** como motor de búsqueda vectorial, e integra una interfaz web en **Flask** para simular consultas clínicas reales. Para la evaluación del sistema se emplea el *framework* **RAGAS**, valorando métricas de

precisión, relevancia y coherencia de las respuestas generadas, demostrando mejoras significativas frente a enfoques puramente generativos.

6.2. Proyectos relacionados

LLM Twin Course: Building Your Production-Ready AI Replica

Este proyecto [12] propone la construcción de un asistente conversacional que actúa como el usuario. Su objetivo principal es crear un sistema capaz de responder, razonar y comunicarse tal y como lo haría un usuario concreto. Para ello debe adaptarse al conocimiento, las preferencias y el estilo de dicho usuario. A nivel técnico, el proyecto emplea una arquitectura modular que combina los modelos *LLM* para la generación de respuestas, con sistemas de memoria persistentes, recuperación de información contextual y orquestación de flujos conversacionales. Uno de los aspectos más relevantes es la integración de memoria externa, que permite almacenar conocimiento personalizado y recuperarlo de manera dinámica durante la conversación. Aunque no se presenta como un *RAG* clásico tiene el mismo objetivo, ampliar la memoria paramétrica del modelo mediante información recuperada.

Building Your Second Brain AI Assistant Using Agents, LLMs and RAG

Este proyecto [13] plantea la creación de un asistente para que organice, recupere y sintetice información personal o profesional. Para realizar esto emplea técnicas de agentes inteligentes y *RAG*. Su arquitectura combina sistemas de recuperación semántica basados en *embeddings*, orquestación mediante agentes, gestión de memoria persistente e integración directa con *LLM* para síntesis de información. Para implementar el modelo *RAG* la información se indexa, se recupera según la consulta del usuario y se incorpora al *prompt* aumentado del modelo. A este flujo se le añaden agentes que coordinan las tareas de búsqueda, filtrado y razonamiento para ampliar las capacidades del sistema.

ChatALL

Este proyecto [8] consiste en diseñar una herramienta que permite interactuar de manera simultánea con múltiples modelos de lenguaje (*LLM*). Su objetivo principal es permitir la comparación de respuestas entre distintos *LLM* desde una única interfaz. Su arquitectura se centra en la orquestación de múltiples APIs de modelos, en la gestión concurrente de respuestas y en el desarrollo de una interfaz unificada para la conversación. Aunque no amplía el conocimiento del modelo mediante el uso de *RAG* es relevante como herramienta comparativa. Facilita evaluar el comportamiento de distintos *LLM* ante una misma consulta.

NotebookLM

NotebookLM⁷⁴ [23] [22] es una herramienta orientada a la interacción inteligente con colecciones de documentos proporcionados por el usuario. Permite cargar documentos, analizarlos y generar respuestas fundamentales en su contenido. Se basa en la indexación de documentos, la recuperación contextual y la generación asistida por *LLM*. Implementa un modelo *RAG* ya que responde utilizando el contenido recuperado. Esto reduce las alucinaciones y mejora la respuesta.

6.3. Análisis de las características de los proyectos

En la tabla 6.1 se muestra una comparativa entre las características de los distintos proyectos explicados previamente y las del modelo *RAG* desarrollado en el TFG.

La comparativa realizada permite observar que PythIA adopta una aproximación intermedia entre los sistemas *RAG* clásicos orientados a recuperación documental y las soluciones comerciales más avanzadas. Frente a proyectos como *LLM Twin Course* o *Second Brain AI Assistant*, que están más orientados a asistentes personales y gestión general del conocimiento, PythIA se centra específicamente en la consulta inteligente de licitaciones públicas, incorporando una recuperación semántica especializada y adaptada

⁷⁴<https://notebooklm.google.com/notebook/4696bf9f-51cb-42c0-8805-401c6286dbec>

al dominio jurídico-administrativo. Frente a *ChatAll*, cuyo objetivo principal es comparar respuestas entre distintos modelos sin implementar recuperación documental, PythIA integra un sistema *RAG* completo con recuperación vectorial, uso de metadatos y trazabilidad de las respuestas. En comparación con *NotebookLM*, PythIA comparte características como la contextualización documental y la referencia a fuentes, aunque utiliza una arquitectura abierta y modular basada en tecnologías *open-source*, permitiendo el uso de modelos locales y configuraciones personalizadas.

Características	<i>LLM Twin Course</i>	<i>Second Brain AI Assistant</i>	<i>ChatAll</i>	<i>NotebookLM</i>	PythIA
Enfoque principal	Réplica digital personalizada	Gestión inteligente del conocimiento	Comparación de <i>LLM</i>	Consulta documental guiada	Consulta inteligente de licitaciones públicas
Uso de <i>RAG</i>	Clásico modular	Híbrido con agentes	×	Propietario integrado	Clásico modular
<i>Chunking</i>	Tokens	Semántico	×	Propietario	Híbrido (tokens + semántico previo)
Solapamiento	✓	×	×	No se sabe	✓
Recuperación semántica	Similitud vectorial	Similitud vectorial + agentes	×	Contextual propietaria	Similitud coseno
Metadatos en recuperación	Parcial	✓	×	✓	✓
Soporte multi <i>LLM</i>	Parcial	✓	✓	×	✓
Uso de modelos locales	Opcional	Parcial	✓	×	✓
Multiagente	×	✓	×	×	×
Trazabilidad respuesta	Parcial	Parcial	×	✓	✓
Comparación de modelos	×	×	✓	×	✓
Evaluación <i>RAG</i>	Limitada	Limitada	×	Desconocido	✓

Tabla 6.1: Comparativa de las características de los proyectos.

7. Conclusiones y Líneas de trabajo futuras

El desarrollo de este Trabajo Fin de Grado ha permitido diseñar, implementar y desplegar un sistema completo basado en la técnica *Retrieval-Augmented Generation (RAG)* aplicado a la consulta inteligente de licitaciones públicas. El proyecto ha demostrado que la combinación de modelos de lenguaje de gran tamaño con sistemas de recuperación semántica permite superar gran parte de las limitaciones tradicionales de los *LLM*, especialmente aquellas relacionadas con el conocimiento estático, la falta de acceso a información específica y las alucinaciones generadas por el modelo.

Uno de los principales logros del proyecto ha sido la construcción de un *pipeline* completo de indexación documental capaz de automatizar la obtención de licitaciones públicas mediante técnicas de *Web Scraping*, procesar los documentos PDF, fragmentarlos en *chunks*, generar *embeddings* y almacenarlos en una base de datos vectorial *Qdrant*. Gracias a ello, el sistema es capaz de recuperar información contextual relevante y utilizarla para enriquecer las respuestas generadas por el modelo de lenguaje.

A nivel técnico, el proyecto ha permitido profundizar en múltiples áreas de la Ingeniería Informática relacionadas con la inteligencia artificial, el procesamiento del lenguaje natural, las bases de datos vectoriales, el desarrollo *web* y el despliegue de aplicaciones en producción. La implementación de la aplicación *web* mediante *Flask*, junto con el uso de *Docker*, *Gunicorn* y *Nginx*, ha permitido construir un entorno reproducible, escalable y preparado para un despliegue real. Además, la integración de autenticación de usuarios, gestión documental, internacionalización, soporte *responsive* y

paneles de administración ha permitido transformar el prototipo inicial en una aplicación funcional y utilizable.

Otro aspecto especialmente relevante ha sido la incorporación de mecanismos automáticos de evaluación del sistema *RAG* mediante *frameworks* como **RAGAS** y **ARES**. Esto ha permitido analizar métricas relacionadas con la relevancia, fidelidad y precisión de las respuestas generadas, aportando una base objetiva para comparar configuraciones y mejorar el comportamiento del sistema. La evaluación ha puesto de manifiesto que la calidad final de las respuestas no depende únicamente del modelo *LLM* utilizado, sino también del proceso de *chunking*, de los *embeddings*, de la calidad de los documentos y de la estrategia de recuperación semántica empleada.

Durante el desarrollo del proyecto también se han identificado diversas dificultades técnicas. Una de las más importantes ha sido la gran heterogeneidad de formatos presentes en los documentos PDF de licitaciones, especialmente en el proceso de conversión automática a **Markdown** y detección de secciones. Esto ha demostrado que, aunque existen herramientas avanzadas de **OCR** y procesamiento documental, la extracción estructurada de información sigue siendo uno de los retos más complejos en sistemas *RAG* aplicados a documentación real.

Por otro lado, el proyecto ha permitido comprobar la importancia de una buena planificación incremental basada en metodologías ágiles como **Scrum**. La organización del desarrollo en *sprints* facilitó la adaptación continua del proyecto ante problemas técnicos, cambios en la página sobre la que se realiza el *Web Scraping* o modificaciones en las decisiones arquitectónicas tomadas inicialmente.

Desde un punto de vista personal y académico, este trabajo ha supuesto una oportunidad para aplicar de forma práctica numerosos conocimientos adquiridos durante el grado, así como para profundizar en tecnologías emergentes relacionadas con los *LLM* y los sistemas *RAG*. Además, el proyecto ha permitido adquirir experiencia en investigación, diseño de arquitecturas *software*, despliegue de aplicaciones, evaluación de sistemas de inteligencia artificial y documentación técnica de proyectos complejos.

7.1. Líneas de trabajo futuras

Aunque el sistema desarrollado cumple los objetivos planteados inicialmente, existen múltiples líneas de mejora y ampliación que podrían desarrollarse en trabajos futuros.

Una de las mejoras más importantes sería optimizar el *pipeline* de recuperación semántica incorporando técnicas avanzadas de *chunking* semántico y modelos de *reranking*. Actualmente, el sistema emplea recuperación semántica basada en similitud coseno sobre los *embeddings* almacenados en Qdrant, junto con filtros híbridos por número de expediente y tipo documental. Además, los fragmentos recuperados se ordenan según su puntuación de similitud antes de incorporarse al *prompt* del *LLM*. Sin embargo, la arquitectura no incorpora todavía una etapa de *reranking* semántico especializada. Como línea de trabajo futura, podría integrarse un modelo *Cross-Encoder* capaz de reevaluar y reordenar los *chunks* recuperados teniendo en cuenta conjuntamente la consulta del usuario y el contenido completo de cada fragmento. Esto permitiría mejorar significativamente la precisión contextual y la relevancia de las respuestas generadas, especialmente en consultas complejas, ambiguas o sobre documentos extensos donde múltiples fragmentos presentan similitudes vectoriales próximas.

Otra línea de desarrollo futuro podría ser incorporar memoria conversacional persistente. Actualmente, las consultas se procesan de forma independiente, aunque el sistema ya almacena historiales y resultados en base de datos. Una posible evolución consistiría en permitir conversaciones con contexto acumulado, de forma que el usuario pudiera realizar preguntas encadenadas sobre una misma licitación sin necesidad de repetir información previa.

A nivel de modelos de lenguaje, una posible mejora consistiría en incorporar sistemas de inferencia más eficientes que permitan ejecutar modelos de gran tamaño con menores requisitos *hardware*. Actualmente, el sistema integra *Ollama* con soporte configurable para *CPU* y *GPU*, así como carga dinámica de distintos modelos configurables desde variables de entorno. En este contexto, sería especialmente interesante investigar la integración del proyecto *AirLLM* [19], desarrollado para ejecutar modelos *LLM* de gran tamaño mediante técnicas de carga dinámica y reducción del consumo de memoria *VRAM*. Su integración permitiría utilizar modelos más avanzados manteniendo un consumo de recursos reducido, mejorando la escalabilidad y facilitando el despliegue en equipos con recursos limitados.

Otra línea de mejora especialmente relevante sería ampliar el sistema de evaluación automática ya implementado en el proyecto. Actualmente, el sistema incorpora métricas y herramientas de evaluación orientadas al análisis de relevancia y calidad de las respuestas generadas. Como evolución futura, sería especialmente interesante integrar el *framework DeepEval* [11], orientado específicamente a la evaluación y *benchmarking* de aplicaciones basadas en *LLM* y sistemas *RAG*. Esto permitiría automatizar pruebas de regresión, comparar modelos y configuraciones de recuperación, detectar degradaciones de calidad y construir un entorno de validación continua para futuras versiones del sistema.

A nivel documental, otra mejora importante consistiría en perfeccionar el procesamiento estructural de los *PDF*. Durante el desarrollo del proyecto se detectó que la gran heterogeneidad de formatos presentes en los pliegos, dificulta la extracción correcta de secciones y subsecciones. Como línea futura podrían investigarse técnicas multimodales, modelos *OCR* avanzados o herramientas de análisis estructural capaces de generar documentos *Markdown* más precisos y estructurados. Esto permitiría enriquecer los metadatos asociados a cada *chunk* y mejorar la recuperación semántica.

Bibliografía

- [1] Alejandro Alija. Técnicas *RAG*: cómo funcionan y ejemplos de casos de uso. <https://datos.gob.es/es/blog/tecnicas-rag-como-funcionan-y-ejemplos-de-casos-de-uso>, 2024. [Online; Accedido 6-Febrero-2026].
- [2] Inc. Cloudflare. ¿por qué el http no es seguro? | http vs. https. <https://www.cloudflare.com/es-es/learning/ssl/why-is-http-not-secure/>, 2026. [Online; Accedido 26-Febrero-2026].
- [3] Inc. Cloudflare. ¿qué es un proxy inverso? | servidores proxy explicados. <https://www.cloudflare.com/es-es/learning/cdn/glossary/reverse-proxy/>, 2026. [Online; Accedido 26-Febrero-2026].
- [4] Shahul Es, Jithin James, Luis Espinosa Anke, and Steven Schockaert. Ragas: Automated evaluation of retrieval augmented generation. pages 150–158, mar 2024. doi: 10.18653/v1/2024.eacl-demo.16. URL <https://aclanthology.org/2024.eacl-demo.16/>.
- [5] Pandora FMS. Qué es nat y cómo actúa en nuestra red. <https://pandorafms.com/es/it-topics/que-es-nat/>, 2005-2026. [Online; Accedido 26-Febrero-2026].
- [6] Gobierto. Qué es la contratación pública. <https://www.gobierto.es/blog/que-es-la-contratacion-publica>, 2024. [Online; Accedido 22-Febrero-2026].
- [7] Juan José Lozano Gómez. Tutorial de flask en español: Desarrollando una aplicación web en python. <https://j2logo.com/tutorial-flask-espanol/>, 2018-2025. [Online; Accedido 2-Diciembre-2025].

- [8] Peter Dave Hello. Chat with all ai bots concurrently, discover the best. <https://github.com/ai-shifu/ChatALL>, 2025. [Online; Accedido 21-Diciembre-2025].
- [9] Docker Inc. What is docker?. <https://docs.docker.com/get-started/docker-overview/>, 2013-2026. [Online; Accedido 3-Febrero-2026].
- [10] GitHub Inc. Acerca de github y git. <https://docs.github.com/es/get-started/start-your-journey/about-github-and-git>, 2025. [Online; Accedido 22-Septiembre-2025].
- [11] Jeffrey Ip. The llm evaluation framework. <https://github.com/confident-ai/deepeval>, 2026. [Online; Accedido 29-Abril-2026].
- [12] Paul Iusztin. Llm twin course: Building your production-ready ai replica. <https://github.com/decodingai-magazine/llm-twin-course?tab=readme-ov-file>, 2025. [Online; Accedido 9-Febrero-2026].
- [13] Paul Iusztin. Building your second brain ai assistant using agents, llms and rag. <https://github.com/decodingai-magazine/second-brain-ai-assistant-course>, 2025. [Online; Accedido 9-Febrero-2026].
- [14] Paul Iusztin and Maxime Labonne. *The LLM Engineer's Handbook*. Packt Publishing, October 2024. ISBN 9781836200079. [Consultado 30-October-2025 a 27-Noviembre-2025].
- [15] Abhinav Kimothi. *A Simple Guide to Retrieval Augmented Generation*. Manning Publications, July 2025. ISBN 9781633435858. [Consultado 8-Septiembre-2025 a 26-Septiembre-2025].
- [16] Martijn Koster, G. Illyes, H. Zeller, and L. Sassman. Robots exclusion protocol (rfc 9309). <https://datatracker.ietf.org/doc/html/rfc9309>, 2022. [Online; Accedido 07-October-2025].
- [17] Tom Krant and Alexandra Jonker. ¿qué es el envenenamiento de datos? <https://www.ibm.com/es-es/think/topics/data-poisoning>, 2024. [Online; Accedido 15-Mayo-2026].
- [18] Daniel Laparra Osca. Retrieval-augmented generation para la extracción de información de documentos inteligente. Trabajo fin de grado, Universitat Politècnica de València, Escuela Técnica Superior de Ingeniería de Telecomunicación, 2024. URL

- <https://riunet.upv.es/server/api/core/bitstreams/c775be7d-8724-476b-b0a4-73e055d03d50/content>. [Accedido 02-Octubre-2025].
- [19] Gavin Li. Airllm. <https://github.com/lyogavin/airllm>, 2026. [Online; Accedido 25-Marzo-2026].
- [20] Lofred Madzou. What is the rag triad? <https://truera.com/ai-quality-education/generative-ai-rags/what-is-the-rag-triad/>. [Online; Accedido 24-Septiembre-2025].
- [21] Julia Martins. ¿qué es la metodología kanban y cómo funciona?. <https://asana.com/es/resources/what-is-kanban>, 2026. [Online; Accedido 27-Febrero-2026].
- [22] Emergent Mind. Notebooklm: Document-grounded ai by google. <https://www.emergentmind.com/topics/notebooklm>, 2025. [Online; Accedido 10-Febrero-2026].
- [23] Emergent Mind. Notebooklm enterprise. <https://docs.cloud.google.com/gemini/enterprise/notebooklm-enterprise/docs/overview?hl=es>, 2026. [Online; Accedido 10-Febrero-2026].
- [24] Columbia University Mailman School of Public Health. Web scraping. <https://www.publichealth.columbia.edu/research/population-health-methods/web-scraping>, -. [Online; Accedido 28-Septiembre-2025].
- [25] W3C Working Group on Browser Testing and Tools. Webdriver — w3c working draft (level 2). <https://www.w3.org/TR/webdriver2/>, 2025. [Online; Accedido 15-Octubre-2025].
- [26] Orange. Diferencias entre ip pública e ip privada. <https://ayuda.orange.es/particulares/internet-y-wi-fi/configuracion-e-instalacion/6860-diferencias-entre-ip-publica-e-ip-privada>, 2026. [Online; Accedido 26-Febrero-2026].
- [27] Selenium Project. Selenium documentation. <https://www.selenium.dev/documentation/>, 2025. [Online; Accedido 10-Octubre-2025].
- [28] Ragas. Ragas documentation. <https://docs.ragas.io/en/stable/>, 2025. [Online; Accedido 05-Octubre-2025].

- [29] Megan Rogge and microsoft. Visual studio code - open source (code – oss). <https://github.com/microsoft/vscode>. [Online; Accedido 27-Febrero-2026].
- [30] Jon Saad-Falcon, Omar Khattab, Christopher Potts, and Matei Zaharia. Ares: An automated evaluation framework for retrieval-augmented generation systems. 2024. URL <https://arxiv.org/abs/2311.09476>. [Online; Accedido 05-October-2025].
- [31] Josh Schneider and Ian Smalley. ¿qué es un entorno de desarrollo integrado (ide)?. <https://www.ibm.com/es-es/think/topics/integrated-development-environment>, 2018-2026. [Online; Accedido 27-Febrero-2026].
- [32] Ken Schwaber and Jeff Sutherland. The scrum guide. <https://scrumguides.org/docs/scrumguide/v2020/2020-Scrum-Guide-US.pdf>, 2020. [Online; Accedido 22-Septiembre-2025].
- [33] Q2B Studio. Por qué «lost in the middle» rompe la mayoría de los sistemas rag. <https://www.q2bstudio.com/nuestro-blog/429461/descubre-por-que-lost-in-the-middle-puede-causar-problemas-en-los-sistemas-rag-y-como-evitarlos>, 2026. [Online; Accedido 15-Mayo-2026].
- [34] Microsoft Playwright Team. Playwright documentation: Actionability. <https://playwright.dev/docs/actionability>, 2025. [Online; Accedido 10-October-2025].
- [35] Joseph Wright. Tex on windows: Miktex or tex live? *TUGboat*, 33(1):53, 2012. URL <https://www.tug.org/TUGboat/tb33-1/tb103wright.pdf>. [Online; Accedido 22-Septiembre-2025].
- [36] WSGI.org. Wsgi. <https://wsgi.readthedocs.io/en/latest/>, 2016-2026. [Online; Accedido 25-Febrero-2026].
- [37] Zilliz. Qdrant vs. pgvector. <https://zilliz.com/comparison/qdrant-vs-pgvector>, 2025. [Online; Accedido 10-Noviembre-2025].